实验三 — SVM 预测录取率：PCA降维对比分析报告

> 生成时间：2026-04-09 20:48:27

一、实验背景

本实验对比 **PCA降维** 对 SVM 模型性能的影响。
两组实验都使用归一化（实验1已证明归一化效果更好），唯一区别是是否使用PCA降维。

二、什么是PCA降维？

2.1 核心思想

PCA（主成分分析）是一种降维技术，把多个相关的特征合并成少数几个"主成分"。

通俗比喻：

- 原始数据：7个特征（GRE、托福、GPA等）
- PCA降维：找出数据中"最重要的方向"，用5个综合指标代替原来的7个
- 这5个主成分保留了原始数据 **97.5%** 的信息

2.2 为什么要降维？

优点：

1. **减少计算量**：特征少了，训练更快
2. **去除冗余**：GRE和托福往往相关，PCA能合并这些相关信息
3. **避免过拟合**：特征太多容易"记住"训练数据，降维能提高泛化能力
4. **可视化**：降到2-3维可以画图观察数据分布

缺点：

1. **损失信息**：5个主成分只保留97.5%信息，丢失了2.5%
2. **可解释性差**：主成分是原始特征的线性组合，不像"GRE分数"那么直观

三、实验设置

- **模型**：SVR（支持向量回归），RBF 核，C=100，gamma=0.1，epsilon=0.1
- **数据划分**：训练集 400 条（80%），测试集 100 条（20%），随机种子=42
- **预处理**：两组都用 MinMaxScaler 归一化
- **唯一变量**：
  - **对比组A**：归一化 → SVM（7个特征）
  - **对比组B**：归一化 → PCA降维 → SVM（5个主成分）

四、实验结果

4.1 数值对比

指标	不降维（7特征）	PCA降维（5特征）	变化
MSE（↓越小越好）	0.004666	0.004785	+2.6%
RMSE（↓越小越好）	0.068306	0.069175	+1.3%
R^2（↑越大越好）	0.771848	0.766005	-0.005843
训练时间	0.0098秒	0.0064秒	+34.1%
特征数	7	5	-29%
方差保留	100.0%	97.5%	-2.5%

> **结论：不降维效果更好。**

4.2 PCA主成分分析

降维后的5个主成分及其方差贡献：

主成分	方差贡献	累计方差
PC1	63.48%	63.48%
PC2	20.54%	84.02%
PC3	5.87%	89.90%
PC4	4.54%	94.44%
PC5	3.05%	97.49%

解读：

- **PC1（第一主成分）**：解释了 63.5% 的数据变化，是最重要的综合指标
- 可能代表"学术能力"（GRE+托福+GPA的综合）
- **PC2（第二主成分）**：解释了 20.5%，可能代表'软实力'（推荐信+SOP）

4.3 可视化分析

对比图保存在： `results/06_pca_comparison_plot.png`

图中包含 6 个子图（2行×3列）：

- **第一行**：不降维的预测图、残差图、统计信息
- **第二行**：PCA降维的预测图、残差图、方差解释图

五、深入分析

5.1 为什么降维后效果变差了？

降维降低了模型性能（R^2 从 0.7718 → 0.7660）

可能原因：

1. **信息损失**：5个主成分只保留了97.5%信息，丢失的2.5%可能包含重要信息
2. **非线性关系**：PCA是线性降维，如果特征之间有非线性关系，PCA无法捕捉
3. **数据集特点**：这个数据集只有7个特征，本身维度不高，降维收益有限

结论： 对于这个数据集，保留所有7个特征效果更好。

5.2 计算效率对比

- **训练时间**：降维后 +34.1%（更快）
- **特征数**：从7个减少到5个，减少29%

注意： 在这个小数据集上（500条），时间差异不明显。
但在大数据集（百万级样本、上千特征）上，降维能显著加速训练。

六、结论与建议

6.1 何时使用PCA降维？

适合降维的场景：

- 特征数量很多（几十到上千个）
- 特征之间高度相关（如图像的像素、文本的词频）
- 计算资源有限，需要加速训练
- 需要可视化高维数据（降到2-3维）

不适合降维的场景：

- 特征数量本身就很少（如本实验的7个）
- 特征之间相互独立，没有冗余
- 需要保留特征的可解释性（如医疗诊断、金融风控）

6.2 实际开发中的最佳实践

1. **先尝试不降维**：如果特征不多（<20个），先用全部特征训练
2. **观察方差解释率**：如果前几个主成分就能解释95%以上方差，可以考虑降维
3. **交叉验证**：用交叉验证对比降维前后的效果，选择更好的方案
4. **注意顺序**：归一化 → PCA → 模型训练（PCA前必须归一化）

6.3 本实验总结

- **数据集**：研究生录取预测，7个特征，500条数据
- **PCA结果**：5个主成分保留97.5%信息
- **模型效果**：不降维效果更好（$R^2 = 0.7718$）
- **建议**：对于这个数据集，保留全部特征

本报告由 exp2/06_analysis.py 自动生成