实验三 — SVM 预测录取率：三模型对比分析报告

> 生成时间：2026-04-09 21:33:59

一、实验背景

本实验对比三种经典机器学习算法在研究生录取预测任务上的表现：

- **多元线性回归**：最简单的线性模型
- **SVM（支持向量机）**：强大的非线性模型
- **决策树**：直观易懂的树形模型

二、三种模型简介

2.1 多元线性回归（Linear Regression）

核心思想： 假设目标值是特征的线性组合。

```
录取概率 = w₁×GRE + w₂×托福 + w₃×GPA + ... + 常数
```

优点：

- 训练速度快，计算简单
- 可解释性强：能看出每个特征的权重
- 不容易过拟合

缺点：

- 只能处理线性关系
- 对异常值敏感
- 假设特征之间相互独立

适用场景： 特征和目标呈线性关系，需要快速建模和解释

2.2 SVM（支持向量机）

核心思想： 找到最优的超平面（或曲面）来拟合数据。

使用 RBF 核函数可以处理非线性关系：

```
K(x, x') = exp(-γ||x - x'||²)
```

优点：

- 能处理非线性关系（通过核函数）
- 泛化能力强，不容易过拟合
- 在高维空间表现良好

缺点：

- 训练速度慢（尤其是大数据集）
- 参数调优复杂（C, gamma, epsilon）
- 可解释性差（黑盒模型）
- 必须归一化

适用场景： 数据量中等，关系复杂，追求高精度

2.3 决策树（Decision Tree）

核心思想： 通过一系列"是/否"问题来做决策。

```
GRE >= 320?
├─ 是 → GPA >= 8.5?
│        ├─ 是 → 录取概率 = 0.85
│        └─ 否 → 录取概率 = 0.65
└─ 否 → ...
```

优点：

- 非常直观，容易理解和解释

- 不需要归一化
- 能自动处理特征交互
- 能处理非线性关系

缺点：

- 容易过拟合（需要剪枝）
- 不够稳定（数据稍变，树结构可能完全不同）
- 对连续值预测不够精确

适用场景： 需要可解释性，特征有明显的阈值划分

三、实验设置

- **数据集**：研究生录取预测，7个特征，500条数据
- **数据划分**：训练集 400 条（80%），测试集 100 条（20%），随机种子=42
- **预处理**：
  - 线性回归 & SVM：MinMaxScaler 归一化
  - 决策树：不归一化（不需要）
- **模型参数**：
  - 线性回归：默认参数
  - SVM：RBF核，C=100，gamma=0.1，epsilon=0.1
  - 决策树：max_depth=5，min_samples_split=10（防止过拟合）

四、实验结果

4.1 数值对比

模型	MSE（↓越小越好）	RMSE（↓越小越好）	R^2（↑越大越好）	训练时间
线性回归	0.003705	0.060866	0.818843	0.0117秒
SVM	0.004666	0.068306	0.771848	0.0081秒
决策树	0.006366	0.079786	0.688714	0.0041秒

> **结论：线性回归效果最好（R^2 = 0.818843）**

4.2 排名分析

准确度排名（按 R^2 从高到低）：

1. **线性回归** - R^2 = 0.818843
2. **SVM** - R^2 = 0.771848
3. **决策树** - R^2 = 0.688714

速度排名（按训练时间从快到慢）：

1. **决策树** - 0.0041秒
2. **SVM** - 0.0081秒
3. **线性回归** - 0.0117秒

4.3 可视化分析

对比图： `results/10_model_comparison_plot.png`

- 3×3 九宫格，每行一个模型
- 每行包含：预测图、残差图、误差分布

指标对比图： `results/10_metrics_comparison.png`

- MSE、R^2、训练时间的柱状对比

五、深入分析

5.1 为什么线性回归效果最好?

线性回归表现最好，说明：

- 这个数据集的特征和目标之间主要是线性关系
- GRE、托福、GPA等分数与录取概率呈线性相关
- 简单模型有时比复杂模型更好（奥卡姆剃刀原则）

启示： 不要盲目追求复杂模型，先尝试简单模型建立基线。

5.2 模型选择建议

场景1：追求最高精度
→ 选择 **线性回归**（$R^2 = 0.818843$）

场景2：需要快速训练
→ 选择 **决策树**（0.0041秒）

场景3：需要可解释性
→ 选择 **线性回归**（能看系数）或 **决策树**（能看规则）

场景4：数据量很大（百万级）
→ 避免 SVM（太慢），选择线性回归或决策树

场景5：特征很多（上千维）
→ 线性回归可能欠拟合，SVM 或决策树更好

六、特征重要性分析

6.1 线性回归的系数

特征	系数	解释
CGPA	0.3511	正相关
GRE Score	0.1217	正相关
TOEFL Score	0.0839	正相关
LOR	0.0603	正相关
Research	0.0240	正相关

解读：

- 系数为正：该特征越大，录取概率越高
- 系数为负：该特征越大，录取概率越低
- 系数绝对值越大，该特征越重要

6.2 决策树的特征重要性

特征	重要性
CGPA	0.8936
GRE Score	0.0619
SOP	0.0144
LOR	0.0131
Research	0.0067

解读：

- 重要性基于信息增益（该特征能减少多少不确定性）
- 重要性越高，该特征在决策树中越靠近根节点

七、总结与建议

7.1 本实验结论

1. **最佳模型：**{best_model}（R^2 = {best_r2:.6f}）
2. **最快模型：**{models[sorted_time_indices[0]]}（{time_vals[sorted_time_indices[0]]:.4f}秒）
3. **三个模型都达到了可接受的精度**（$R^2 > 0.7$）

7.2 实际应用建议

如果你是数据科学家：

- 先用线性回归建立基线（快速、简单）
- 再尝试 SVM 或决策树看能否提升
- 用交叉验证选择最佳模型

如果你是产品经理：

- 需要向用户解释预测结果 → 用线性回归或决策树
- 只关心准确度 → 用 {best_model}
- 需要实时预测（毫秒级） → 避免 SVM

如果你是学生（Me,做作业）：

- 三个模型都跑一遍，对比分析
- 理解每个模型的优缺点
- 根据数据特点选择合适的模型

7.3 进一步优化方向 (可以做了解呢)

1. **超参数调优**：用 GridSearchCV 寻找最佳参数
2. **特征工程**：尝试特征交互（如 GRE×GPA）
3. **集成学习**：用随机森林或 XGBoost 提升效果
4. **交叉验证**：用 K-fold 验证模型稳定性

本报告由 exp3/10_model_comparison.py 自动生成