第二章：模型评估与选择

互动

- 机器学习模型设计主要考虑什么？
  - 泛化能力：过拟合/欠拟合
  - 分解：偏差/方差/噪声
- 怎么评估不同的机器学习模型？
  - -训练集/验证集/测试集；
  - 留出法/交叉验证法/自助法
- 有哪些常见的性能指标？
  - 均方误差
  - 错误率和精度
  - 查准率、查全率和F1
  - ROC与AUC

大纲

- 经验误差与过拟合
- 偏差与方差
- 评估方法
- 性能度量
- 阅读材料

经验误差与过拟合

- 错误率&误差：
  - 错误率：错分样本的占比： $E = a/m$
  - 误差：样本真实输出与预测输出之间的差异
    - 训练(经验)误差：训练集上
    - 测试误差：测试集
    - 泛化误差：除训练集外所有样本

由于事先并不知道新样本的特征，我们只能努力使经验误差最小化；很多时候虽然能在训练集上做到分类错误率为零，但多数情况下这样的学习器并不好。

经验误差与过拟合

- 过拟合：

  学习器把训练样本学习的“太好”，将训练样本本身的特点，当做所有样本的一般性质，导致泛化性能下降

  - 优化目标加正则项；early stop

- 欠拟合：

  对训练样本的一般性质尚未学好

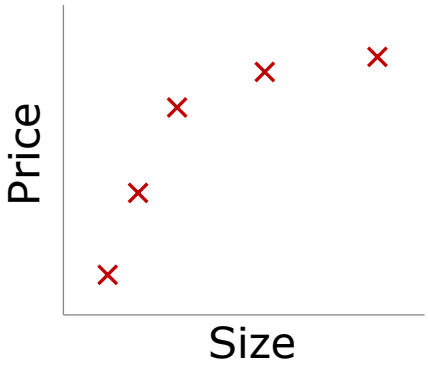

$\theta_0 + \theta_1 x$

欠拟合
高偏差

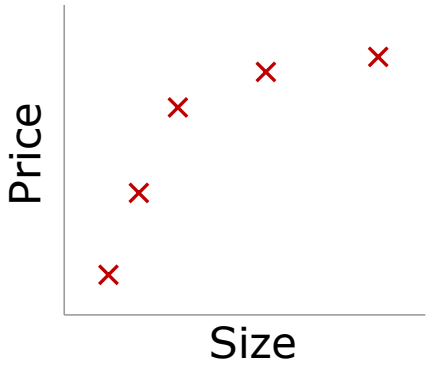

$\theta_0 + \theta_1 x + \theta_2 x^2$

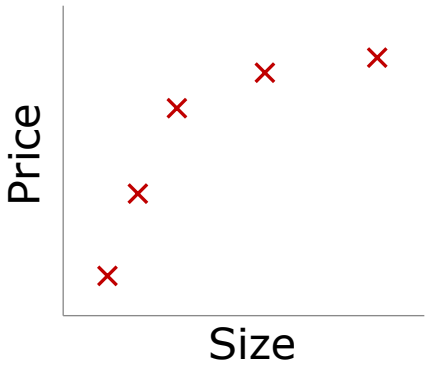

$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$

过拟合
高方差

经验误差与过拟合

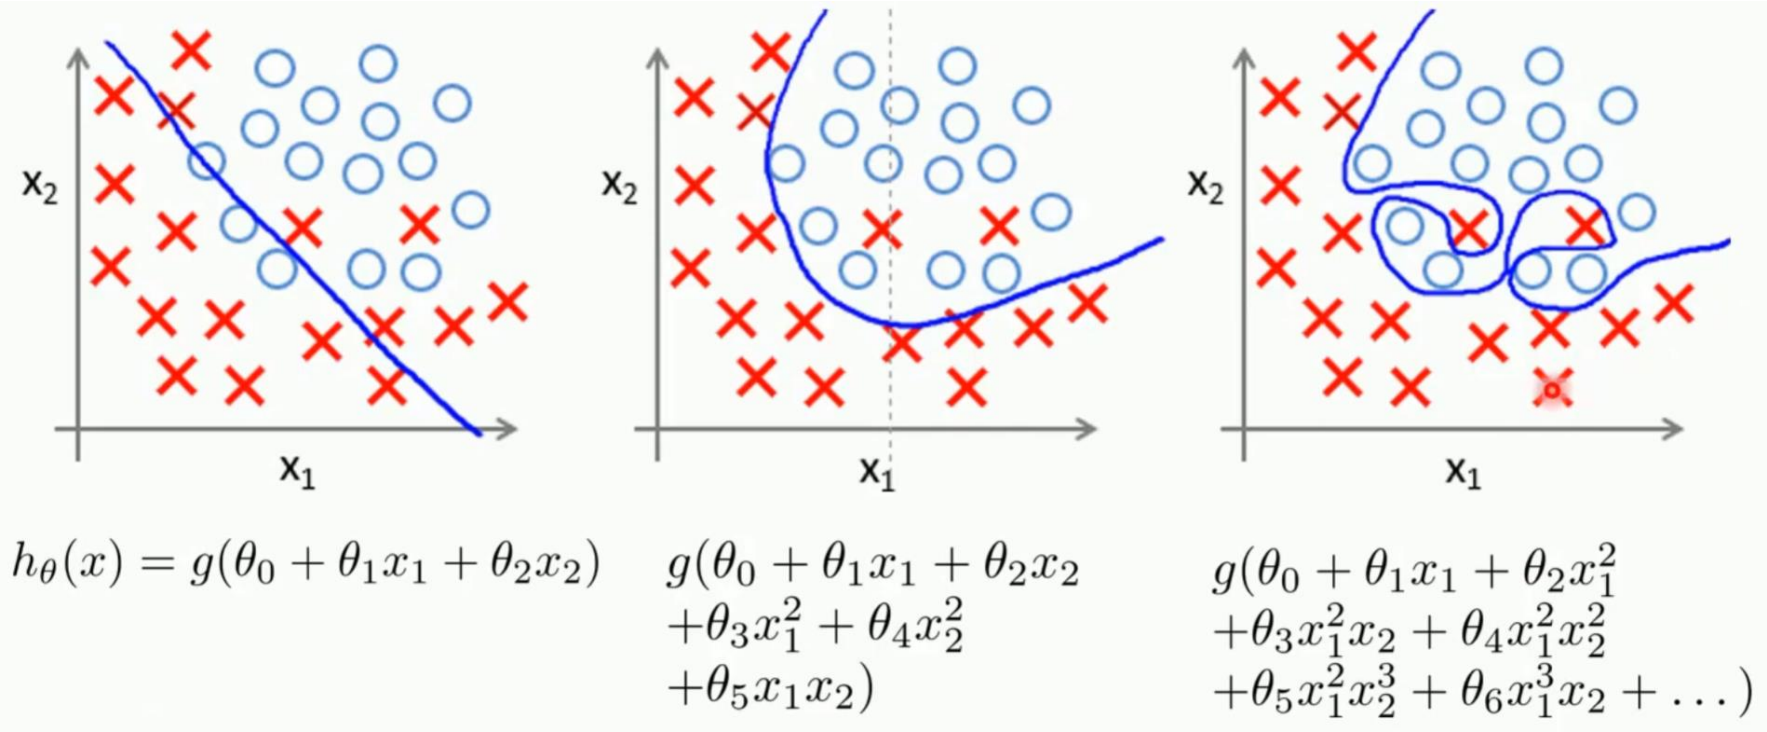

欠拟合　　正确拟合　　过拟合

经验误差与过拟合

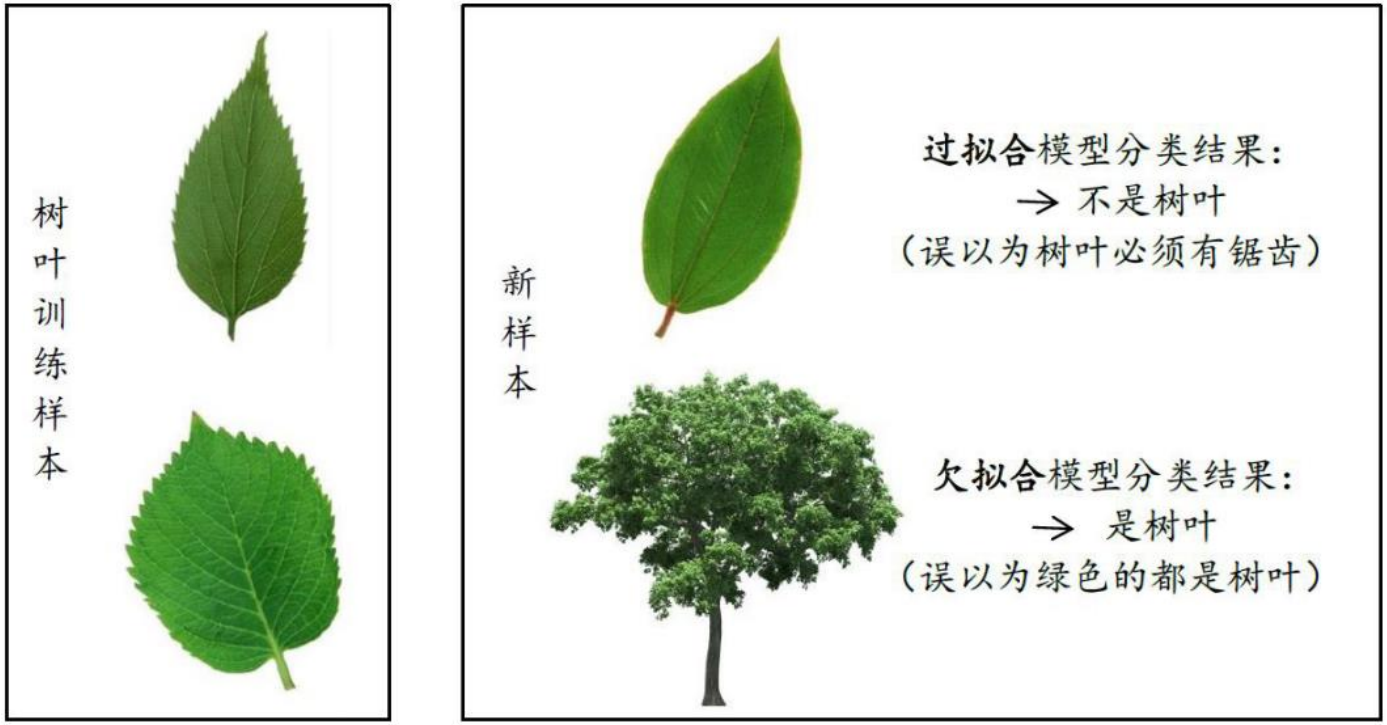

过拟合、欠拟合的直观类比

大纲

- 经验误差与过拟合
- 偏差与方差
- 评估方法
- 性能度量
- 阅读材料

基本术语-偏差与方差

- **偏差**：度量模型预测的期望值与真实值的偏离程度，反映模型的拟合能力。高偏差意味着模型过于简单，容易欠拟合。例如，用线性模型拟合二次函数，无论怎么调整，线性模型都无法逼近真实曲线，导致系统性偏差。
- **方差**：度量模型预测的波动程度，即同样大小的训练集变动导致的学习性能变化，反映模型对数据扰动的敏感性。高方差意味着模型过于复杂，容易过拟合。例如，深度决策树对训练数据的微小变化非常敏感，稍微改变几个样本，树的结构就可能完全不同，导致预测结果大幅波动。
- **噪声**：数据本身的不可约误差，与模型无关。它表达了当前任务上任何学习算法所能达到的期望泛化误差的下界，即学习问题本身的难度。例如，在图像分类中，模糊的图像即使人类也难以辨别，这种不确定性就是噪声。

基本术语-偏差与方差

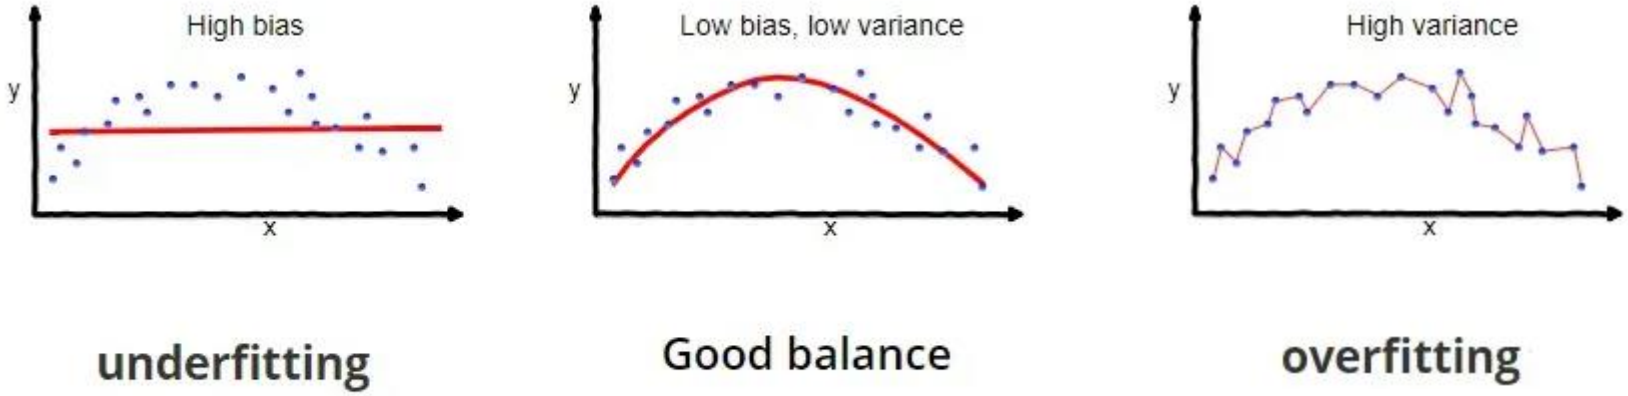

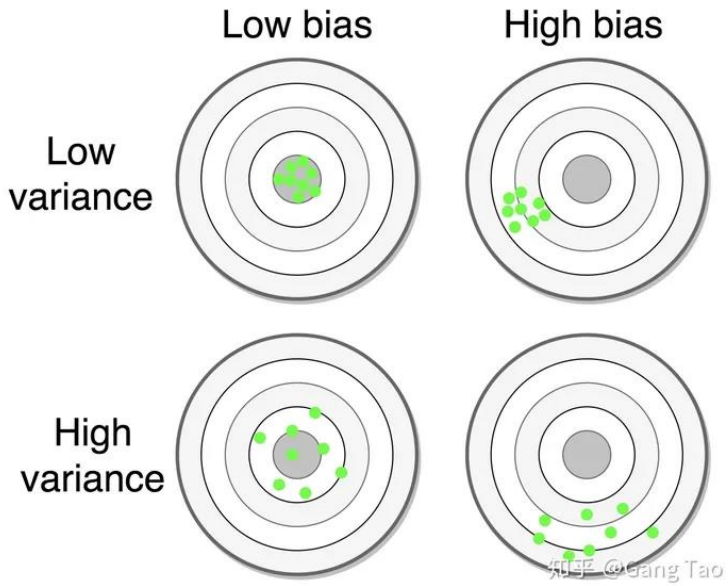

偏差（bias）：描述模型输出结果的期望与样本真实结果的差距。 **准确度**

方差（var）：描述模型对于给定值的输出稳定性。 **精确度/稳定性**

基本术语-偏差与方差

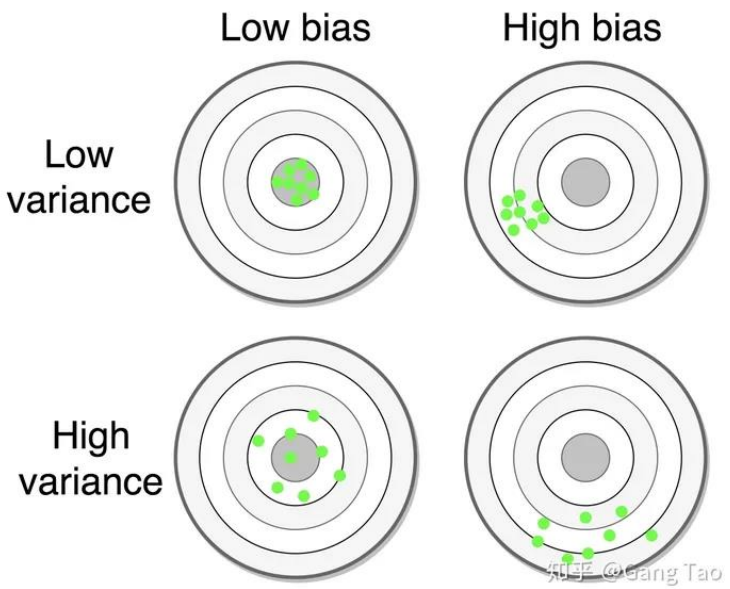

特征	偏差 (BIAS)	方差 (VARIANCE)
衡量指标	准确度	精确度
值高意味着	系统性偏离真实值	预测结果分散不稳定
打靶比喻	离靶心的距离	射击点的分散程度

	低方差 (精确)	高方差 (不精确)
低偏差 (准确)	理想：准确且稳定	尚可：平均准确但分散
高偏差 (不准确)	差：稳定地出错	最差：不准也不稳

基本术语-偏差与方差

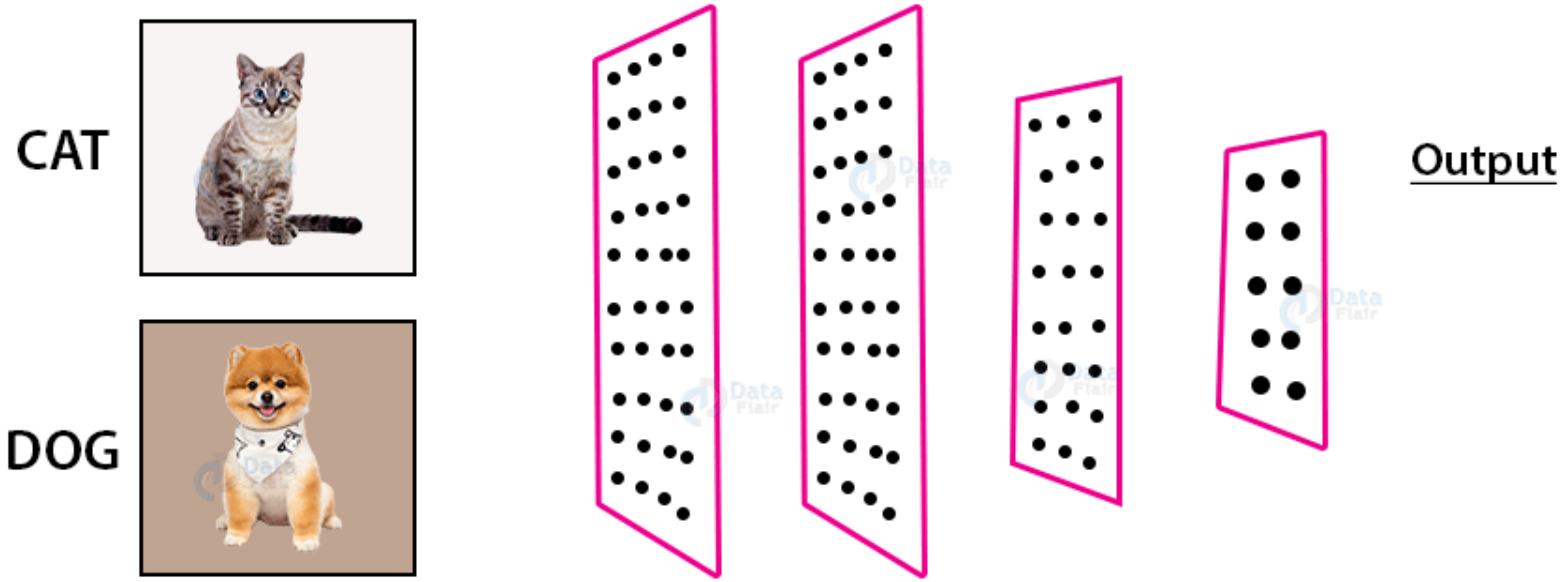

(1)训练集错误率：1%、测试集错误率：11%　　低偏差 高方差

(2)训练集错误率：15%、测试集错误率：16%　　高偏差 低方差

(3)训练集错误率：15%、测试集错误率：30%　　高偏差 高方差

(4)训练集错误率：0.5%、测试集错误率：1%　　低偏差 低方差

泛化误差的偏差与方差分解

通过实验可以估计学习算法的泛化性能，而“偏差-方差分解”可以用来帮助解释泛化性能。偏差-方差分解试图对学习算法期望的泛化错误率进行**拆解**。

泛化误差可分解为偏差、方差与噪声之和。

$$\boxed{E(f;D) = bias^2(\boldsymbol{x}) + var(\boldsymbol{x}) + \varepsilon^2}$$

- 偏差，对象是单个模型，度量期望输出与真实结果的偏离程度；即模型对数据的**拟合能力**；
- 方差，对象是多个模型，度量了换同样规模的训练集所导致的学习性能的变化；即刻画了**数据扰动**所造成的影响；
- 噪声表达了在当前任务上任何学习算法所能达到的期望泛化误差的下界；即刻画了学习问题**本身的难度**。

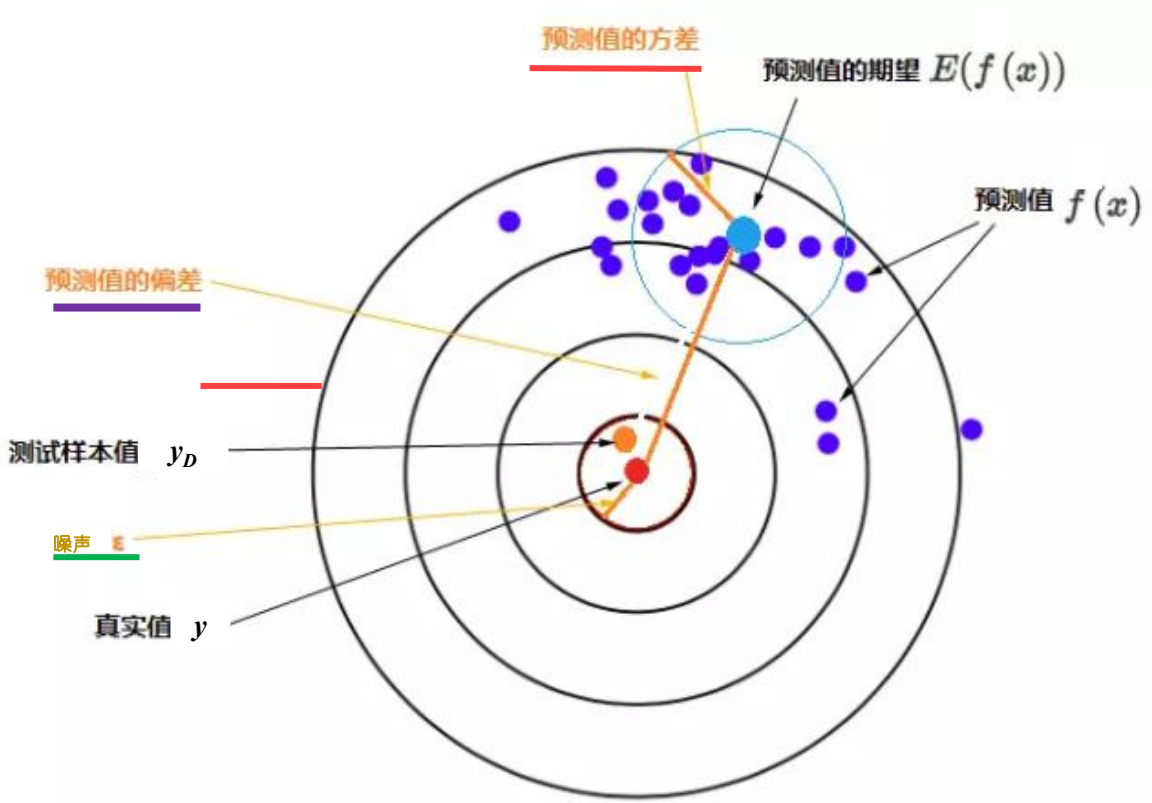

泛化错误率的偏差与方差分解

对测试**样本**x,令y_D为x在数据集中的标记,y为x的**真实标记**,$f(\boldsymbol{x};D)$为训练集D上学得模型f在x上的**预测**输出。针对不同数据集D，f在x上的期望预期为：

$$\boxed{E(f;D)=bias^2(\boldsymbol{x})+var(\boldsymbol{x})+\varepsilon^2}$$

$$\bar{f}(\boldsymbol{x})=\mathbb{E}_D[f(\boldsymbol{x};D)]$$

$$Err(\boldsymbol{x})=\mathbb{E}_D\left[\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})\right)^2\right]+\left(\bar{f}(\boldsymbol{x})-y\right)^2+\mathbb{E}_D\left[(y_D-y)^2\right]$$

偏差为

$$bias^2(\boldsymbol{x})=\left(\bar{f}(\boldsymbol{x})-y\right)^2$$

使用样本数目相同的不同训练集产生的方差：

$$var(\boldsymbol{x})=\mathbb{E}_D\left[\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})\right)^2\right]$$

噪声为

$$\varepsilon^2=\mathbb{E}_D\left[(y_D-y)^2\right]$$

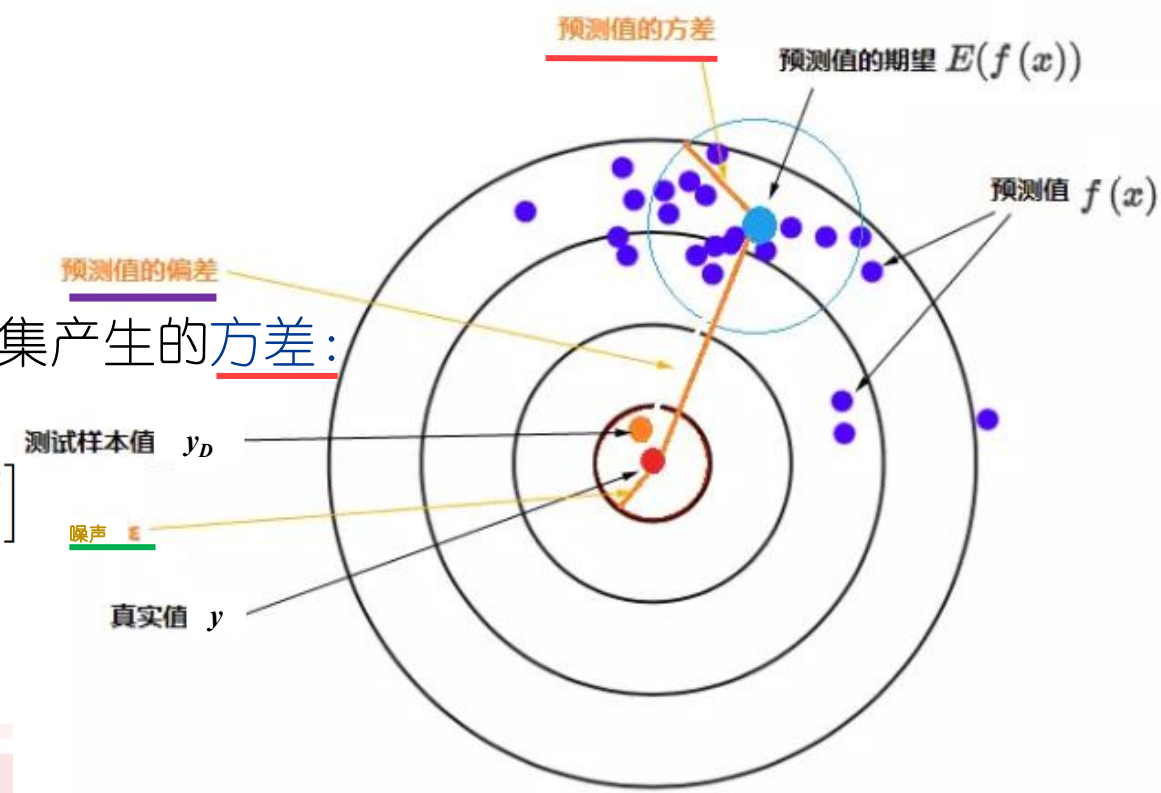

偏差与方差

泛化误差分解：

$$
\begin{aligned}
E(f;D) =& \mathbb{E}_D\left[(f(\boldsymbol{x};D)-y_D)^2\right] \\
=& \mathbb{E}_D\left[\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})+\bar{f}(\boldsymbol{x})-y_D\right)^2\right] \\
=& \mathbb{E}_D\left[\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})\right)^2\right]+\mathbb{E}_D\left[\left(\bar{f}(\boldsymbol{x})-y_D\right)^2\right] \\
&+\mathbb{E}_D\left[2\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})\right)\left(\bar{f}(\boldsymbol{x})-y_D\right)\right] \\
=& \mathbb{E}_D\left[\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})\right)^2\right]+\mathbb{E}_D\left[\left(\bar{f}(\boldsymbol{x})-y_D\right)^2\right] \\
=& \mathbb{E}_D\left[\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})\right)^2\right]+\mathbb{E}_D\left[\left(\bar{f}(\boldsymbol{x})-y+y-y_D\right)^2\right] \\
=& \mathbb{E}_D\left[\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})\right)^2\right]+\mathbb{E}_D\left[\left(\bar{f}(\boldsymbol{x})-y\right)^2\right]+\mathbb{E}_D\left[(y-y_D)^2\right] \\
&+2\mathbb{E}_D\left[\left(\bar{f}(\boldsymbol{x})-y\right)(y-y_D)\right] \\
=& \mathbb{E}_D\left[\left(f(\boldsymbol{x};D)-\bar{f}(\boldsymbol{x})\right)^2\right]+\left(\bar{f}(\boldsymbol{x})-y\right)^2+\mathbb{E}_D\left[(y-y_D)^2\right]
\end{aligned}
$$

偏差与方差

泛化误差要衡量的是“模型在所有可能场景下的平均表现”，这才是它的核心价值。

偏差衡量的是“模型的平均预测值与真实值之间的差距”——简单说，就是模型“骨子里”的错误，是它对问题的“先天偏见”。

方差衡量的是“模型预测值的波动程度”——也就是模型在不同训练集上的预测结果有多不稳定。

噪声是下限：因为偏差和方差都是非负的，所以泛化误差的最小值不可能低于噪声——这就是“模型再好，也不可能完美预测所有数据”的数学依据。

偏差与方差-偏差-方差窘境

一般来说，偏差与方差是有冲突的，称为偏差-方差窘境。在噪声固定的情况下，偏差减小，方差往往会增大；方差减小，偏差往往会增大。
如右图所示，假如我们能控制算法的训练程度：

- 在训练不足时，学习器拟合能力不强，训练数据的扰动不足以使学习器的拟合能力产生显著变化，此时偏差主导泛化错误率；
- 随着训练程度加深，学习器拟合能力逐渐增强，方差逐渐主导泛化错误率；
- 训练充足后，学习器的拟合能力非常强，训练数据的轻微扰动都会导致学习器的显著变化，若训练数据自身非全局特性被学到则会发生过拟合。

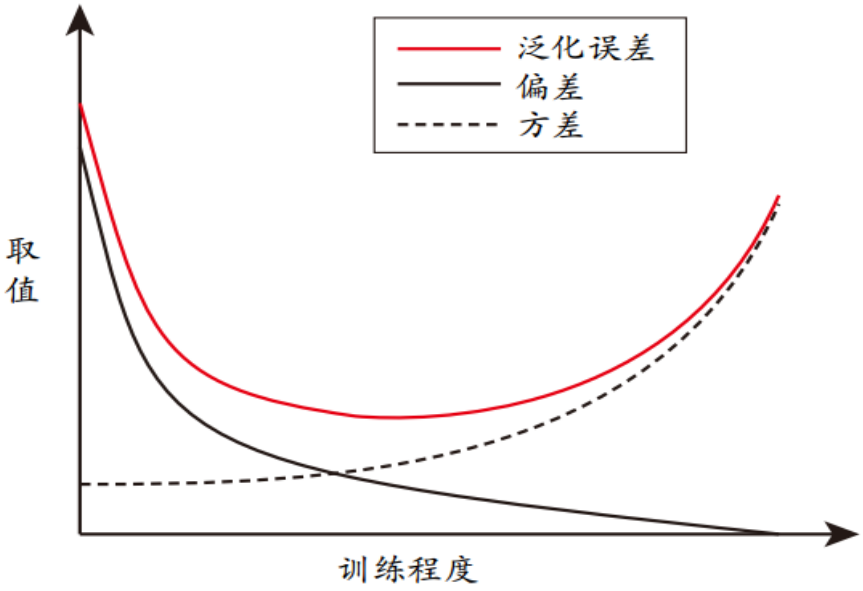

泛化误差与偏差、方差的关系示意图

偏差与方差

如何控制偏差和方差？

1. 降低偏差：提升模型的“拟合能力”
（1）复杂模型；（2）增加参数；（3）特征工程；

2. 降低方差：提升模型的“稳健性”
（1）正则化；（2）数据增广；（3）集成学习；

3. 交叉验证：找到偏差-方差的“平衡点”

4. 噪声处理：降低泛化误差的“下限”
（1）数据清洗；（2）数据平滑。

偏差与方差

通过实验可以估计学习算法的泛化性能，而“偏差-方差分解”可以用来帮助解释泛化性能。偏差-方差分解试图对学习算法期望的泛化错误率进行**拆解**。

偏差：由于简单的假设所造成的。

低偏差：对目标函数提出更少的假设；
高偏差：对目标函数提出更多的假设；
低偏差模型例子：KNN 和 SVM；
高偏差模型例子：线性回归和逻辑斯特回归；

方差：由于不同训练集的分布不同造成的。

低方差：随着训练数据集的变化，对目标函数估计值的变化非常小；
高方差：随着训练数据集的变化，对目标函数估计值的变化非常大；

一般而言，具有很大灵活性的非参数学习算法都具有很高的方差。
高方差例子：KNN 和 SVM。

偏差与方差

补充：**参数学习**和**非参数学习**

参数学习：通过固定大小的参数集概括数据的学习模型；

1.选择合适的目标函数的形式，2.通过训练数据学习目标函数的参数。

常见算法：

- 逻辑回归、线性成分分析、感知机

非参数学习：对于目标函数形式不作过多的假设的算法；

常见算法：

- KNN、决策树，例如CART和C4.5、支持向量机、神经网络

大纲

- 经验误差与过拟合
- 偏差与方差
- 评估方法
- 性能度量
- 阅读材料

评估方法

现实任务中往往会对学习器的泛化性能、时间开销、存储开销、可解释性等方面的因素进行评估并做出选择

我们假设测试集是从样本真实分布中独立采样获得，将测试集上的“测试误差”作为泛化误差的近似，所以测试集要和训练集中的样本尽量互斥。

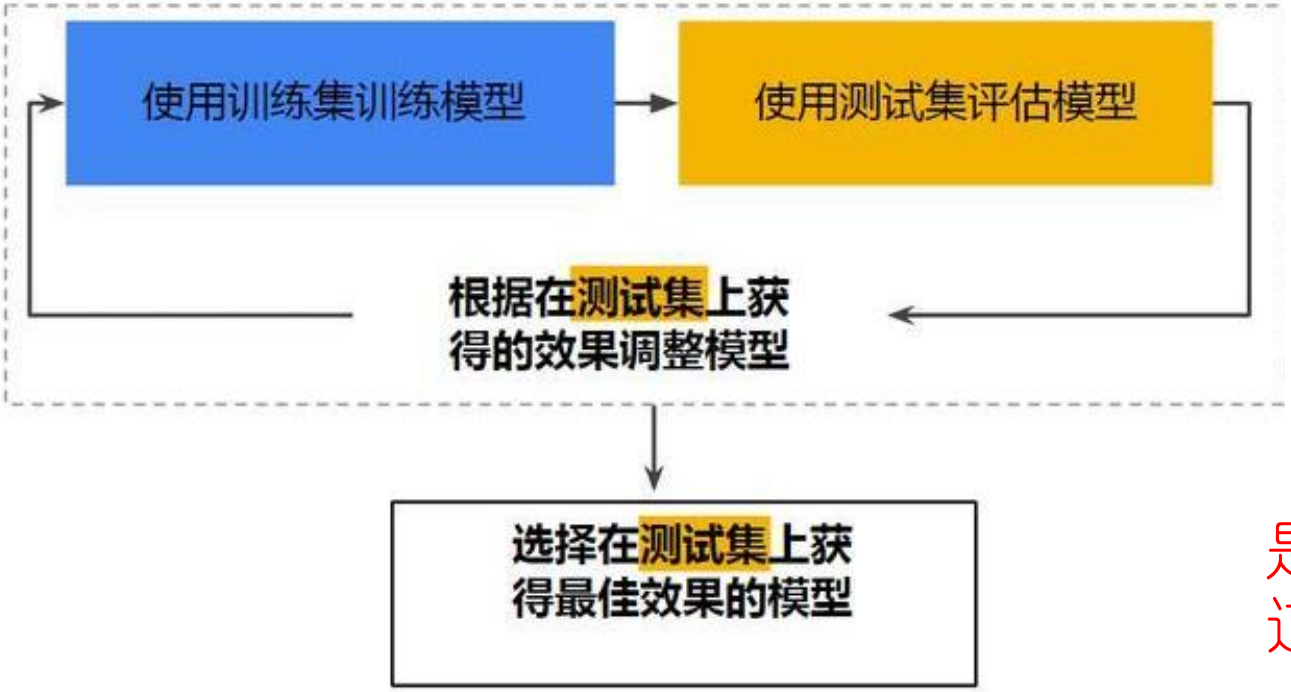

是不是还听过验证集？

评估方法

为什么需要验证集？

防止针对测试集的特性进行了过拟合

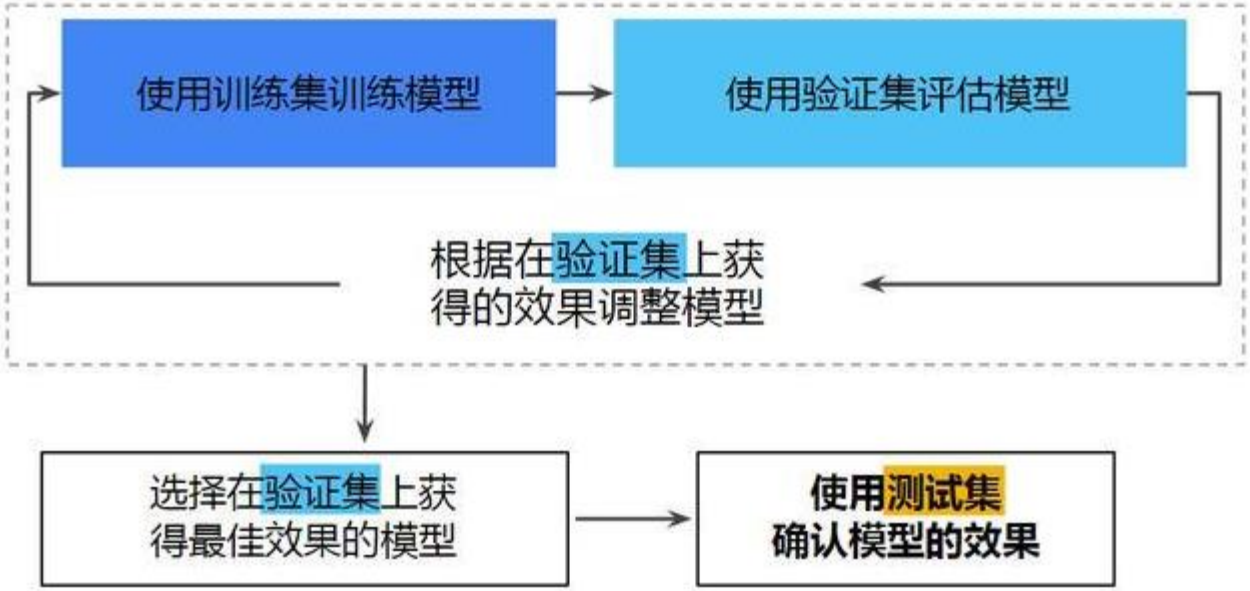

评估方法

训练集、测试集、验证集三者区别

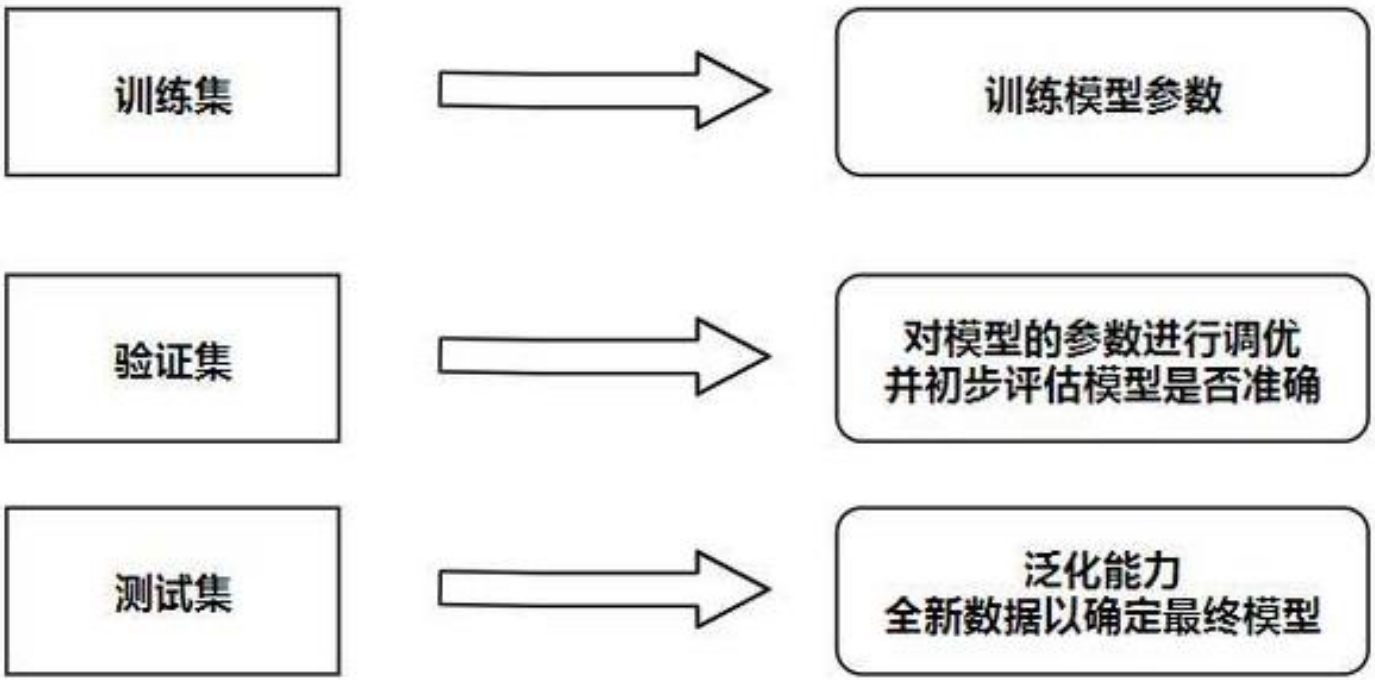

评估方法

- 划分训练集和测试集的方法：
  - 留出法；
  - 交叉验证法；
  - 自助法

评估方法-留出法

通常将包含个m样本的数据集$D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$
拆分成训练集 S 和测试集 T：

- 留出法：
  - 直接将数据集划分为两个互斥集合
  - 训练/测试集划分要尽可能保持数据分布的一致性
  - 一般若干次随机划分、重复实验取平均值
  - 训练/测试样本比例通常为2:1~4:1

评估方法-交叉验证法

- 交叉验证法：

将数据集分层采样划分为k个大小相似的互斥子集，每次用k-1个子集的并集作为训练集，余下的子集作为测试集，最终返回k个测试结果的均值，k最常用的取值是10.

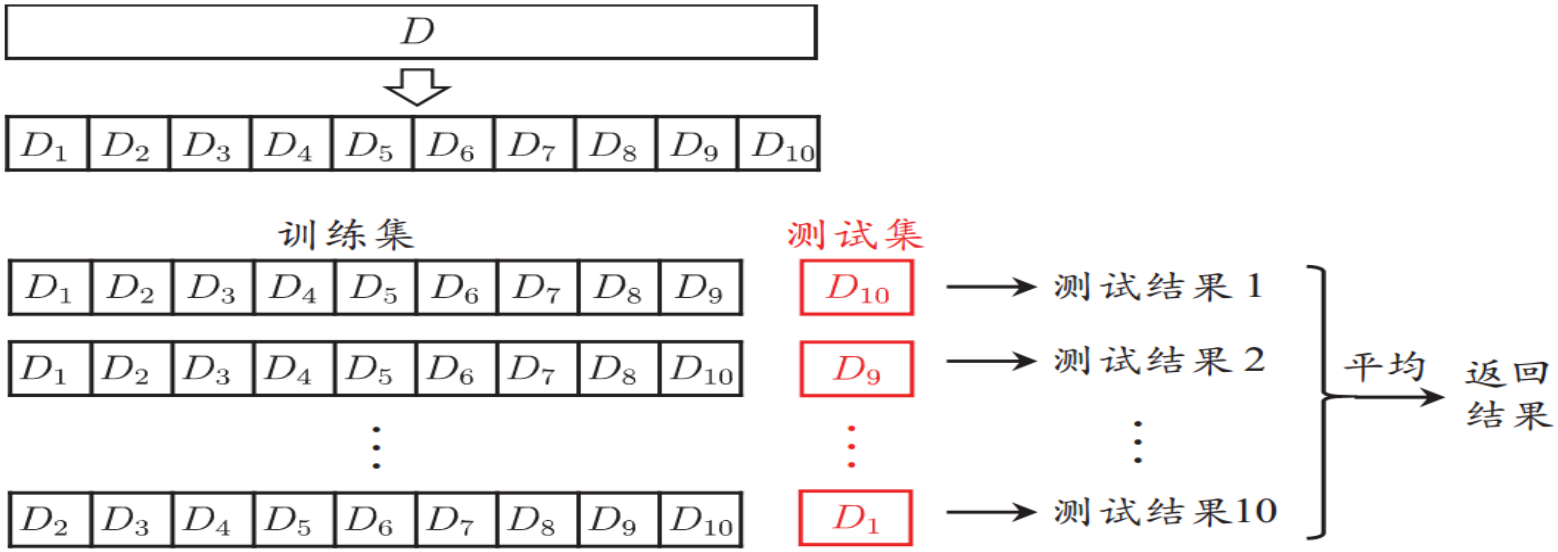

10 折交叉验证示意图

评估方法

与留出法类似，将数据集D划分为k个子集同样存在多种划分方式，为了减小因样本划分不同而引入的差别，k折交叉验证通常随机使用不同的划分重复p次，最终的评估结果是这p次k折交叉验证结果的均值，例如常见的“10次10折交叉验证”

假设数据集D包含m个样本，若令 $k = m$ 则得到留一法：

- 不受随机样本划分方式的影响
- 结果往往比较准确
- 当数据集比较大时，计算开销难以忍受

评估方法-自助法

- 自助法：

  以自助采样法为基础，对数据集 D 有放回采样 m 次得到训练集 D'，$D \setminus D'$ 用做测试集。

  - 实际模型与预期模型都使用 m 个训练样本
  - 约有1/3的样本没在训练集中出现
  - 从初始数据集中产生多个不同的训练集，对集成学习有很大的好处
  - 自助法在数据集较小、难以有效划分训练/测试集时很有用；由于改变了数据集分布可能引入估计偏差，在数据量足够时，留出法和交叉验证法更常用。

大纲

- 经验误差与过拟合
- 偏差与方差
- 评估方法
- 性能度量
- 阅读材料

性能度量

性能度量是衡量模型**泛化能力**的评价标准，反映了任务需求；使用不同的性能度量往往会导致不同的**评判结果**

在预测任务中，给定样例集 $D=\{(\boldsymbol{x}_1,y_1),(\boldsymbol{x}_2,y_2),\ldots,(\boldsymbol{x}_m,y_m)\}$
评估学习器的性能 f 也即把**预测结果** $f(\boldsymbol{x})$ 和**真实标记** $\boldsymbol{y}$ 比较.

回归任务最常用的性能度量是“均方误差”：

$$E(f;D)=\frac{1}{m}\sum_{i=1}^{m}\left(f\left(\boldsymbol{x}_i\right)-y_i\right)^2$$

性能度量-1. 错误率和精度

对于分类任务,错误率和精度是最常用的两种性能度量：

- 错误率：分错样本占样本总数的比例
- 精　度：分对样本占样本总数的比例

分类错误率

$$E(f;D)=\frac{1}{m}\sum_{i=1}^{m}\mathbb{I}\left(f\left(\boldsymbol{x}_i\right)\neq y_i\right)$$

精度

$$\begin{aligned}\operatorname{acc}(f;D) &= \frac{1}{m}\sum_{i=1}^{m}\mathbb{I}\left(f\left(\boldsymbol{x}_i\right)=y_i\right)\\ &= 1-E(f;D)\ .\end{aligned}$$

性能度量-2.查准率、查全率与F1

情景一

在信息检索、Web搜索等应用中经常出现，例如在信息检索中，我们经常会关心：

“检索出的信息中有多少比例是用户感兴趣的”， 查准率

“用户感兴趣的信息中有多少被检索出来了”。 查全率

情景二

假定瓜农拉来一车西瓜，想把好瓜挑出来。我们用训练好的模型对这些西瓜进行判别，显然，错误率衡量了有多少比例的瓜被判别错误。但是我们关心的是

“挑出的西瓜中有多少比例是好瓜”， 查准率

“所有好瓜中有多少比例被挑了出来” 查全率

→ 查准率 和 查全率

性能度量—混淆矩阵

统计真实标记和预测结果的组合可以得到“混淆矩阵”

分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

查准率
(精确率)

$$P = \frac{TP}{TP + FP}$$

查全率
(召回率)

$$R = \frac{TP}{TP + FN}$$

性能度量-”P-R曲线”

根据学习器的预测结果，按正例可能性大小，对样例进行排序，并逐个把样本作为正例进行预测，则可以得到查准率-查全率曲线，简称“P-R曲线”

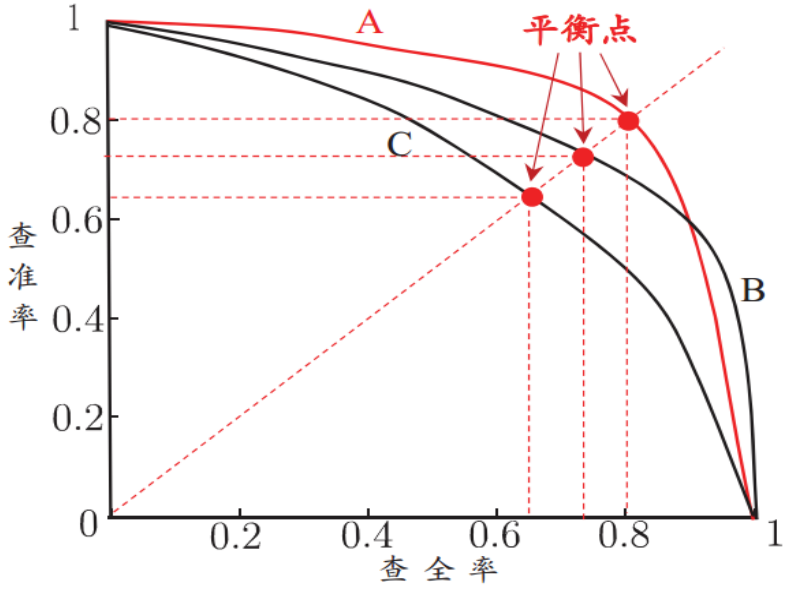

P-R曲线与平衡点示意图

平衡点是曲线上“查准率=查全率”时的取值，可用来度量P-R曲线有交叉的分类器性能高低

性能度量-"P-R曲线"-举个例子

假设：
- 共 **10** 个样本
- 真实正例（1）：**5** 个
- 真实负例（0）：**5** 个

总正例 = 5 个
（位置 1、2、3、5、7）

绘制规则：
依次把**每个样本的得分当作阈值**：
≥ 阈值 → 判为正例
< 阈值 → 判为负例
每一个阈值，算出一对 **(Recall, Precision)**，
就是曲线上**一个点**。

把样本**按模型预测得分从高到低排好序**

排序	真实标签 y	模型预测得分	含义
1	1	0.95	最像正例
2	1	0.90	
3	1	0.85	
4	0	0.80	误判高分
5	1	0.75	
6	0	0.70	
7	1	0.65	
8	0	0.60	
9	0	0.55	
10	0	0.50	最不像正例

性能度量-”P-R曲线”-举个例子

点 1：阈值 = 0.95（只把最高分判正）
- 预测正例：第 1 个
- TP=1, FP=0, FN=5−1=4
- Precision=1+01=1.00,Recall=51=0.20
- **点 1：(0.20, 1.00)**

点 2：阈值 = 0.90
- 预测正例：1、2
- TP=2, FP=0, FN=3
- Precision=1.00,Recall=0.40
- **点 2：(0.40, 1.00)**

点 3：阈值 = 0.85
- 预测正例：1、2、3
- TP=3, FP=0, FN=2
- Precision=1.00,Recall=0.60
- **点 3：(0.60, 1.00)**

点 4：阈值 = 0.80（开始出现假阳性）
- 预测正例：1、2、3、4
- TP=3, FP=1, FN=2
- Precision=43=0.75,Recall=0.60
- **点 4：(0.60, 0.75)**

……

把样本按模型预测得分从高到低排好序

排序	真实标签 y	模型预测得分	含义
1	1	0.95	最像正例
2	1	0.90	
3	1	0.85	
4	0	0.80	误判高分
5	1	0.75	
6	0	0.70	
7	1	0.65	
8	0	0.60	
9	0	0.55	
10	0	0.50	最不像正例

性能度量-F1度量

比P-R曲线平衡点更用常用的是F1度量：

$$F1 = \frac{2 \times P \times R}{P + R} = \frac{2 \times TP}{\text{样例总数} + TP - TN}$$

F1的大小反应了模型的稳定性。数值越大，说明越稳定。

比F1更一般的形式 F_β，

$$F_\beta = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$

$\beta = 1$： 标准F1

$\beta > 1$： 偏重查全率（逃犯信息检索）

$\beta < 1$： 偏重查准率（商品推荐系统）

性能度量-3. ROC曲线

1. 一个混淆矩阵：

分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

查准率（精确率）

$$P = \frac{TP}{TP + FP}$$

查全率（召回率）

$$R = \frac{TP}{TP + FN}$$

2.计算TPR和FPR，得到（TPR1，FPR1）

- 真正例率(True Postive Rate)TPR: TP/(TP+FN),代表分类器预测的正类中实际正实例占所有正实例的比例。
- 假正例率(False Postive Rate)FPR: FP/(FP+TN). 代表分类器预测的正类中实际负实例占所有负实例的比例。

3. ROC曲线：

1. 将模型预测结果从高到低排序，将每次概率值依次作为阈值，那么就可以得到多个混淆矩阵，对应(TPR_1，FPR_1),…,(TPR_n，FPR_n)。
2. 以FPR为横坐标，TPR为纵坐标，画出曲线。

性能度量-3. ROC与AUC

类似P-R曲线，根据学习器的预测结果对样例排序，并逐个作为正例进行预测，以“假正例率”为横轴，“真正例率”为纵轴可得到ROC曲线，全称“受试者工作特征”.

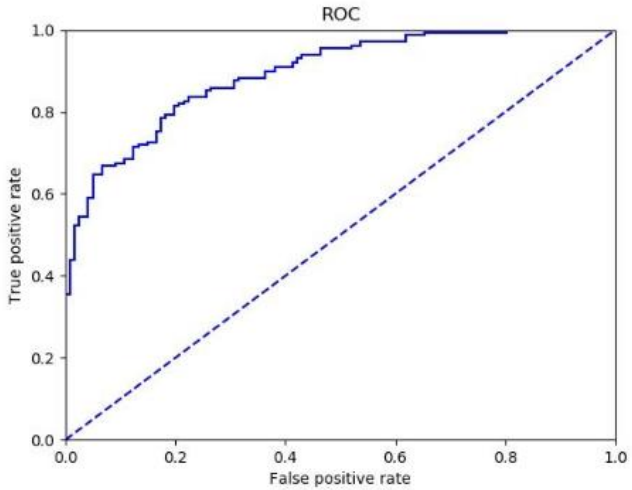

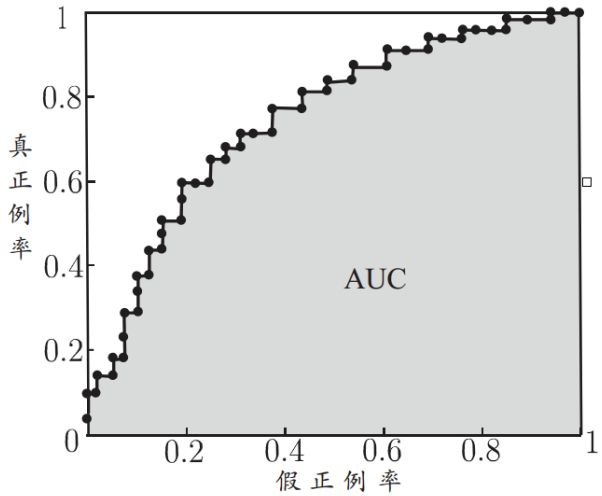

基于有限样例绘制的 ROC 曲线与 AUC

ROC图的绘制：给定 m^+ 个正例和 m^- 个负例，根据学习器预测结果对样例进行排序，将分类阈值设为每个样例的预测值，当前标记点坐标为 (x,y)，当前若为真正例，则对应标记点的坐标为 $(x, y+\frac{1}{m^+})$；当前若为假正例，则对应标记点的坐标为 $(x+\frac{1}{m^-}, y)$，然后用线段连接相邻点.

性能度量-AUC

若某个学习器的ROC曲线被另一个学习器的曲线“包住”，则后者性能优于前者；否则如果曲线交叉，可以根据ROC曲线下面积大小进行比较，也即AUC值（Area Under ROC Curve）。

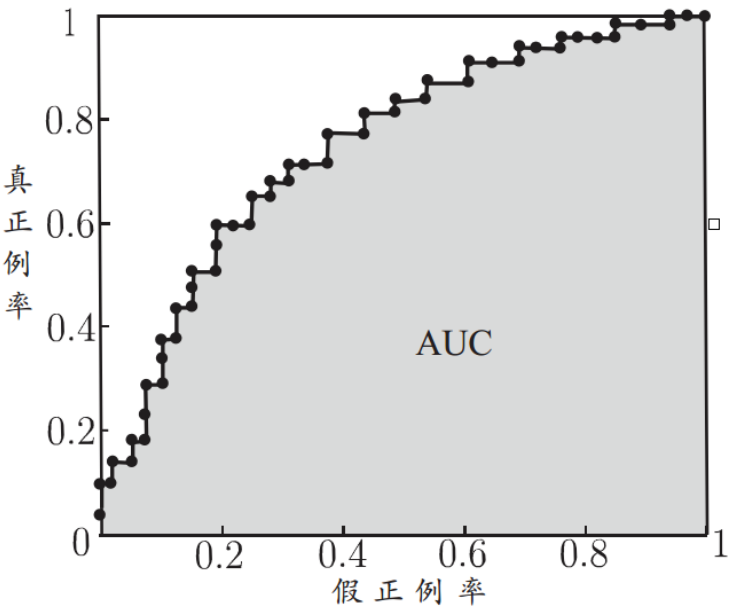

基于有限样例绘制的 ROC 曲线与 AUC

假设ROC曲线由$\{(x_1,y_1),(x_2,y_2),\ldots,(x_m,y_m)\}$的点按序连接而形成，$(x_1=0,\ x_m=1)$，则：

AUC可估算为：

$$\mathrm{AUC}=\frac{1}{2}\sum_{i=1}^{m-1}(x_{i+1}-x_i)\cdot(y_i+y_{i+1})$$

AUC衡量了样本预测的排序质量。

性能度量

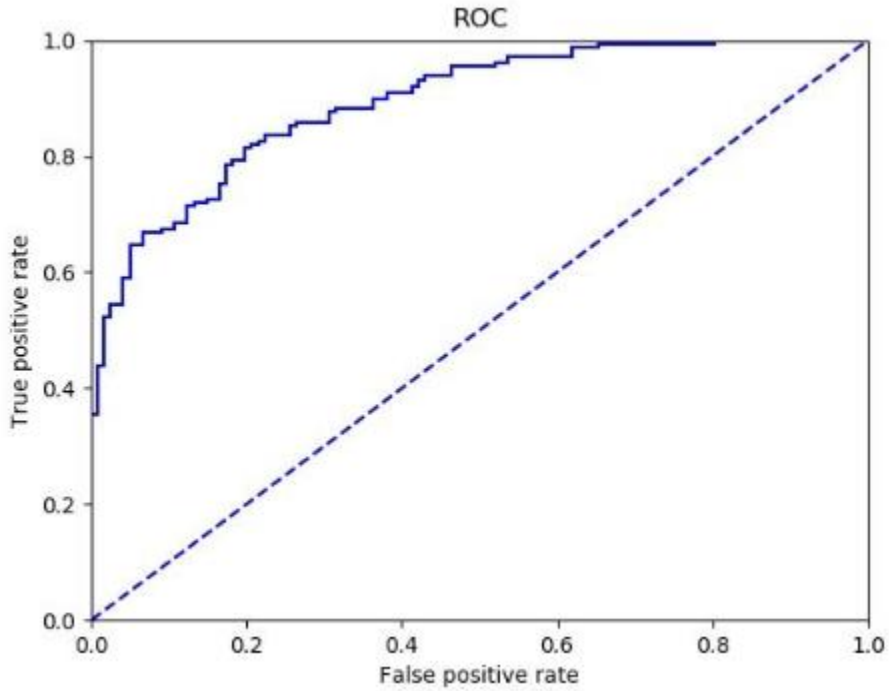
ROC
True positive rate
False positive rate
0.0
0.2
0.4
0.6
0.8
1.0

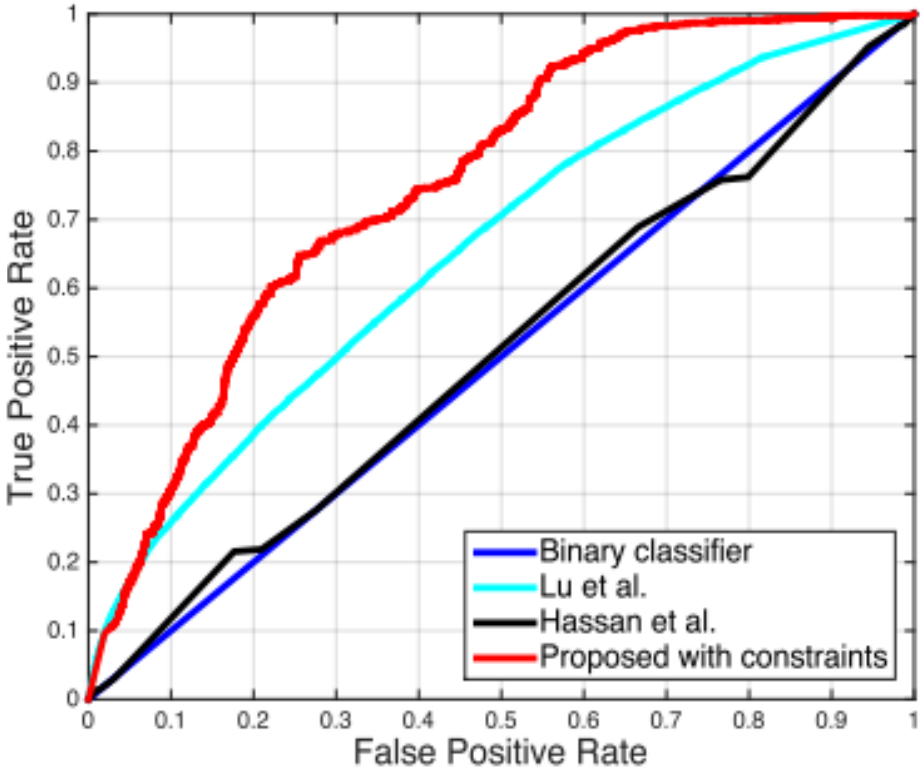
True Positive Rate
False Positive Rate
Binary classifier
Lu et al.
Hassan et al.
Proposed with constraints
0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.8
0.9
1

大纲

- 经验误差与过拟合
- 偏差与方差
- 评估方法
- 性能度量
- 阅读材料

阅读材料

- 自助采样法在机器学习中有重要用途,[Efron and Tibshirani, 1993]对此有详细讨论。

- ROC曲线在二十世纪八十年代后期被引入机器学习[Spackman, 1989],AUC则是从九十年代中期起在机器学习领域广为使用[Bradley,1997].[Hand and Till,2001]将ROC曲线从二分类任务推广到多分类任务.[Fawcett,2006]综述了ROC曲线的用途.

- [Drummond and Holte,2006]发明了代价曲线.代价敏感学习[Elkan,2001;Zhou and Liu,2006]专门研究非均等代价下的学习。

阅读材料

- [Dietterich,1998]指出了常规k折交叉验证法存在的风险,并提出了5*2折交叉验证法.[Demsar, 2006]讨论了对多个算法进行比较检验的方法.

- [Geman et al.,1992]针对回归任务给出了偏差-方差-协方差分解,后来被简称为偏差-方差分解。但仅基于均方误差的回归任务中推导，对分类任务，由于0/1损失函数的跳变性,理论上推导出偏差-方差分解很困难。已有多种方法可通过试验队偏差和方差进行估计[Kong and Dietterich,1995;Kohavi and Wolpert, 1996; Breiman,1996;Friedman,1997;Domingos,2000].

作业

1. 数据集包含100个样本，其中正反例各一半，假定学习算法所产生的模型是将新样本预测为训练样本数较多的类别（训练样本数相同时进行随机猜测），试给出用10折交叉验证法和留一法分别对错误率进行评估所得的结果。

2. 试述错误率与ROC曲线之间的关系。

下节课准备

- Ch. 3 线性模型
  - 上台：线性判别模型LDA
  - 学生： ?