复习-线性模型

- 线性回归
  - 单元线性回归
  - 多元线性回归

最小二乘法
梯度下降法

- 二分类任务
  - 对数几率回归
  - 线性判别分析

广义线性回归模型
对数几率函数、极大似然法
最大化广义瑞利商

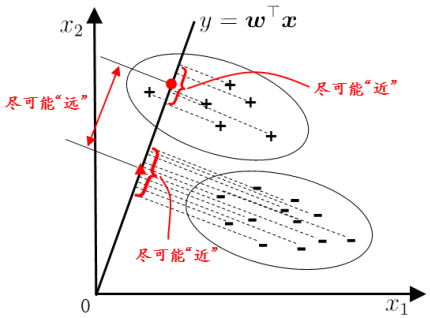

- 多分类学习
  - 一对一、一对其余、多对多
- 类别不平衡问题

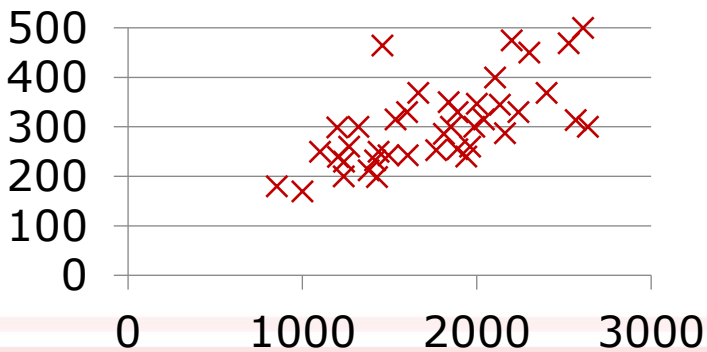

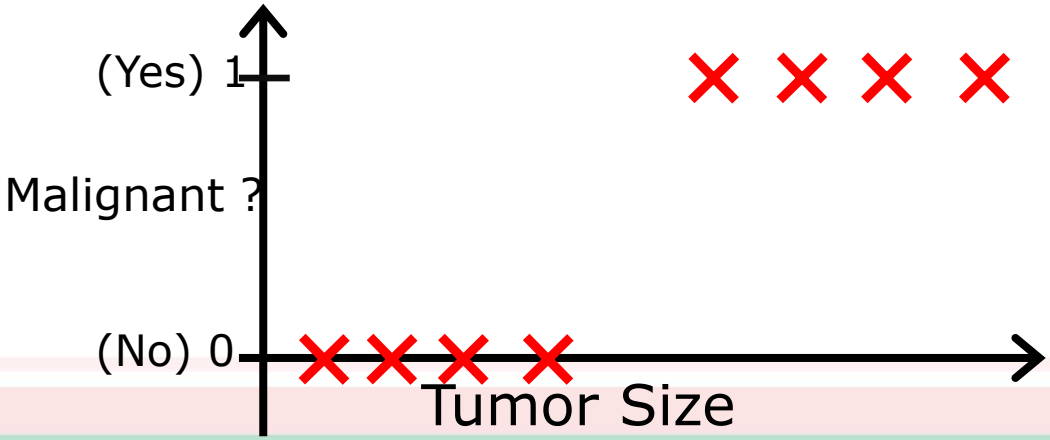

线性回归小结-1

- 给定：
  - 数据集

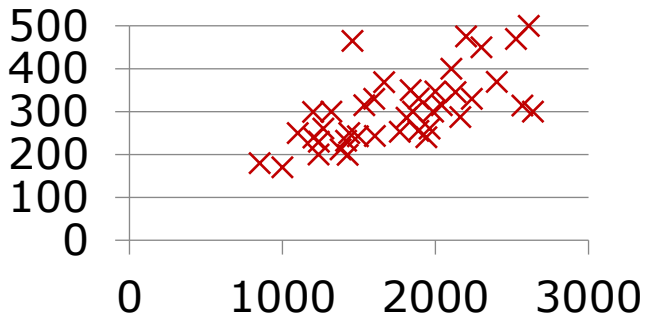

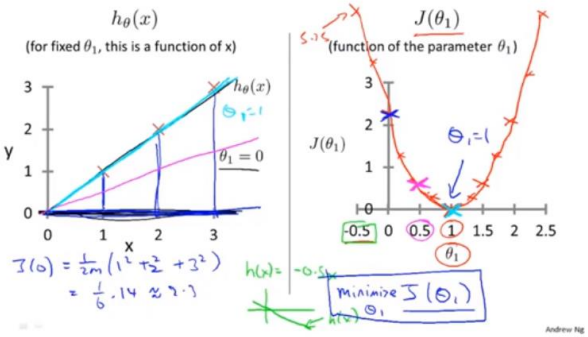

- 输出：
  - 模型（假设、参数）：单变量线性模型

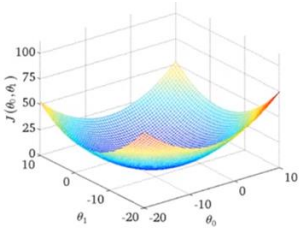

- 求解（函数+算法）：
  - 函数：代价函数/损失函数{均方误差、……}
  - 算法：最小二乘法、梯度下降

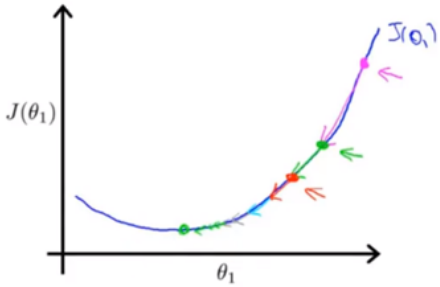

线性回归小结-2

- 给定：
  - 数据集
- 输出：
  - 模型（假设、参数）{多变量线性回归}
- 求解（函数+算法）：
  - 函数：代价函数/损失函数{均方误差}
  - 算法：梯度下降、正规方程法
    - 技巧：特征缩放、均值归一化、学习率设置
  - 特征选择、多项式回归

Size (feet²) x_1	Number of bedrooms x_2	Number of floors x_3	Age of home (years) x_4	Price ($1000) y
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
…	…	…	…	…

$m = 47$

Notation:

- n = number of features $\quad n=4$
- $x^{(i)}$ = input (features) of ith training example.
- $x_j^{(i)}$ = value of feature j in i^{th} training example.

$x^{(2)} = \begin{bmatrix} 1416 \\ 3 \\ 2 \\ 40 \end{bmatrix}$

$x_3^{(2)} = 2$

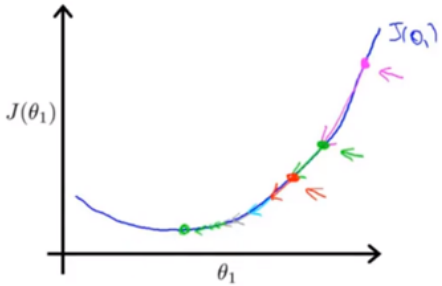

对数几率回归小结

模型：

$$y = \frac{1}{1+e^{-z}}$$

$$\Downarrow$$

$$ln\frac{y}{1-y} = w^T x + b$$

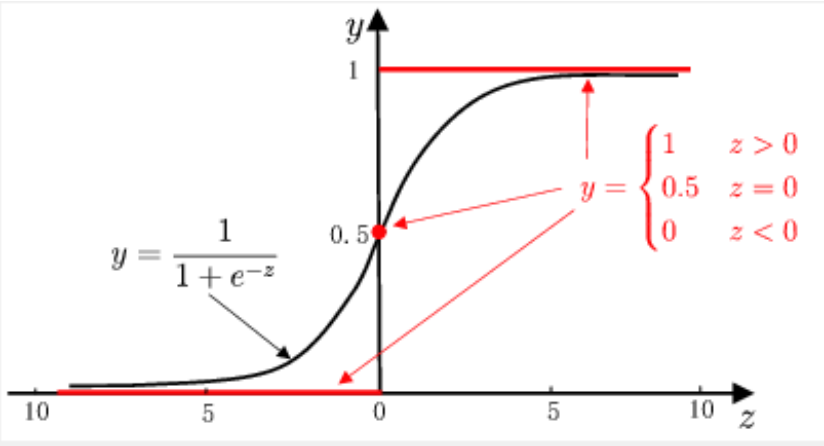

函数：

$$J(\theta) = -\frac{1}{m}[\sum_{i=1}^{m} y^{(i)} \log h_\theta(x^{(i)}) + (1-y^{(i)}) \log (1-h_\theta(x^{(i)}))]$$

算法：

Want $\min_\theta J(\theta)$:

$$\Theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix}$$

for i=0 to n

Repeat{

$$\boxed{\theta_j := \theta_j - \alpha \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}}$$

(simultaneously update all θ_j)

}

$h_\theta(x) = \theta^T x$

$h_\theta(x) = \frac{1}{1+e^{-\theta^T x}}$

线性判别分析小结

- 线性判别分析（Linear Discriminant Analysis）[Fisher, 1936]

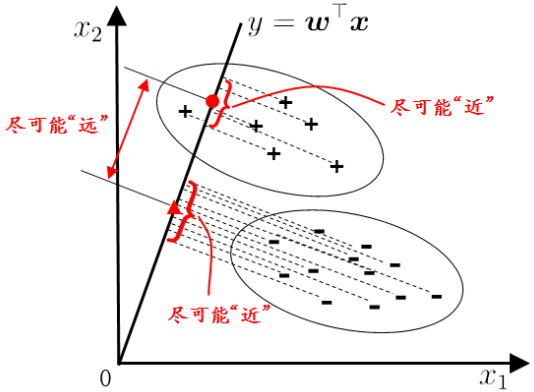

LDA也可被视为一种监督降维技术

"试金石"

$$J = \frac{\left\|\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}_0 - \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}_1\right\|_2^2}{\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}_0\boldsymbol{w} + \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}_1\boldsymbol{w}} = \frac{\boldsymbol{w}^{\mathrm{T}}\left(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1\right)\left(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1\right)^{\mathrm{T}}\boldsymbol{w}}{\boldsymbol{w}^{\mathrm{T}}\left(\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1\right)\boldsymbol{w}}$$

$$J = \frac{w^T S_b w}{w^T S_w w}$$

广义瑞利商

类间散度：
类别中心距离，尽可能大

类内散度：
同类样本间协方差，尽可能小

3.5多分类学习 – 两种策略比较

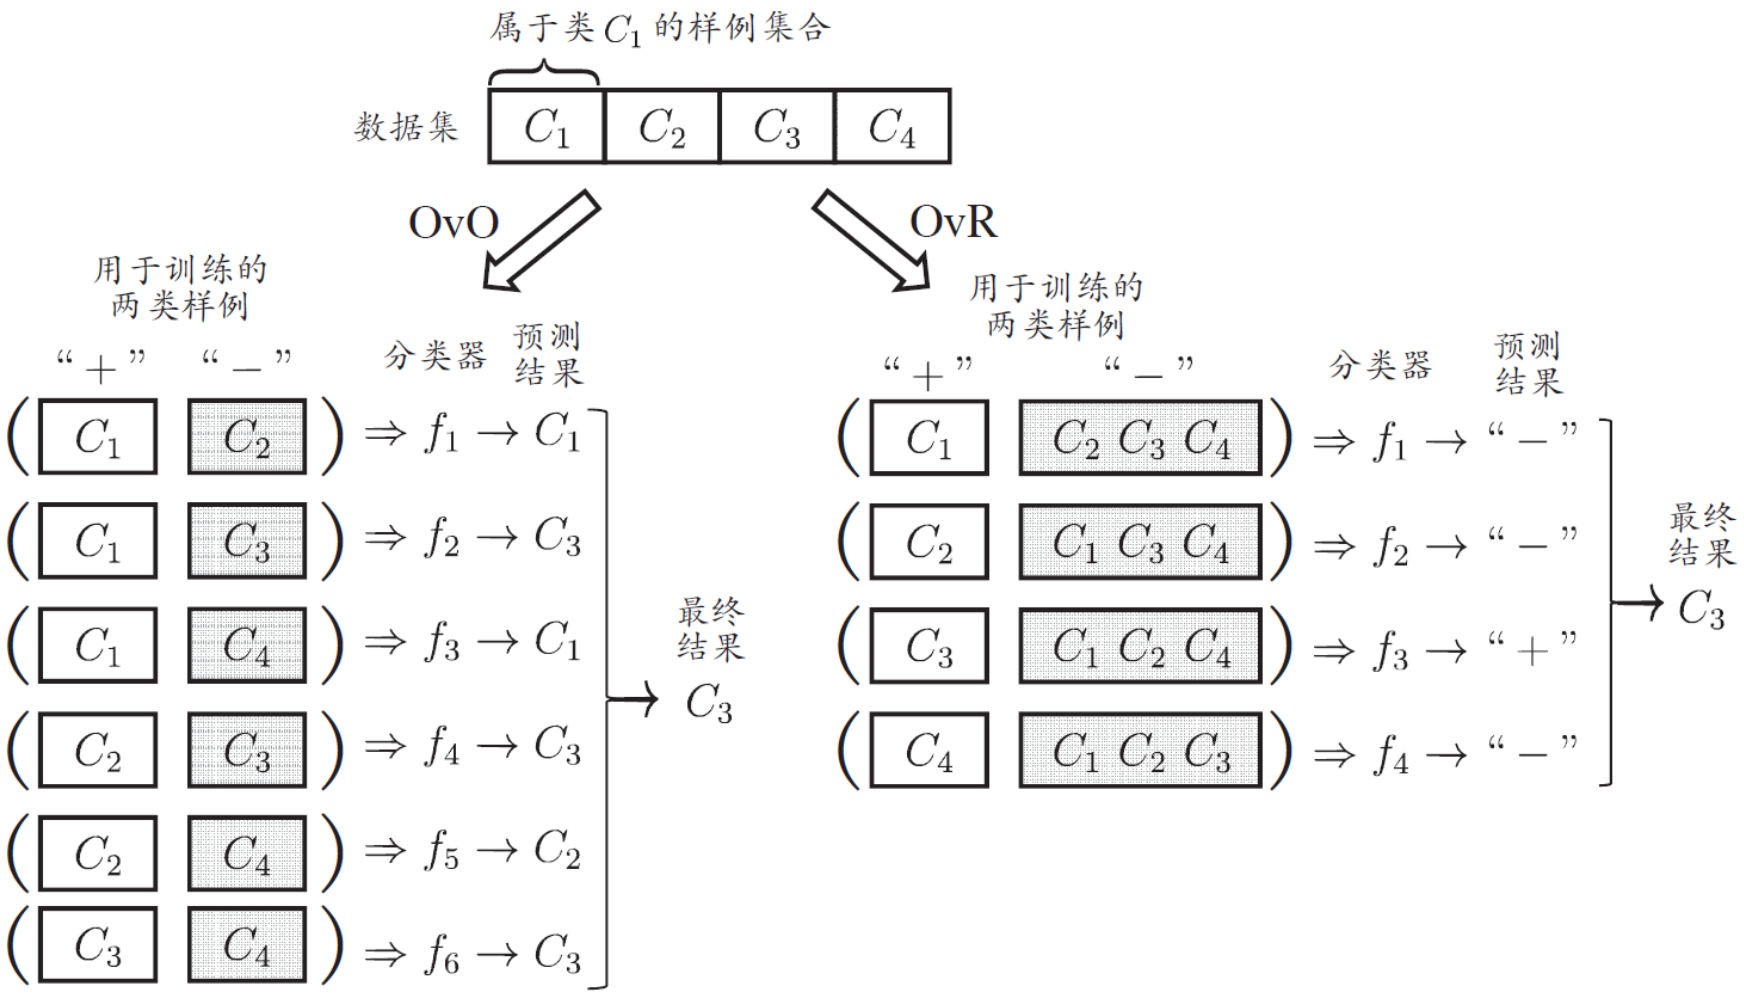

一对一　　一对其余

总结：优化提要

- 各任务下（回归、分类）各个模型优化的目标
  - 最小二乘法：最小化均方误差
  - 对数几率回归：最大化样本分布似然
  - 线性判别分析：投影空间内最小（大）化类内（间）散度

- 参数的优化方法
  - 最小二乘法：线性代数
  - 对数几率回归：凸优化梯度下降、牛顿法
  - 线性判别分析：矩阵论、广义瑞利商

第四章：决策树

思考

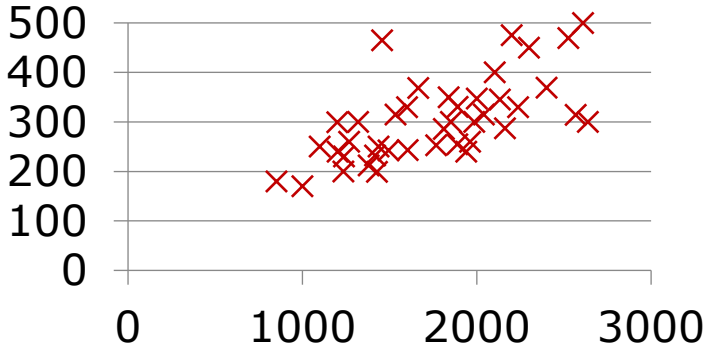
500
400
300
200
100
0
0
1000
2000
3000

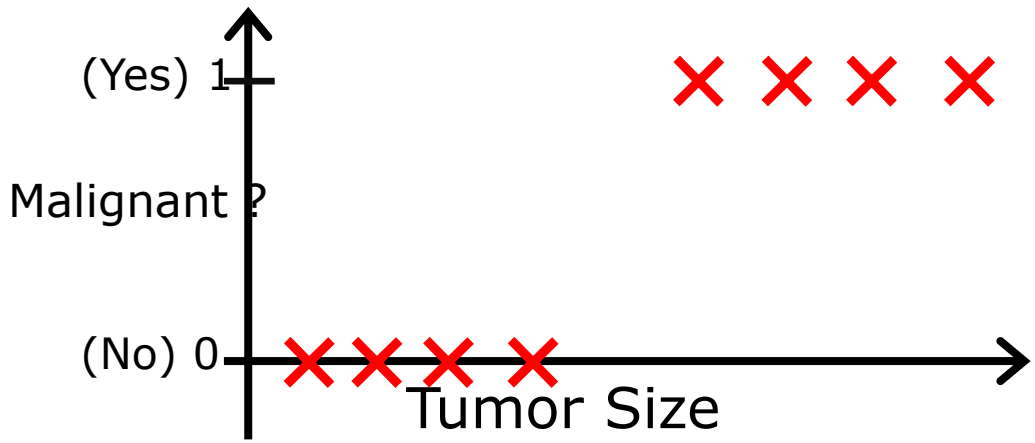
(Yes) 1
Malignant ?
(No) 0
Tumor Size

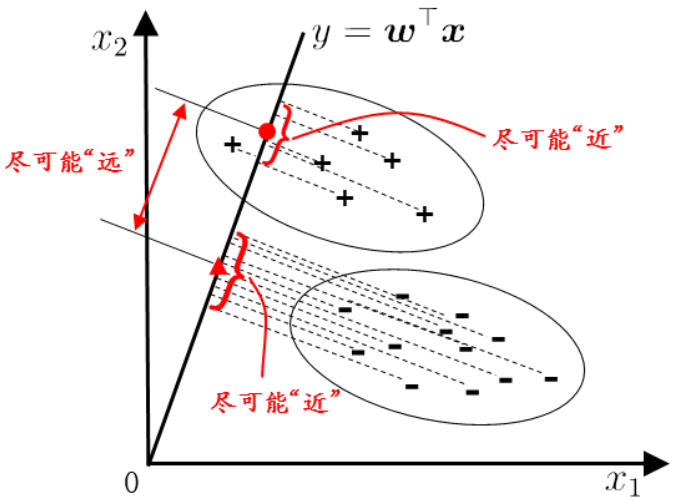
x_2
$y = \boldsymbol{w}^\top \boldsymbol{x}$
尽可能“远”
尽可能“近”
尽可能“近”
0
x_1

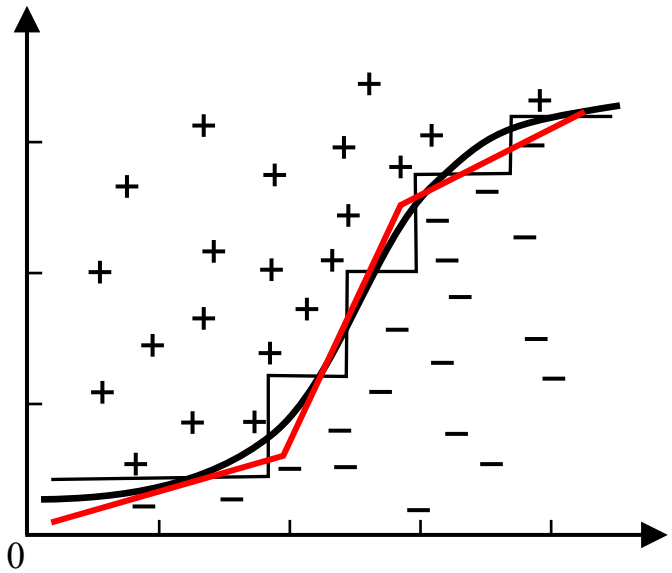
0

引例

约会

序号	星期几	约会方式	天气	晚间电视节目	是否答应约会
1	周末	吃饭	暖	不好看	否
2	周末	泡吧	暖	不好看	是
3	周末	泡吧	暖	不好看	是
4	周末	泡吧	冷	好看	否
5	周末	泡吧	冷	不好看	?

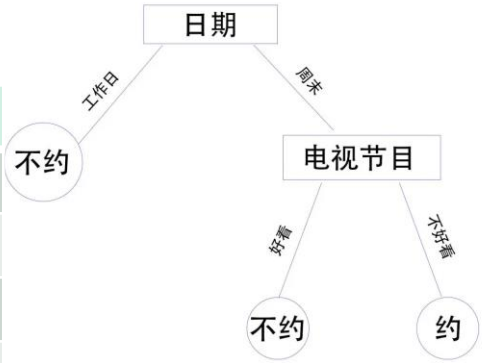

相亲

女儿：多大年纪了？ （年龄）
母亲：26。
女儿：长的帅不帅？ （长相）
母亲：挺帅的。
女儿：收入高不？ （收入情况）
母亲：不算很高，中等情况。
女儿：是公务员不？ （是否公务员）
母亲：是，在税务局上班呢。
女儿：那好，我去见见。

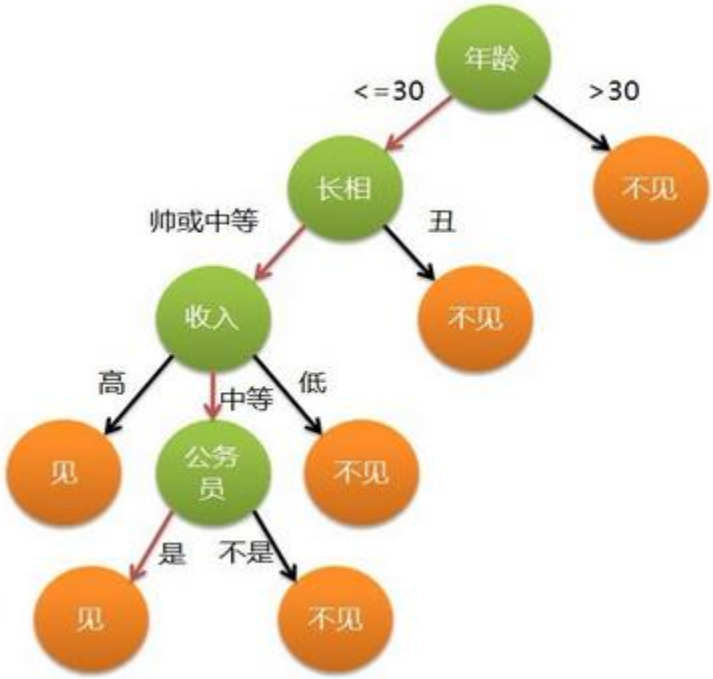

互动

- 总体思想？
  - 分类问题，选核心特征用来做分界判断；对各子树递归生成，最后得到合适的分类树
  - 核心：泛化能力强

4.1 基本算法

- 核心问题？
  - 每一次划分时，节点如何选择？划分后希望更纯？
  - 每个子树如何生成？何时停止？树太大了，怎么办？

4.2 划分选择：
信息增益、增益率、基尼指数

4.3 剪枝处理：
预剪枝、后剪枝

- 其他？
  - 连续值？有些属性值缺失？
  - 现有单属性无法划分好？

4.4 连续与缺失值
4.5 多变量决策树

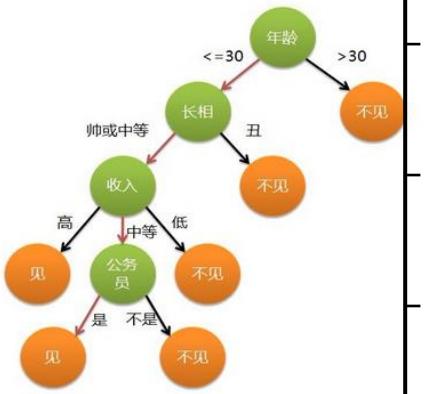

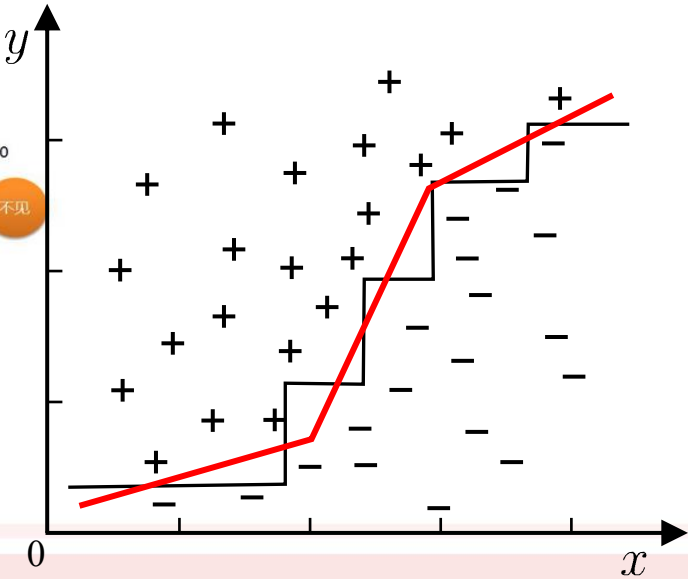

大纲

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值
- 多变量决策树

4.1 基本流程

□什么是决策树？

分类决策树模型是一种描述对实例进行分类的树形结构。决策树由结点和有向边组成。结点有两种类型：内部结点和叶节点。内部结点表示一个特征或属性，叶节点表示一个类。

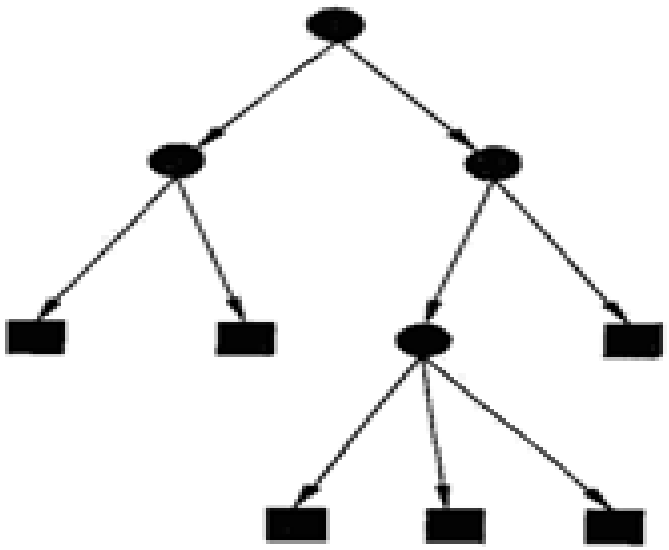

图 5.1　决策树模型

4.1 基本流程

决策树基于树结构来进行预测

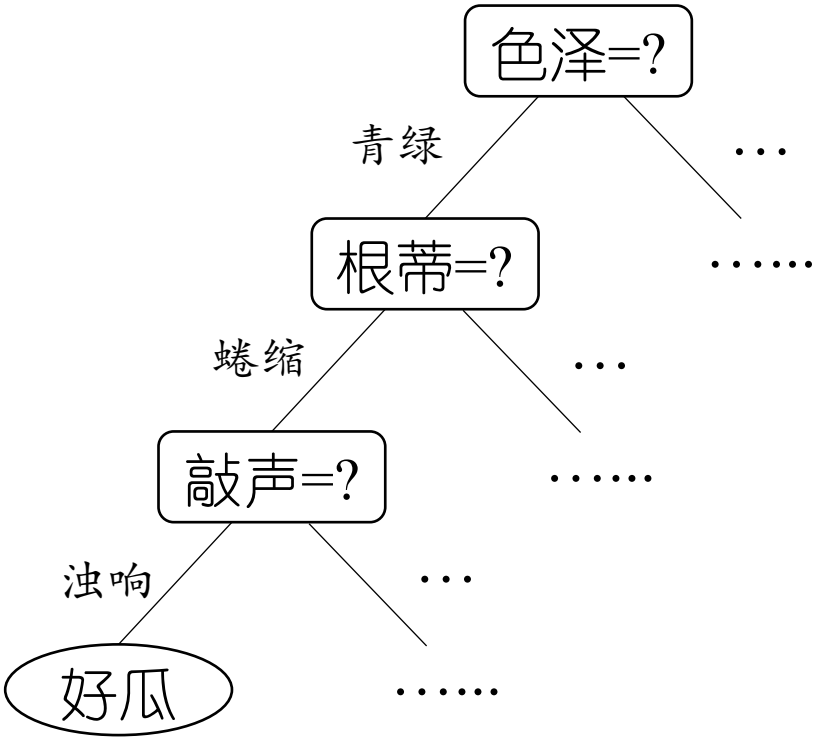

4.1 基本流程

- 决策过程中提出的每个判定问题都是对某个属性的“测试”
- 决策过程的最终结论对应了我们所希望的判定结果
- 每个测试的结果或是导出最终结论，或者导出进一步的判定问题，其考虑范围是在上次决策结果的限定范围之内
- 从根结点到每个叶结点的路径对应了一个判定测试序列

决策树学习的目的是为了产生一棵泛化能力强，
即处理未见示例能力强的决策树

4.1 基本流程

Algorithm 1 决策树学习基本算法

输入:

- 训练集 $D = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_m, y_m)\}$;
- 属性集 $A = \{a_1, \ldots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

```
生成结点 node;
if D 中样本全属于同一类别 C then
    将 node 标记为 C 类叶结点; return
end if
if A = ∅ OR D 中样本在 A 上取值相同 then
    将 node 标记叶结点，其类别标记为 D 中样本数最多的类; return
end if
从 A 中选择最优划分属性 a*;
for a* 的每一个值 a*^v do
    为 node 生成每一个分枝; 令 D_v 表示 D 中在 a* 上取值为 a*^v 的样本子集;
    if D_v 为空 then
        将分枝结点标记为叶结点, 其类别标记为 D 中样本最多的类; return
    else
        以 TreeGenerate(D_v, A − {a*}) 为分枝结点
    end if
end for
```

输出: 以 node 为根结点的一棵决策树

（1）当前结点包含的样本全部属于同一类别

（2）当前属性集为空，或所有样本在所有属性上取值相同

（3）当前结点包含的样本集合为空

4.1 基本流程

（1）当前结点包含的样本全部属于同一类别C

无需划分，叶子节点标记为类别C

（2）当前属性集为空，或所有样本在所有属性上取值相同

当前结点标记为叶子节点，类别=该结点所含样本最多的类别

（3）当前结点包含的样本集合为空

当前结点标记为叶子节点，类别=该结点的父节点所含样本最多的类别

大纲

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值
- 多变量决策树

4.2 划分选择

- 决策树学习的关键在于如何选择最优划分属性。一般而言，随着划分过程不断进行，我们希望决策树的分支结点所包含的样本尽可能属于同一类别，即结点的“纯度”(purity)越来越高

- 经典的属性划分方法：
  - 信息增益： ID3
  - 增益率：C4.5
  - 基尼指数：CART

4.2 划分选择

“决策树的分支结点所包含的样本尽可能属于同一类别”

这句话可以这样理解：“最优划分属性”就是那个能把当前数据分得最开的属性。我们希望划分之后，每个分支里的样本阵营越统一越好。因为只有这样，后续的预测才能越简单、越准确，最终形成一棵泛化能力强、结构简洁的决策树。”

在信息论中，混乱程度用“熵”来衡量。如果一堆样本全是好瓜，熵为0，非常确定。如果好瓜坏瓜各一半，熵最大，最不确定。

•我们的目标是从根结点（不确定性较大）开始，通过划分，让每个分支结点的不确定性（熵）尽可能降低。

•**信息增益**这个概念，衡量的就是“不确定性减少了多少”。我们选择的属性，应该是那个能让混乱程度下降得最快的属性。

4.2.1 信息增益

- “信息熵”是度量样本集合纯度最常用的一种指标，假定当前样本集合D中第k类样本所占的比例为$p_k\,(K=1,2,\ldots,|\mathcal{Y}|)$，则$D$的信息熵定义为

$$\mathrm{Ent}(D)=-\sum_{k=1}^{|\mathcal{Y}|}p_k\log_2 p_k$$

  $\mathrm{Ent}(D)$的值越小，则D的纯度越高

- 计算信息熵时约定：若 $p=0$，则$p\log_2 p=0$
- $\mathrm{Ent}(D)$的最小值为0，最大值为$\log_2|\mathcal{Y}|$

4.2.1 信息增益

- 当随机变量只有两个值，例如1,0时，即X的分布为

P(X=1)=p，P(X=0)=1-p，0<=p<=1.

则熵$H(p) = -plog_2p - (1-p)log_2(1-p)$

- 熵H(p)随概率p变化的曲线如右图：

- 可知，当p=0或p=1时，H(p)=0，随机变量完全没有不确定性。

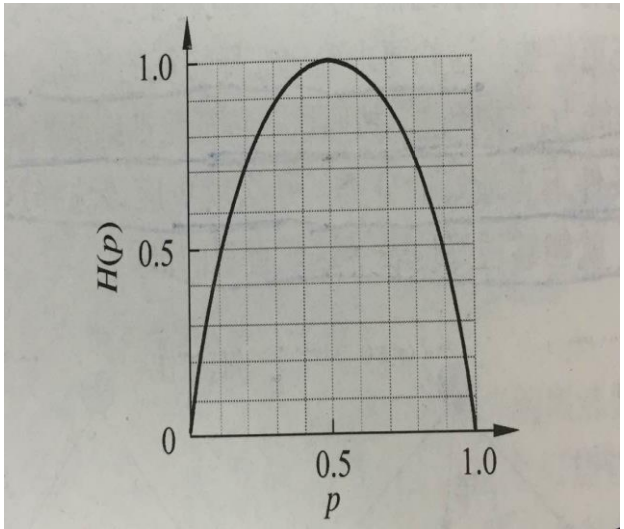

图 5.4 分布为贝努利分布时熵与概率的关系

4.2.1 信息增益

- 离散属性a有V个可能的取值$\{a^1, a^2, \ldots, a^V\}$，用$a$来进行划分，则会产生$V$个分支结点，其中第$v$个分支结点包含了$D$中所有在属性$a$上取值为$a^v$的样本，记为$D^v$。则可计算出用属性$a$对样本集$D$进行划分所获得的“信息增益”：

$$\mathrm{Gain}(D, a) = \mathrm{Ent}(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} \mathrm{Ent}(D^v)$$

为分支结点权重，样本数越多的分支结点的影响越大

- 一般而言，信息增益越大，则意味着使用属性a来进行划分所获得的“纯度提升”越大
- ID3（Iterative Dichotomiser，迭代二分器）决策树学习算法[Quinlan, 1986]以信息增益为准则来选择划分属性

4.2.1 信息增益

信息增益实例

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

该数据集包含17个训练样本，$|\mathcal{Y}|=2$，其中正例占 $p_1=\frac{8}{17}$，反例占 $p_2=\frac{9}{17}$，计算得到根结点的信息熵为

$$\mathrm{Ent}(D)=-\sum_{k=1}^{2}p_k\log_2 p_k=-\left(\frac{8}{17}\log_2\frac{8}{17}+\frac{9}{17}\log_2\frac{9}{17}\right)=0.998$$

4.2.1 信息增益

- 以属性“色泽”为例，其对应的3个数据子集分别为 D^1(色泽=青绿)，D^2(色泽=乌黑)，D^3 (色泽=浅白)
- 子集 D^1 包含编号为$\{1, 4, 6, 10, 13, 17\}$的6个样例，其中正例占 $p_1 = \frac{3}{6}$ ，反例占 $p_2 = \frac{3}{6}$ ，D^2、D^3 同理，3个结点的信息熵为：

$$\mathrm{Ent}(D^1) = -\left(\frac{3}{6}\log_2\frac{3}{6} + \frac{3}{6}\log_2\frac{3}{6}\right) = 1.000$$

$$\mathrm{Ent}(D^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918$$

$$\mathrm{Ent}(D^3) = -\left(\frac{1}{5}\log_2\frac{1}{5} + \frac{4}{5}\log_2\frac{4}{5}\right) = 0.722$$

- 属性“色泽”的信息增益为

$$\begin{aligned}\mathrm{Gain}(D, \text{色泽}) &= \mathrm{Ent}(D) - \sum_{v=1}^{3}\frac{|D^v|}{|D|}\mathrm{Ent}(D^v) \\ &= 0.998 - \left(\frac{6}{17}\times 1.000 + \frac{6}{17}\times 0.918 + \frac{5}{17}\times 0.722\right) \\ &= 0.109\end{aligned}$$

4.2.1 信息增益

- 类似的，其他属性的信息增益为

$$\mathrm{Gain}(D, \text{根蒂}) = 0.143 \qquad \mathrm{Gain}(D, \text{敲声}) = 0.141$$

$$\mathrm{Gain}(D, \text{纹理}) = 0.381 \qquad \mathrm{Gain}(D, \text{脐部}) = 0.289$$

$$\mathrm{Gain}(D, \text{触感}) = 0.006$$

- 显然，属性“纹理”的信息增益最大，其被选为划分属性

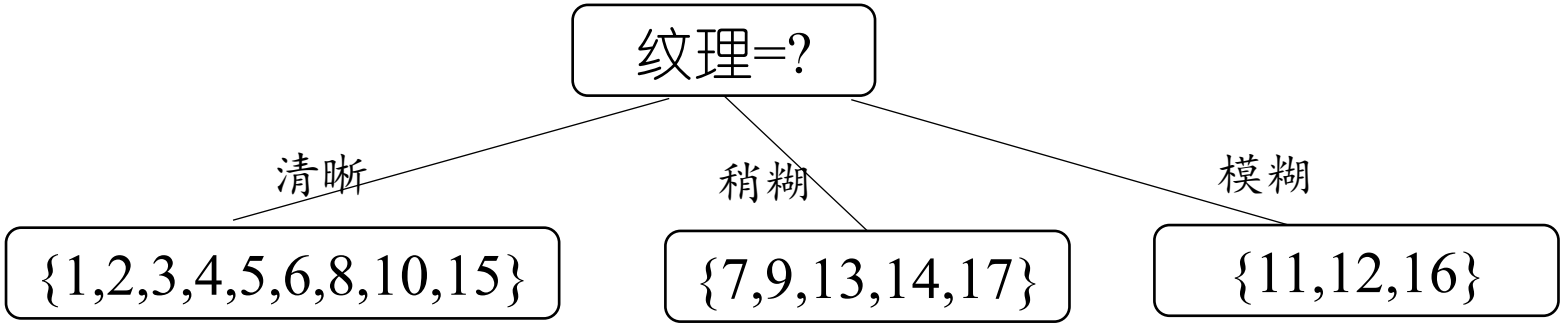

4.2.1 信息增益

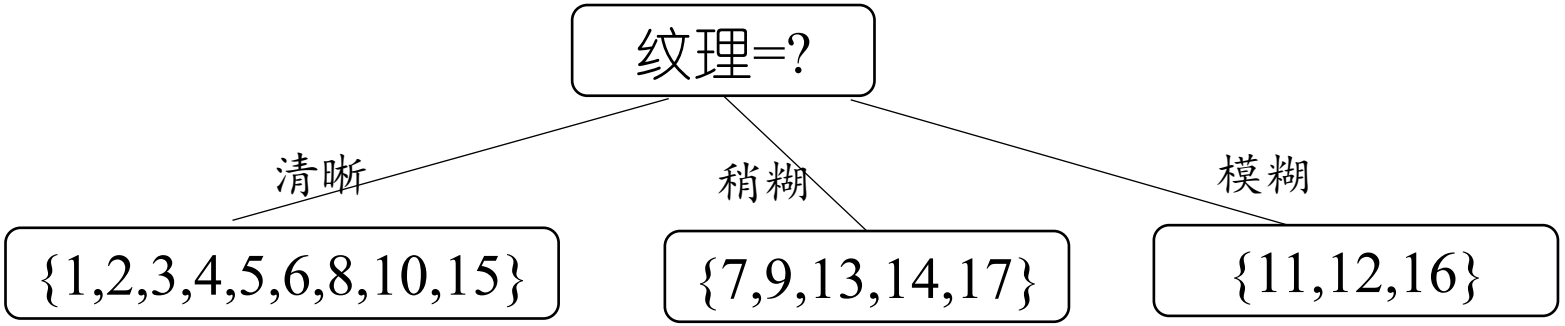

- 继续对每个分支进行划分，以第一个节点（纹理=清晰）为例：

$$\mathrm{Gain}(D^1, \text{色泽}) = 0.043; \quad \mathrm{Gain}(D^1, \text{根蒂}) = 0.458;$$

$$\mathrm{Gain}(D^1, \text{敲声}) = 0.331; \quad \mathrm{Gain}(D^1, \text{脐部}) = 0.458;$$

$$\mathrm{Gain}(D^1, \text{触感}) = 0.458.$$

- “根蒂”、“脐部”、“触感”3个属性均取得了最大信息增益，可以随机选一个。

4.2.1 信息增益

- 决策树学习算法将对每个分支结点做进一步划分，最终得到的决策树如图：

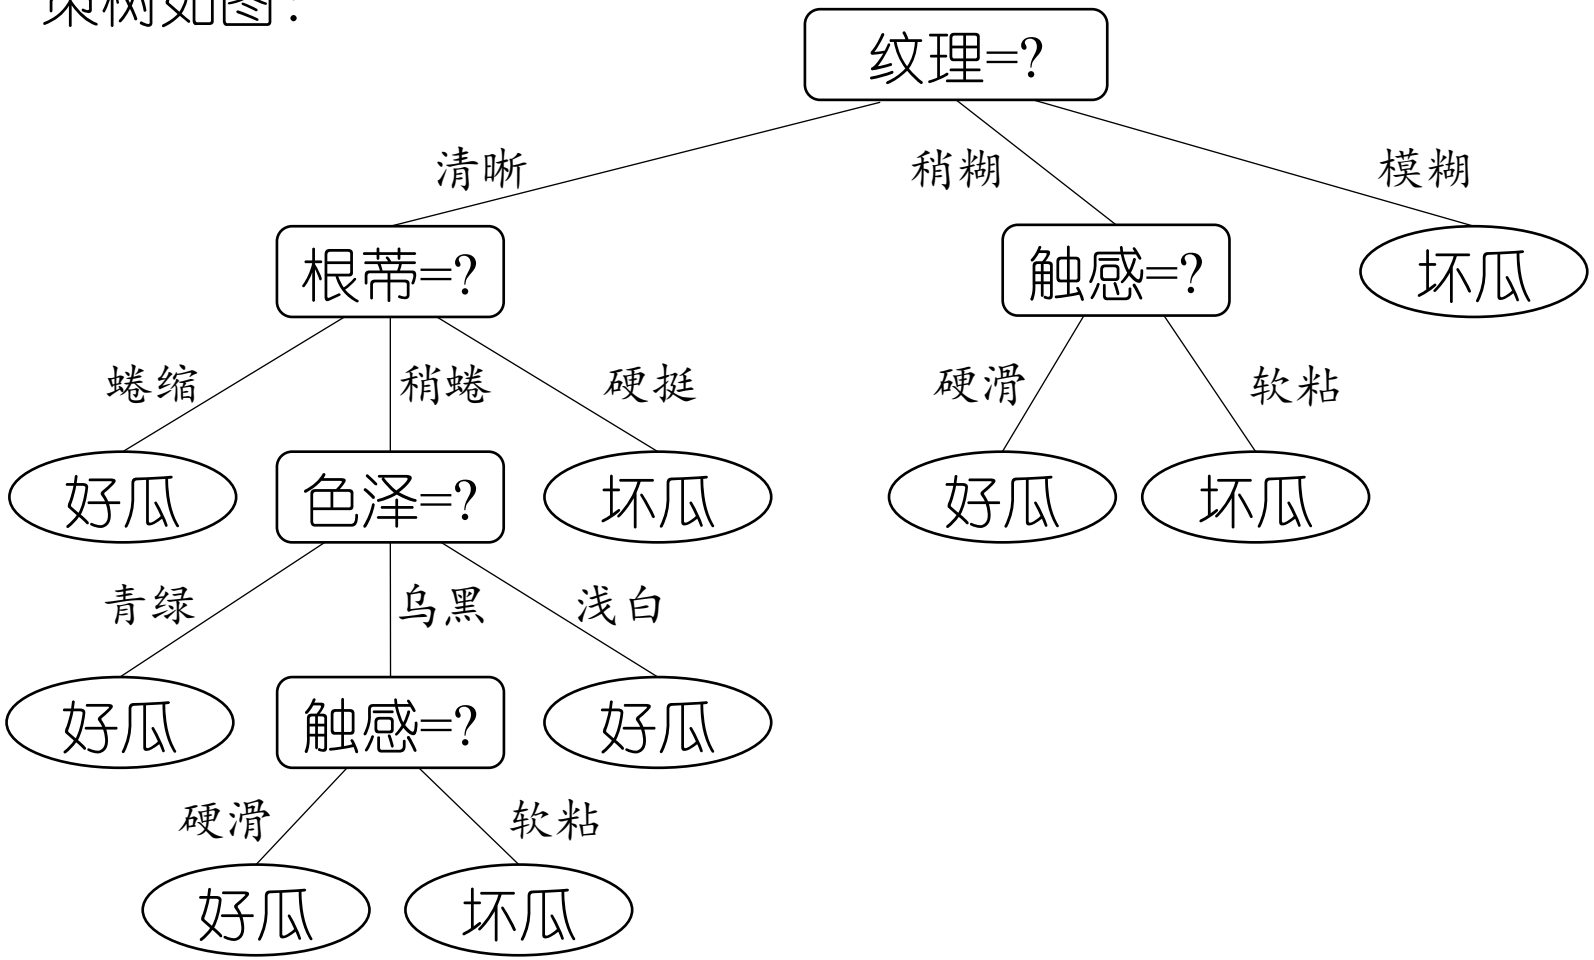

4.2.1 信息增益

存在的问题

- 若把“编号”也作为一个候选划分属性，则其信息增益一般远大于其他属性。显然，这样的决策树不具有泛化能力，无法对新样本进行有效预测
- 4.1中，每个“编号”的信息熵：

$$\mathrm{Ent}(D) = 17 * \left(-\left(\frac{1}{1}\log_2 1 + \frac{0}{0}\log_2 0 \right) \right) = 0$$

- 信息增益为：0.998-0=0.998

信息增益对可取值数目较多的属性有所偏好

4.2.2 增益率

- 增益率定义：

$$\text{Gain_ratio}(D,a)=\frac{\text{Gain}(D,a)}{\text{IV}(a)}$$

其中

$$\text{IV}(a)=-\sum_{v=1}^{V}\frac{|D^v|}{|D|}\log_2\frac{|D^v|}{|D|}$$

称为属性a的“固有值” [Quinlan, 1993]，属性a的可能取值数目越多（即V越大），则 $\text{IV}(a)$的值通常就越大

4.2.2 增益率

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

如何计算IV（触感）？

触感：{硬滑，软粘}

D1=硬滑：{1,2,3,4,5,8,9,11,13,14,16,17} 12个

D2=软粘：{6,7,10,12,15} 5个

$$IV(\text{触感},v=2) = -\Sigma_{i=1}^{2}\frac{|D^1|}{|D|}\log_2\frac{|D^1|}{|D|}$$

$$=-(\frac{12}{17}\log_2\frac{12}{17}+\frac{5}{17}\log_2\frac{5}{17}) = 0.874$$

同理：IV(色泽,v=3) = 1.580

IV(编号,v=17) = 4.008

增益率准则对可取值数目较少的属性有所偏好

- C4.5 [Quinlan, 1993]使用了一个启发式：先从候选划分属性中找出信息增益高于平均水平的属性，再从中选取增益率最高的

4.2.3 基尼指数

定义：分类问题中，假设有K个类，样本点属于第k类的概率为p_k,则概率分布的基尼值定义为：

$$Gini(p) = \sum_{k=1}^{K} p_k(1-p_k) = 1 - \sum_{k=1}^{K} p_k^2$$

反映了随机抽取两个样本，其类别标记不一致的概率

Gini(D)越小，数据集D的纯度越高；

给定数据集D，属性a的基尼指数定义为：

$$Gini_{index}(D,a) = \Sigma_{v=1}^{V} \frac{|D^v|}{|D|} Gini(D^v)$$

在候选属性集合A中，选择那个使得划分后基尼指数最小的属性作为最优划分属性。

4.2.3 基尼指数

例1：

比如体温为恒温时包含哺乳类5个，鸟类2个：

$$Gini = 1 - [\left(\frac{5}{7}\right)^2 + \left(\frac{2}{7}\right)^2] = \frac{20}{49}$$

体温为非恒温时包含爬行类3个、鱼类3个、两栖类2个，则

$$Gini = 1 - \left[\left(\frac{3}{8}\right)^2 + \left(\frac{3}{8}\right)^2 + \left(\frac{2}{8}\right)^2\right] = \frac{42}{64}$$

Gini： $Gini_{\text{index}} = \frac{7}{15} \times \frac{20}{49} + \frac{8}{15} \times \frac{42}{64}$

$$Gini(p) = \sum_{k=1}^{K} p_k(1 - p_k) = 1 - \sum_{k=1}^{K} p_k^2$$

$$Gini_{index}(D, a) = \Sigma_{v=1}^{V} \frac{|D^v|}{|D|} Gini(D^v)$$

4.2.3 基尼指数

例2：求(age=youth)的基尼指数？

ID	age	work	house	credit	class
1	youth	no	no	common	refuse
2	youth	no	no	good	refuse
3	youth	yes	no	good	agree
4	youth	yes	yes	common	agree
5	youth	no	no	common	refuse
6	mid	no	no	common	refuse
7	mid	no	no	good	refuse
8	mid	yes	yes	good	agree
9	mid	no	yes	excellent	agree
10	mid	no	yes	excellent	agree
11	elder	no	yes	excellent	agree
12	elder	no	yes	good	agree
13	elder	yes	no	good	agree
14	elder	yes	no	excellent	agree
15	elder	no	no	common	refuse

1.总样本数|D|=15;
2.age=youth时:
总样本数:5;
refuse:3;
agree:2

$$gini_1 = 1 - \left(\left(\frac{3}{5}\right)^2 + \left(\frac{2}{5}\right)^2\right)$$

3.age!=youth时:
总样本数:10;
refuse:3;
agree:7

$$gini_1 = 1 - \left(\left(\frac{3}{10}\right)^2 + \left(\frac{7}{10}\right)^2\right)$$

4.基尼指数:

$$gini = \frac{5}{15} * gini1 + \frac{10}{15} * gini2$$

大纲

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值
- 多变量决策树

4.3 剪枝处理

- 为什么剪枝
  - “剪枝”是决策树学习算法对付“过拟合”的主要手段
  - 可通过“剪枝”来一定程度避免因决策分支过多，以致于把训练集自身的一些特点当做所有数据都具有的一般性质而导致的过拟合

- 剪枝的基本策略
  - 预剪枝
  - 后剪枝

- 判断决策树泛化性能是否提升的方法
  - 留出法：预留一部分数据用作“验证集”以进行性能评估

4.3 剪枝处理

举例：判断“今天是否适合打球”

样本	天气	湿度	是否打球
1	晴	高	否
2	晴	中	是
3	阴	高	是
4	阴	中	是
5	雨	高	否
6	雨	中	否
7	晴	低	是

剪枝前的决策树

```
          天气=?
          /     \
        晴        阴/雨? ...
       /    \
湿度=高? 湿度=中?
  /          \
否(1)        是(2,7)? 这里为了区分2和7可能再分
           /        \
     湿度=中?     湿度=低?
       /            \
     是(2)          是(7)  (假设7是噪声)
```

不剪枝的树：为了记住训练数据中的每一个细节（包括噪声），它变得极其复杂，失去了对普遍规律的把握，从而产生**过拟合**。

剪枝后的决策树

```
    [天气]
    /     \
 晴          阴/雨...
  |           /     \
[是]       [是]    [否]
```

剪枝后的树：通过牺牲训练集上的一点点准确率，换来了在未知数据上更好的表现，**提高了泛化能力**。

4.3 剪枝处理

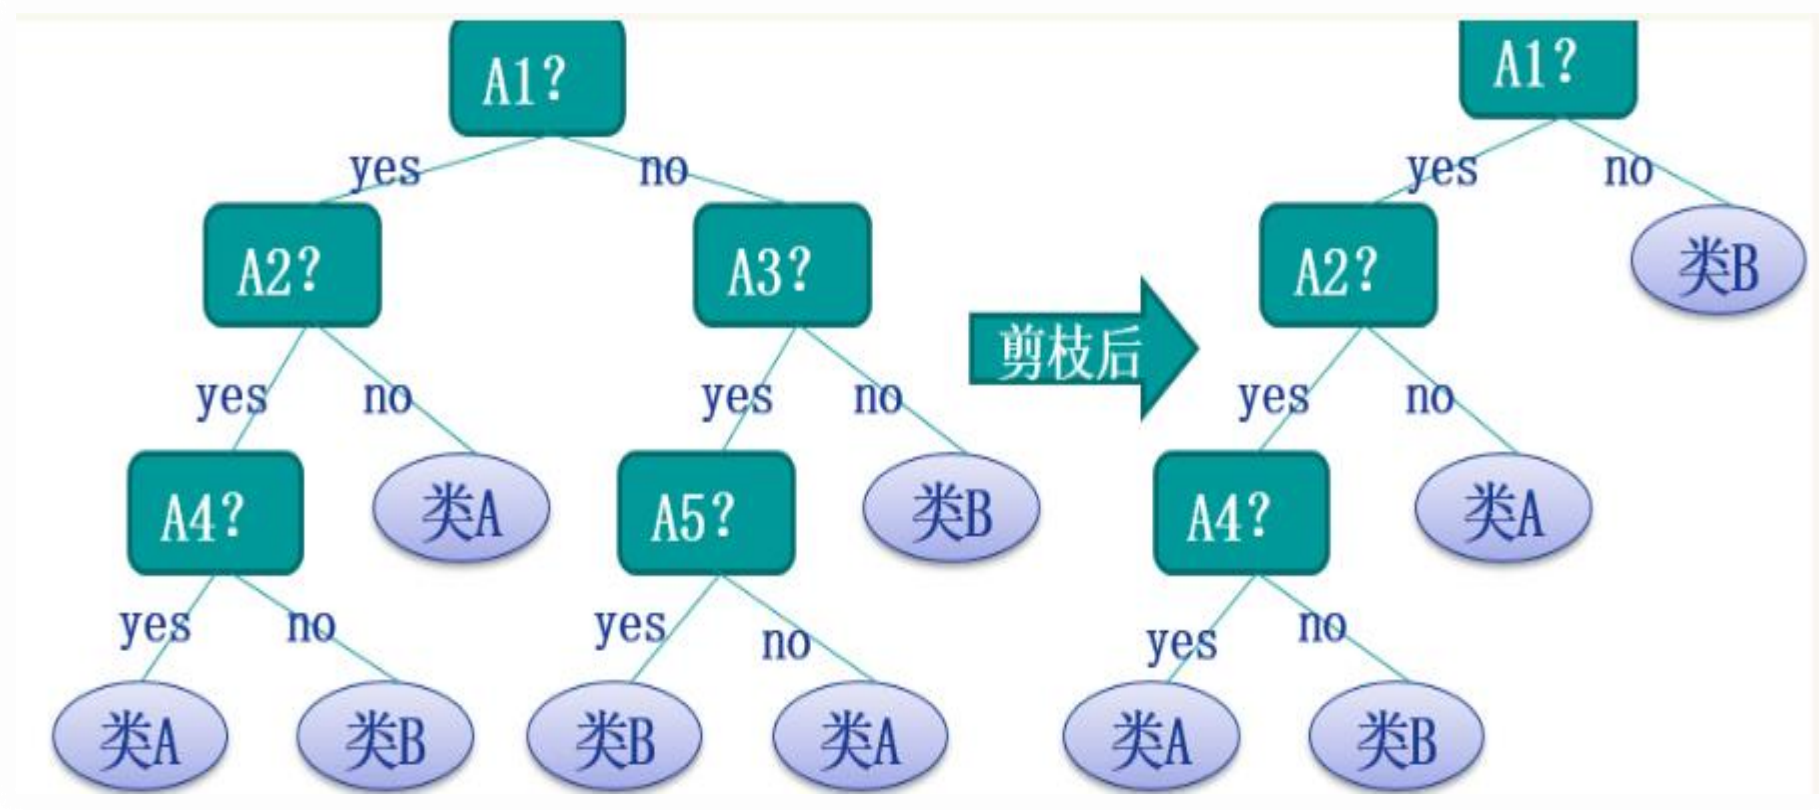

1.怎么剪？

2.剪枝后效果如何判断？ 预留一部分验证集

4.3.1 预剪枝

通过提前停止树的构建而对树剪枝，一旦停止，节点就是树叶。

停止决策树生长最简单的方法有：

1. 定义一个高度，当决策树达到该高度时就停止决策树的生长
2. 达到某个节点的实例具有相同的特征向量，即使这些实例不属于同一类，也可以停止决策树的生长。
3. 定义一个阈值，当达到某个节点的实例个数小于阈值时就可以停止决策树的生长。或定义一个阈值，通过计算每次扩张对系统性能的增益，并比较增益值与该阈值大小来决定是否停止决策树的生长。
   不足：阈值不好设置，过大决策树过于简单；过小，有多余树枝，过于茂盛。

4.3.1 预剪枝

数据集

训练集

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
10	青绿	硬挺	清脆	清晰	平坦	软粘	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	否

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

4.3.1 预剪枝

未剪枝决策树

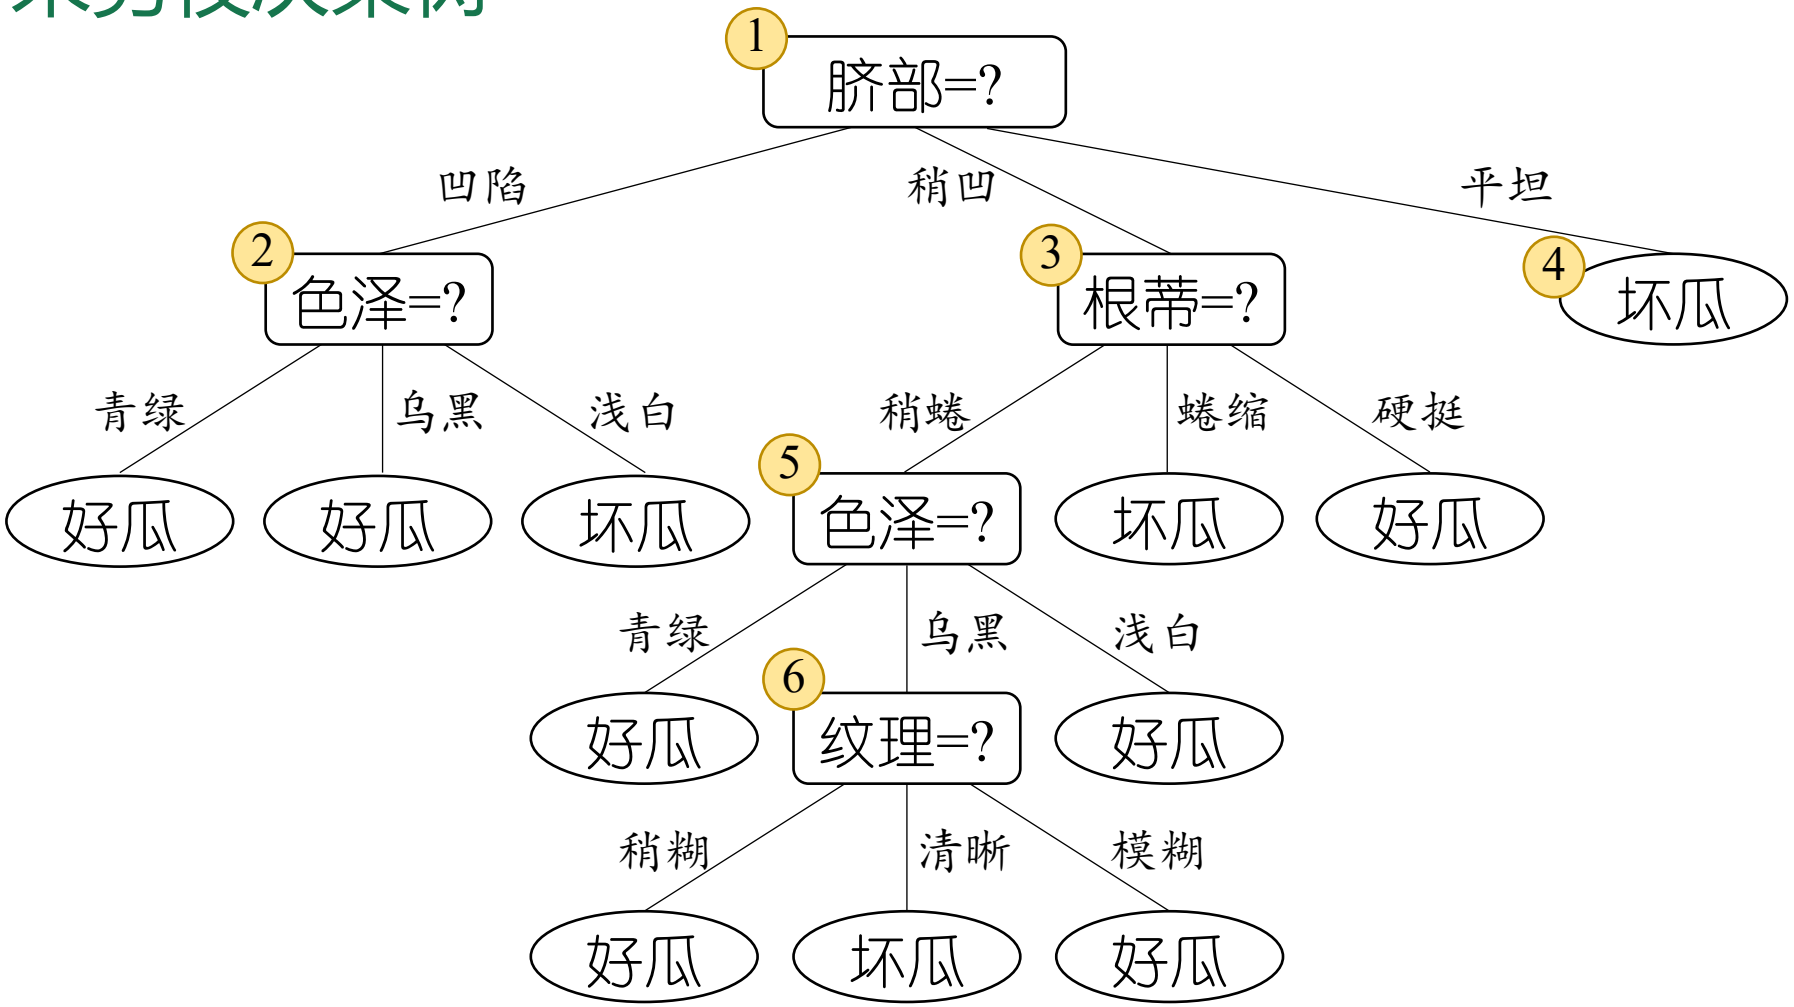

4.3.1 预剪枝

- 决策树生成过程中，对每个结点在划分前先进行估计，若当前结点的划分不能带来决策树泛化性能提升，则停止划分并将当前结点记为叶结点，其类别标记为训练样例数最多的类别

- 针对上述数据集，基于信息增益准则，选取属性“脐部”划分训练集。分别计算划分前（即直接将该结点作为叶结点）及划分后的验证集精度，判断是否需要划分。若划分后能提高验证集精度，则划分，对划分后的属性，执行同样判断；否则，不划分。

4.3.1 预剪枝

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1：若不划分，则将其标记为叶结点，类别标记为训练样例中最多的类别，即好瓜。验证集中，$\{4,5,8\}$被分类正确，得到验证集精度为$\frac{3}{7}\times 100\% = 42.9\%$

验证集精度

1 脐部=?

“脐部=?” 划分前: 42.9%

4.3.1 预剪枝

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点1：若划分，根据结点②，③，④的训练样例，将这3个结点分别标记为“好瓜”、“好瓜”、“坏瓜”。此时，验证集中编号为$\{4,5,8,11,12\}$的样例被划分正确，验证集精度为$\frac{5}{7}\times 100\% = 71.4\%$

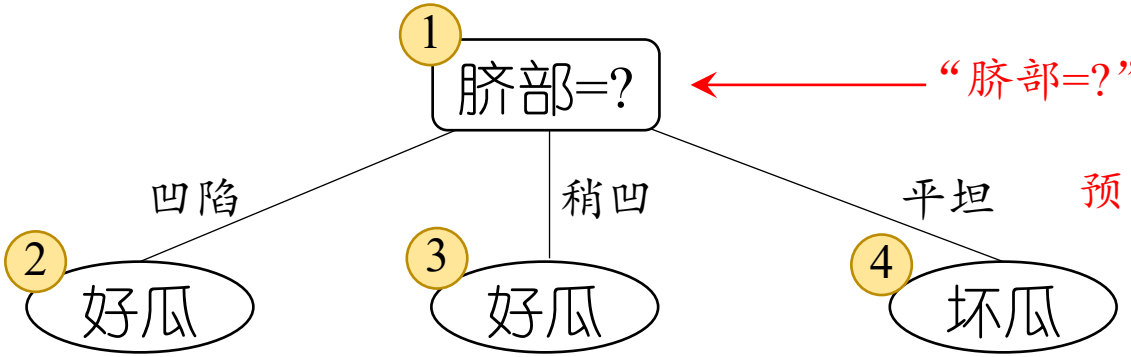

验证集精度

“脐部=?” 划分前: 42.9%

划分后: 71.4%

预剪枝决策: 划分

4.3.1 预剪枝

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

结点2：色泽继续划分，验证集中编号为{4,8,11,12} 的样例被划分正确，验证集精度为4/7*100% = 57.1%

验证集精度

划分前: 71.4%

划分后: 57.1%

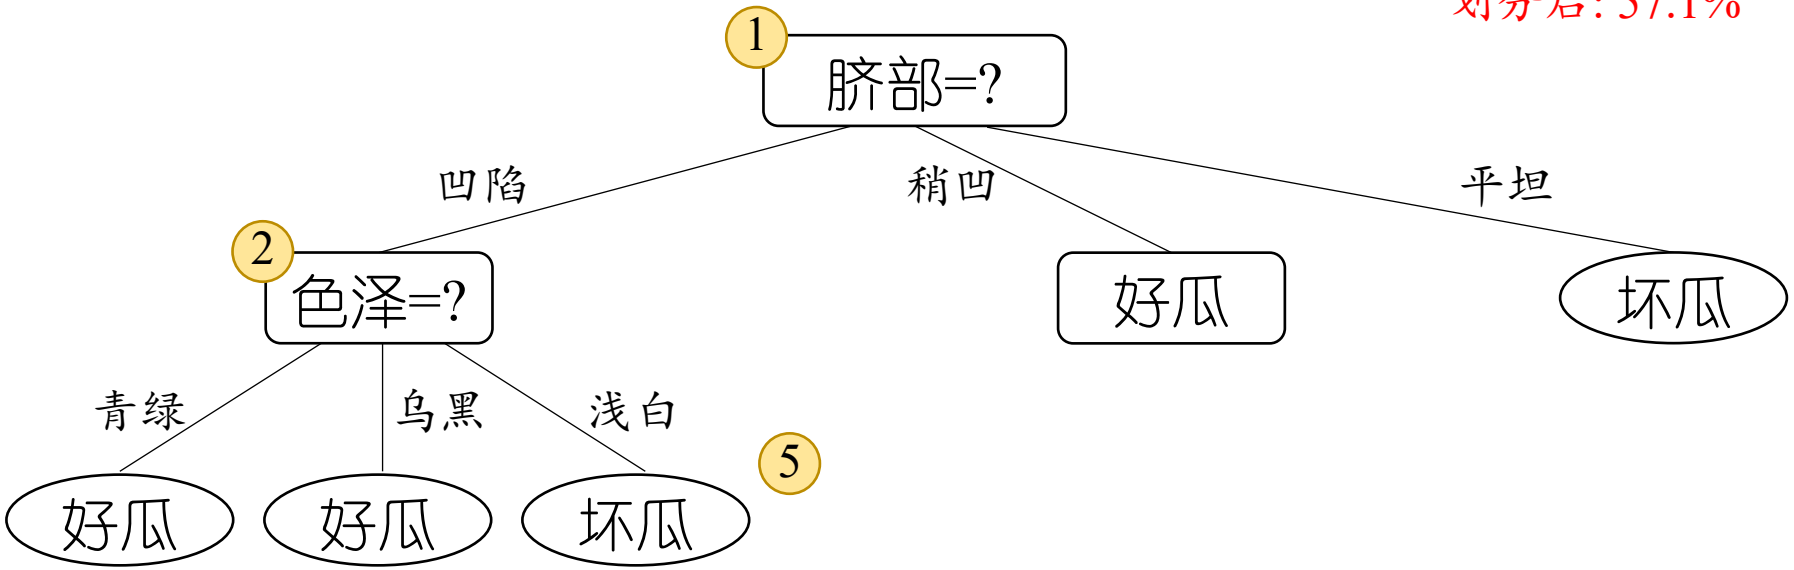

4.3.1 预剪枝

验证集

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

对结点2，3，4分别进行剪枝判断，结点2、3， 都禁止划分，结点4本身为叶子结点。最终得到仅有一层划分的决策树，称为**“决策树桩”**

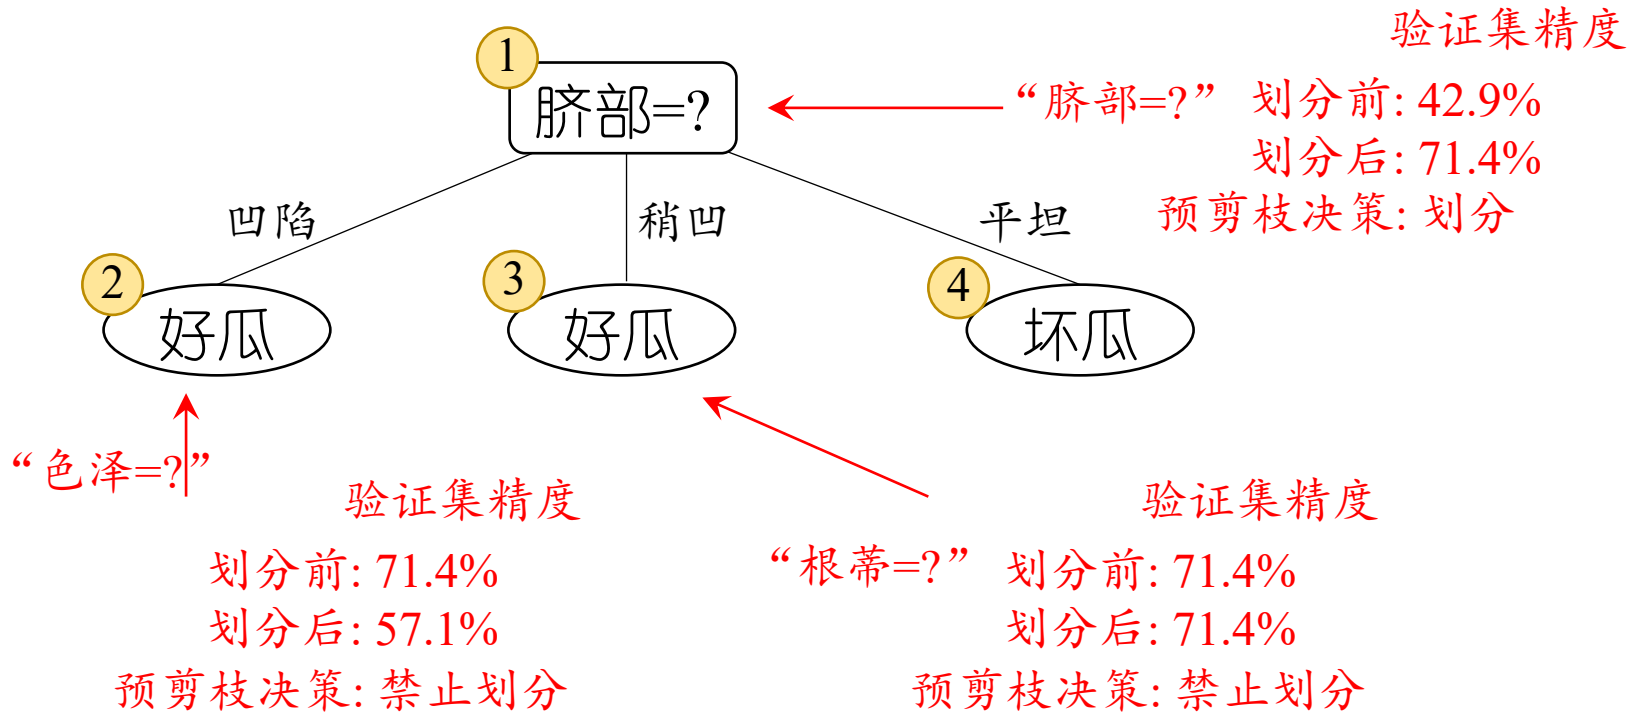

4.3.1 预剪枝

预剪枝的优缺点

- 优点
  - 降低过拟合风险
  - 显著减少训练时间和测试时间开销

- 缺点
  - 欠拟合风险：有些分支的当前划分虽然不能提升泛化性能，但在其基础上进行的后续划分却有可能导致性能显著提高。预剪枝基于“贪心”本质禁止这些分支展开，带来了欠拟合风险

4.3.2 后剪枝

- 先从训练集生成一棵完整的决策树，然后自底向上地对非叶结点进行考察，若将该结点对应的子树替换为叶结点能带来决策树泛化性能提升，则将该子树替换为叶结点

首先生成一棵完整的决策树，该决策树的验证集精度为42.9%

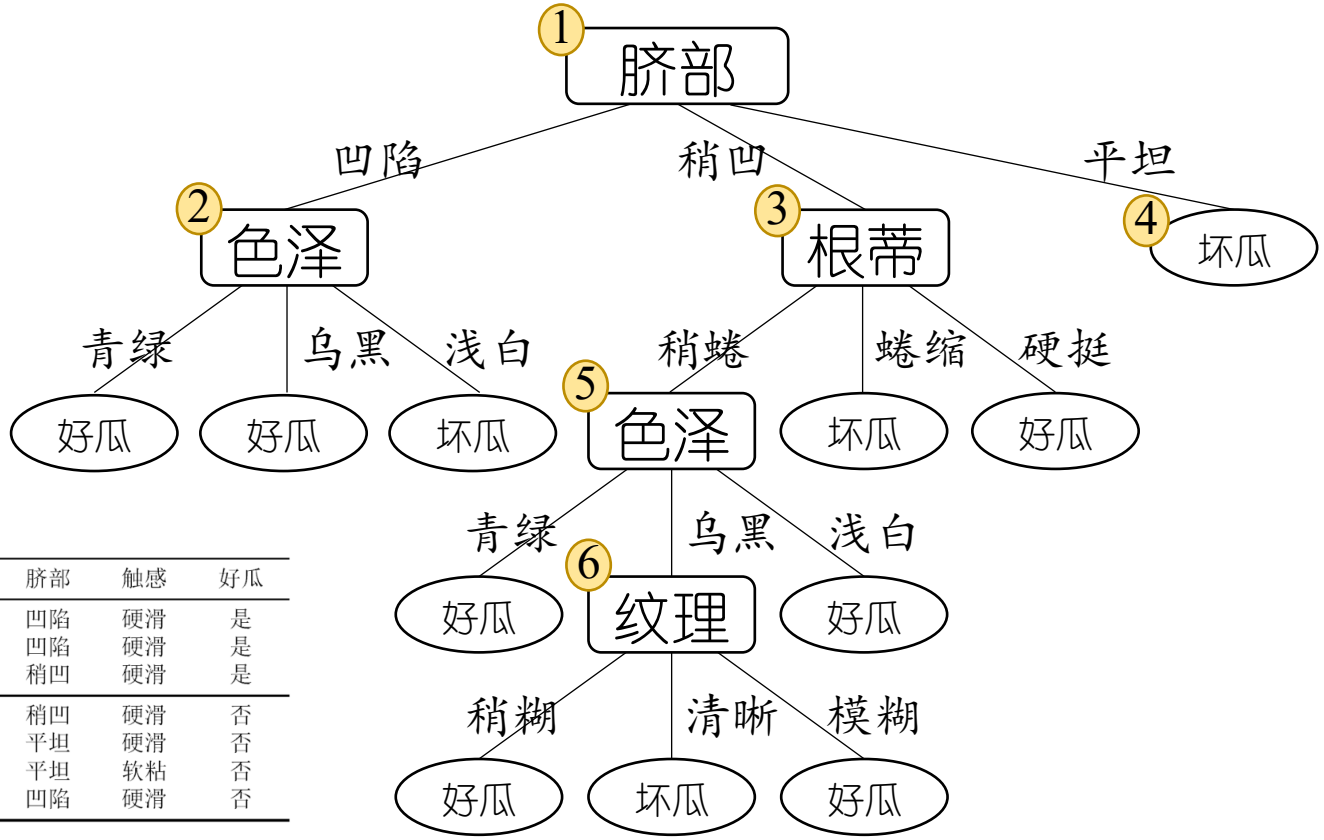

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

4.3.2 后剪枝

- 首先考虑结点⑥，若将其替换为叶结点，根据落在其上的训练样本{7, 15}将其标记为“好瓜”，得到验证集精度提高至57.1%，则决定剪枝

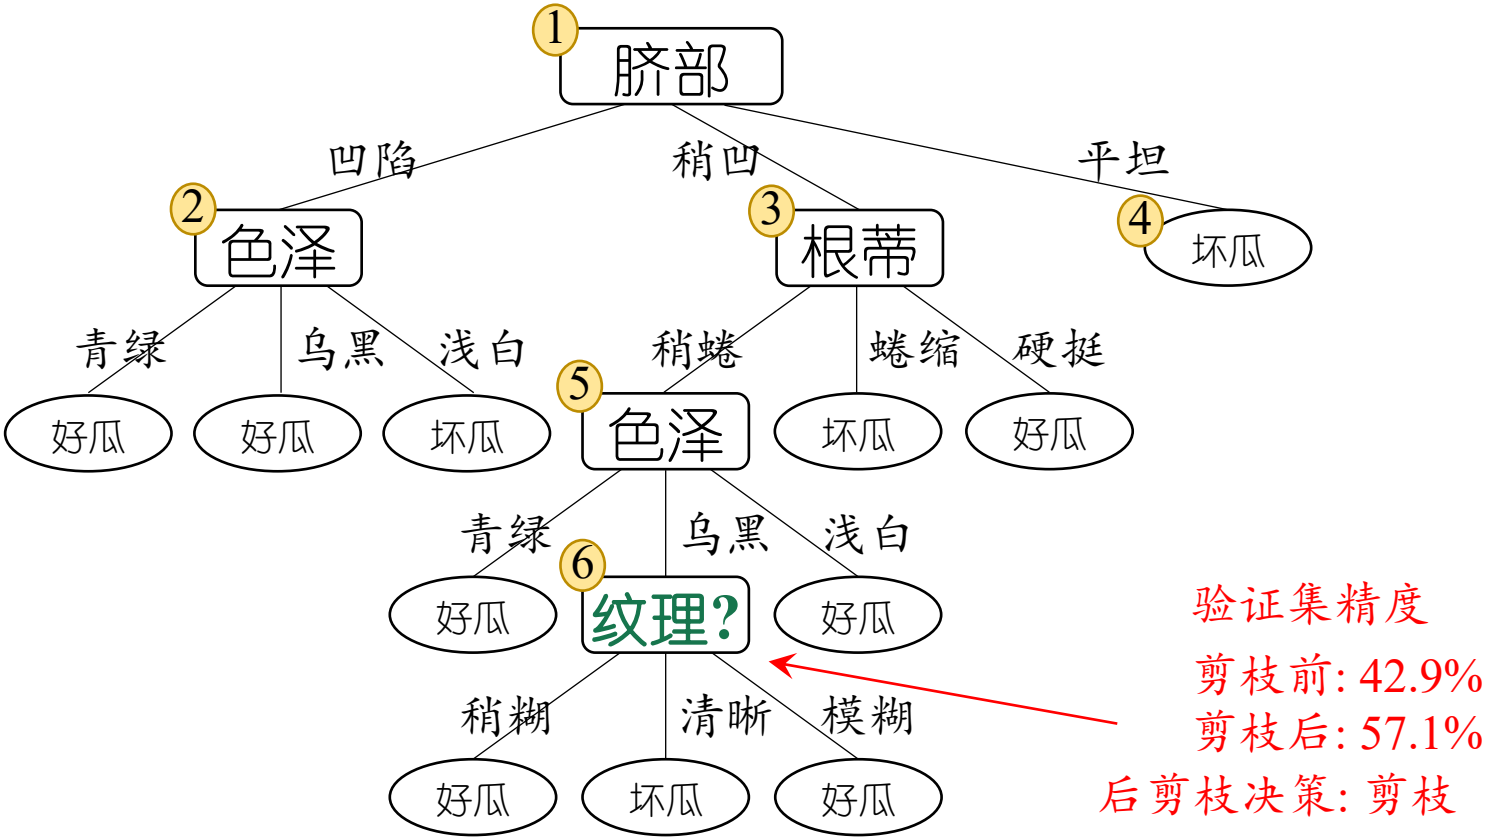

验证集精度

剪枝前: 42.9%

剪枝后: 57.1%

后剪枝决策: 剪枝

4.3.2 后剪枝

- 首先考虑结点⑥，若将其替换为叶结点，根据落在其上的训练样本{7, 15}将其标记为“好瓜”，得到验证集精度提高至57.1%，则决定剪枝

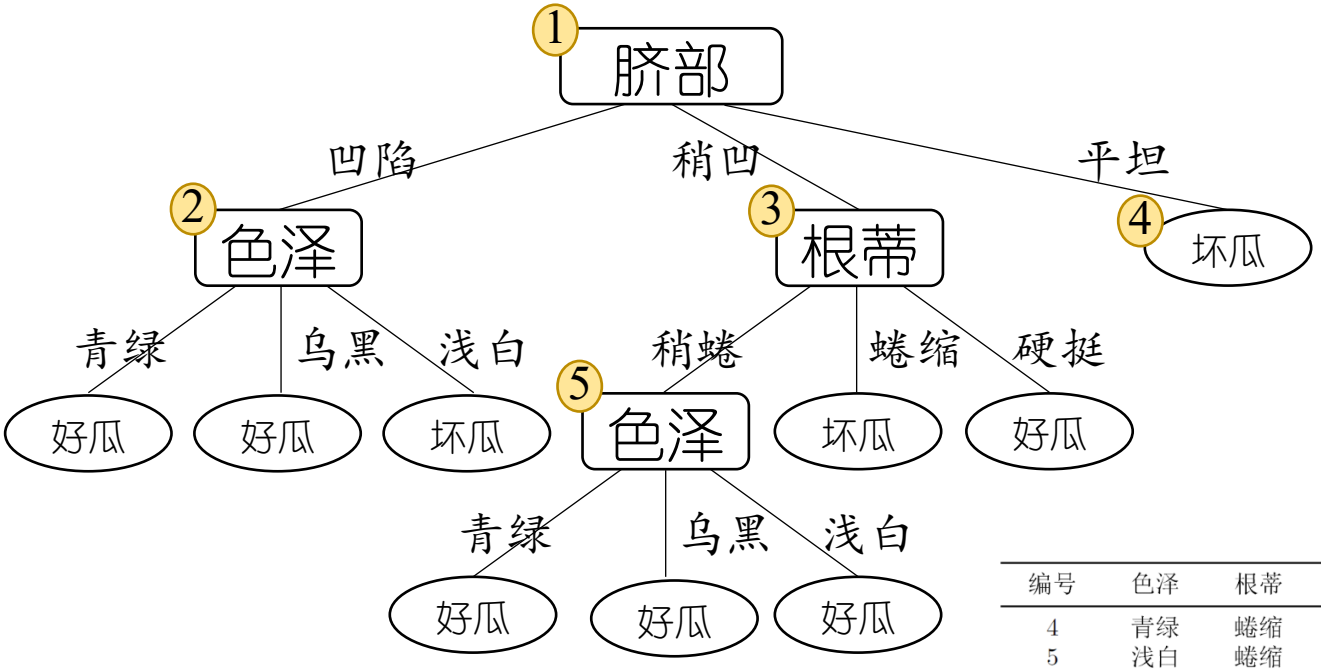

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	否

4.3.2 后剪枝

- 然后考虑结点⑤，若将其替换为叶结点，根据落在其上的训练样本$\{6,7,15\}$将其标记为“好瓜”，得到验证集精度仍为57.1%，可以不进行剪枝

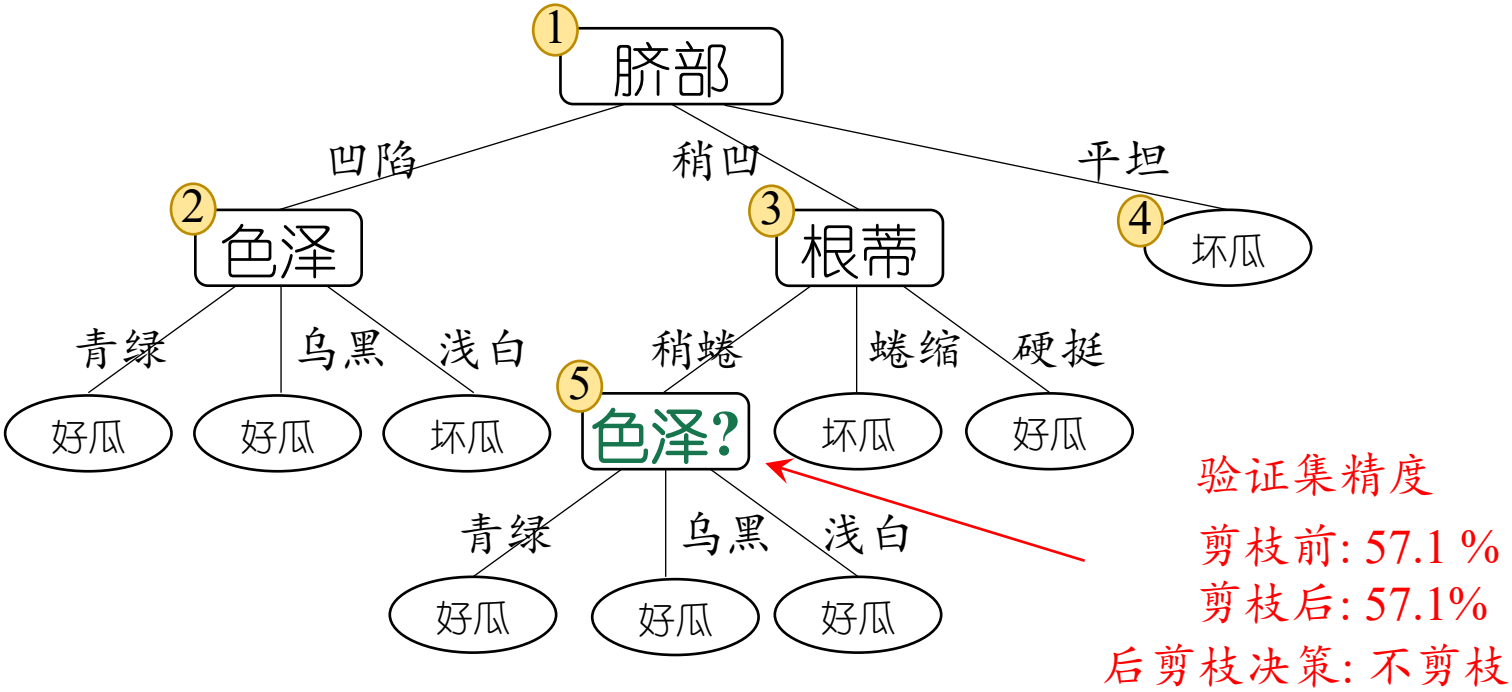

4.3.2 后剪枝

- 然后考虑结点⑤，若将其替换为叶结点，根据落在其上的训练样本$\{6,7,15\}$将其标记为“好瓜”，得到验证集精度仍为57.1%，可以不进行剪枝

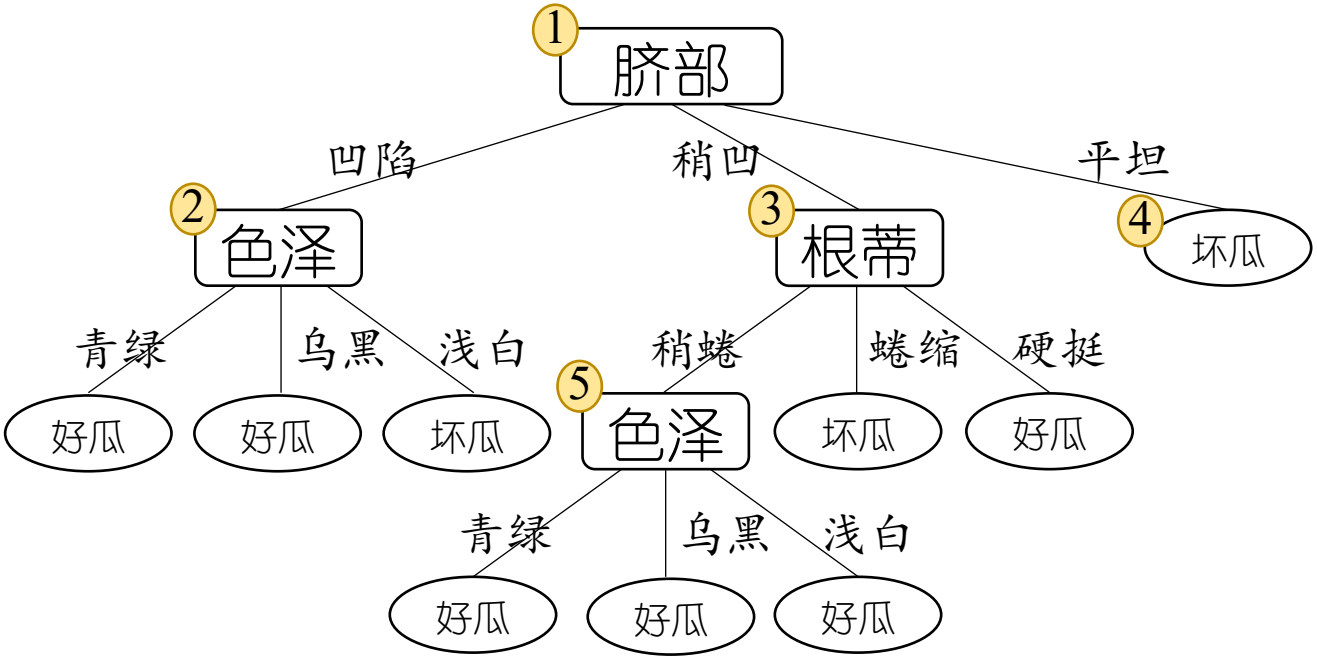

4.3.2 后剪枝

- 对结点②，若将其替换为叶结点，根据落在其上的训练样本$\{1,2,3,14\}$，将其标记为“好瓜”，得到验证集精度提升至71.4%，则决定剪枝

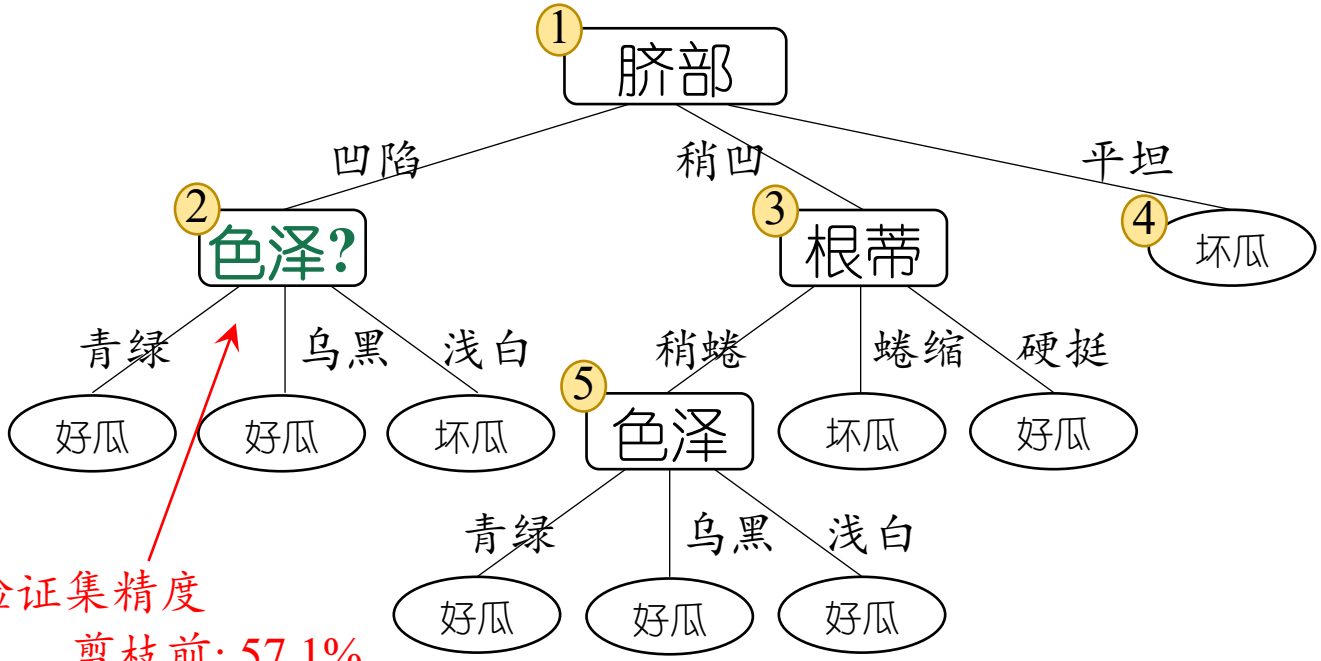

验证集精度

剪枝前: 57.1%

剪枝后: 71.4%

后剪枝决策: 剪枝

4.3.2 后剪枝

- 对结点③和①，先后替换为叶结点，验证集精度均未提升，则分支得到保留

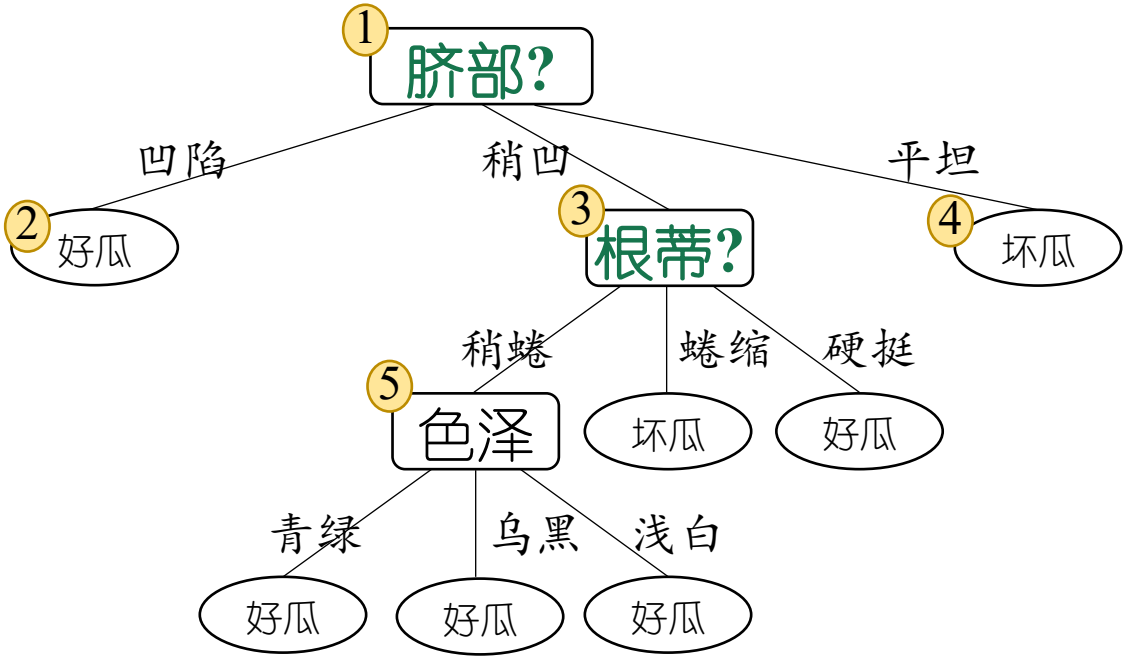

4.3.2 后剪枝

- 最终基于后剪枝策略得到的决策树如图所示

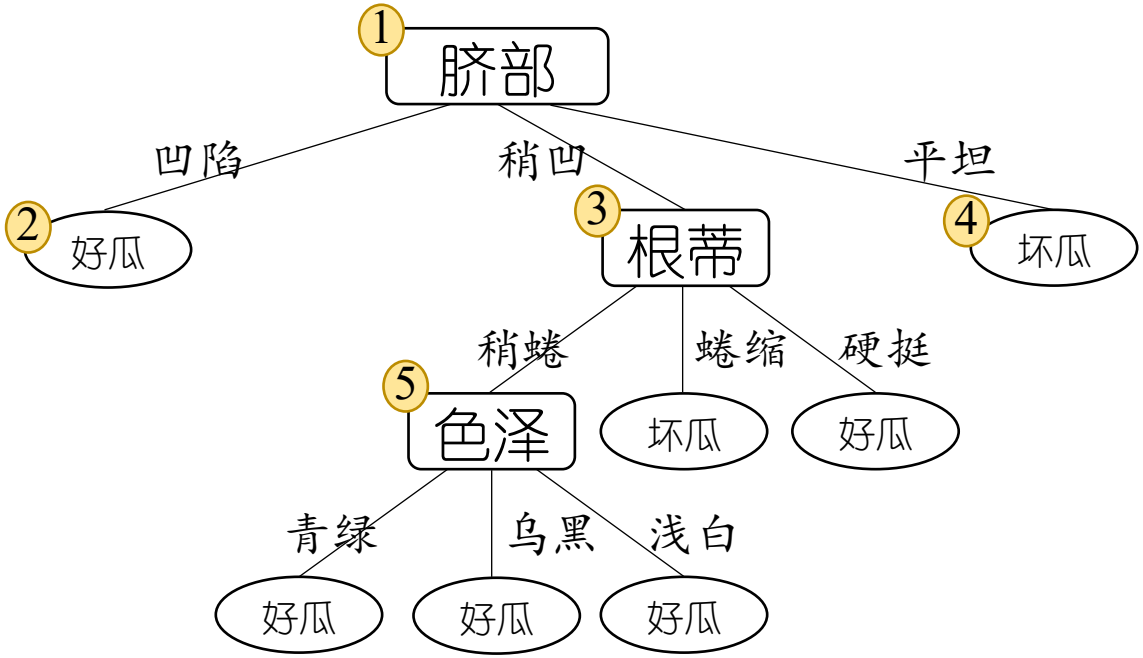

4.3.2 后剪枝

后剪枝的优缺点

- 优点
  - 后剪枝比预剪枝保留了更多的分支，欠拟合风险小，泛化性能往往优于预剪枝决策树
- 缺点
  - 训练时间开销大：后剪枝过程是在生成完全决策树之后进行的，需要自底向上对所有非叶结点逐一考察

大纲

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值
- 多变量决策树

4.4.1 连续与缺失值 – 连续值处理

- 连续属性取值数目不再有限，不能直接进行划分；

- 离散化(二分法)
  - 第一步：假定连续属性a在样本集D上出现n个不同的取值，从小到大排列，记为 $a^1, a^2, \ldots a^n$，基于划分点t，可将D分为子集D_t^-和D_t^+，其中D_t^-包含那些在属性a上取值不大于t的样本，D_t^+包含那些在属性a上取值大于t的样本。考虑包含$n-1$个元素的候选划分点集合

$$T_a = \left\{ \frac{a^i + a^{i+1}}{2} \mid 1 \le i \le n-1 \right\}$$

即把区间$[a^i, a^{i-1})$的中位点$\frac{a^i+a^{i+1}}{2}$作为候选划分点

4.4.1 连续值处理

- 连续属性离散化(二分法)
  - 第二步：采用离散属性值方法，考察这些划分点，选取最优的划分点进行样本集合的划分

$$
\begin{aligned}
\mathrm{Gain}(D,a) &= \max_{t\in T_a} \mathrm{Gain}(D,a,t) \\
&= \max_{t\in T_a} \mathrm{Ent}(D) - \sum_{\lambda\in\{-,+\}} \frac{|D_t^\lambda|}{|D|}\mathrm{Ent}(D_t^\lambda)
\end{aligned}
$$

其中 $\mathrm{Gain}(D,a,t)$ 是样本集D基于划分点t二分后的信息增益，于是，就可选择使 $\mathrm{Gain}(D,a,t)$ 最大化的划分点

4.4.1 连续值处理

例子：给定下表数据，按照信息增益选择哪个属性进行划分？

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

1.对属性“密度”，其候选划分点集合包含16个候选值：例如(0.245+0.243)/2=0.244

$$T_{密度} = \{0.244, 0.294, 0.351, 0.381, 0.420, 0.459, 0.518, 0.574, 0.600, 0.621, 0.636, 0.648, 0.661, 0.681, 0.708, 0.746\}$$

计算每个划分点的信息增益，得到最大增益为：0.262，对应划分点为0.381

$$\mathrm{Ent}(D) = -\sum_{k=1}^{2} p_k \log_2 p_k = -\left(\frac{8}{17}\log_2\frac{8}{17} + \frac{9}{17}\log_2\frac{9}{17}\right) = 0.998$$

4.4.1 连续值处理

例子：给定下表数据，按照信息增益选择哪个属性进行划分？

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

取划分点:t_0=0.381;

则:

D(t>t_0)={1,2,3,4,5,6,7,8,9,13,14,16,17}

好瓜：8

坏瓜：5

Ent(D(t>t_0)) =

$-(\frac{8}{13}\log\frac{8}{13}+\frac{5}{13}\log\frac{5}{13})=0.961$

D(t< t_0)={10,11,12,15}

好瓜：0

坏瓜：4

Ent(D(t<t_0)) = 0

Gain(D,a,t) = 0.998 - $\frac{13}{17}*0.961$ = 0.263

4.4.1 连续值处理

例子：给定下表数据，按照信息增益选择哪个属性进行划分？

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	[illegible]
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	[illegible]
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	[illegible]

1.对属性“密度”，计算每个划分点的信息增益，得到最大增益为：0.262，对应划分点为0.381

2.对“含糖量”计算每个划分点的信息增益，得到最大增益为：0.349，对应划分点为0.126

3.计算色泽等信息增益：

$$\mathrm{Gain}(D,\text{色泽})=0.109;\quad \mathrm{Gain}(D,\text{根蒂})=0.143;$$
$$\mathrm{Gain}(D,\text{敲声})=0.141;\quad \mathrm{Gain}(D,\text{纹理})=0.381;$$
$$\mathrm{Gain}(D,\text{脐部})=0.289;\quad \mathrm{Gain}(D,\text{触感})=0.006;$$
$$\mathrm{Gain}(D,\text{密度})=0.262;\quad \mathrm{Gain}(D,\text{含糖率})=0.349.$$

选择纹理进行划分

4.4.1 连续值处理

纹理作为根节点，此后递归划分，得到下图决策树：

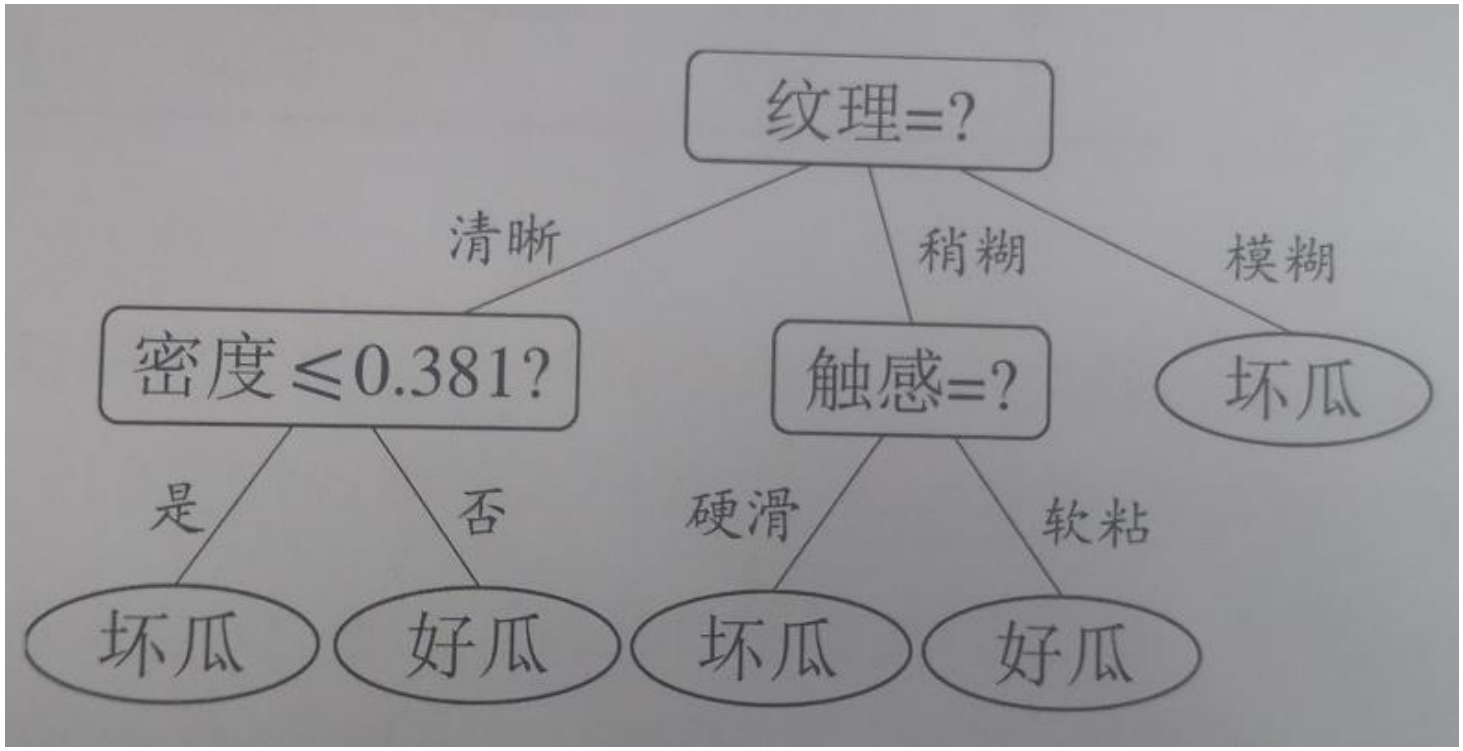

与离散属性不同，若当前结点划分属性为连续属性，该属性还可作为其后代结点的划分属性

4.4.2 缺失值处理

- 不完整样本，即样本的属性值缺失
- 仅使用无缺失的样本进行学习?

对数据信息极大的浪费

- 使用有缺失值的样本，需要解决两个问题？

Q1：如何在属性缺失的情况下进行划分属性选择？

Q2：给定划分属性，若样本在该属性上的值缺失，如何对样本进行划分？

4.4.2 缺失值处理

- $\tilde{D}$ 表示 D 中在属性 a 上没有缺失值的样本子集，$\tilde{D}^v$ 表示 $\tilde{D}$ 中在属性 a 上取值为 a^v 的样本子集，$\tilde{D}_k$ 表示 $\tilde{D}$ 中属于第 k 类的样本子集

  为每个样本 $\boldsymbol{x}$ 赋予一个权重 w_x，并定义：

  - 无缺失值样本所占的比例

$$\rho = \frac{\sum_{x \in \tilde{D}} w_x}{\sum_{x \in D} w_x}$$

  - 无缺失值样本中第 k 类所占比例

$$\tilde{p}_k = \frac{\sum_{x \in \tilde{D}_k} w_x}{\sum_{x \in \tilde{D}} w_x} \quad (1 \le k \le |\mathcal{Y}|)$$

  - 无缺失值样本中在属性 a 上取值 a^v 的样本所占比例

$$\tilde{r}_v = \frac{\sum_{x \in \tilde{D}^v} w_x}{\sum_{x \in \tilde{D}} w_x} \quad (1 \le v \le V)$$

Q1：如何在属性缺失的情况下进行划分属性选择？

4.4.2 缺失值处理

- 基于上述定义，可得

$$\begin{aligned}\mathrm{Gain}(D,a) &= \rho \times \mathrm{Gain}(\tilde{D},a) \\ &= \rho \times \left(\mathrm{Ent}(\tilde{D}) - \sum_{v=1}^{V} \tilde{r}_v \mathrm{Ent}(\tilde{D}^v)\right)\end{aligned}$$

计算没有缺失值部分的信息增益

其中

$$\mathrm{Ent}(\tilde{D}) = -\sum_{k=1}^{|\mathcal{Y}|} \tilde{p}_k \log_2 \tilde{p}_k$$

- 对于Q2
  - 若样本$\boldsymbol{x}$在划分属性a上的取值已知，则将$\boldsymbol{x}$划入与其取值对应的子结点，且样本权值在子结点中保持为w_x
  - 若样本$\boldsymbol{x}$在划分属性a上的取值未知，则将$\boldsymbol{x}$同时划入所有子结点，且样本权值在与属性值a^v对应的子结点中调整为$\tilde{r}_v \cdot w_x$(直观来看，相当于让同一个样本以不同概率划入不同的子结点中去)

4.4.2 缺失值处理-实例

例子：

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	–	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	–	是
3	乌黑	蜷缩	–	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	–	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	–	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	–	稍凹	硬滑	是
9	乌黑	–	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	–	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	–	否
12	浅白	蜷缩	–	模糊	平坦	软粘	否
13	–	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	–	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	–	沉闷	稍糊	稍凹	硬滑	否

- 学习开始时，根结点包含样本集D中全部17个样例，各样例的权值均为1
- 以属性“色泽”为例，该属性上无缺失值的样例子集$\tilde{D}$包含14个样例，$\tilde{D}$的信息熵为

$$\mathrm{Ent}(\tilde{D}) = -\sum_{k=1}^{2} \tilde{p}_k \log_2 \tilde{p}_k$$

$$= -\left(\frac{6}{14}\log_2\frac{6}{14} + \frac{8}{14}\log_2\frac{8}{14}\right) = 0.985$$

4.4.2 缺失值处理-实例

- 令 $\tilde{D}^1$, $\tilde{D}^2$, $\tilde{D}^3$ 分别表示在属性“色泽”上取值为“青绿”“乌黑”以及“浅白”的样本子集，有

$$\mathrm{Ent}(\tilde{D}^1) = -\left(\frac{2}{4}\log_2\frac{2}{4} + \frac{2}{4}\log_2\frac{2}{4}\right) = 1.000 \quad \mathrm{Ent}(\tilde{D}^2) = -\left(\frac{4}{6}\log_2\frac{4}{6} + \frac{2}{6}\log_2\frac{2}{6}\right) = 0.918$$

$$\mathrm{Ent}(\tilde{D}^3) = -\left(\frac{0}{4}\log_2\frac{0}{4} + \frac{4}{4}\log_2\frac{4}{4}\right) = 0.000$$

- 因此，样本子集 $\tilde{D}$ 上属性“色泽”的信息增益为

$$\begin{aligned}\mathrm{Gain}(\tilde{D}, \text{色泽}) &= \mathrm{Ent}(\tilde{D}) - \sum_{v=1}^{3}\tilde{r}_v\mathrm{Ent}(\tilde{D}^v) \\ &= 0.985 - \left(\frac{4}{14}\times 1.000 + \frac{6}{14}\times 0.918 + \frac{4}{14}\times 0.000\right) \\ &= 0.306\end{aligned}$$

- 于是，样本集 D 上属性“色泽”的信息增益为

$$\mathrm{Gain}(D, \text{色泽}) = \rho \times \mathrm{Gain}(\tilde{D}, \text{色泽}) = \frac{14}{17}\times 0.306 = 0.252$$

4.4.2 缺失值处理-实例

- 类似地可计算出所有属性在数据集上的信息增益

$$\mathrm{Gain}(D, 色泽) = 0.252 \qquad \mathrm{Gain}(D, 根蒂) = 0.171$$

$$\mathrm{Gain}(D, 敲声) = 0.145 \qquad \boxed{\mathrm{Gain}(D, 纹理) = 0.424}$$

$$\mathrm{Gain}(D, 脐部) = 0.289 \qquad \mathrm{Gain}(D, 触感) = 0.006$$

进入“纹理=清晰”分支

进入“纹理=稍糊”分支

进入“纹理=模糊”分支

样本权重在各子结点仍为1

在属性“纹理”上出现缺失值，样本8和10同时进入3个分支，调整8和10在3分分支权值分别为7/15，5/15，3/15

编号	色泽	根蒂	敲声	纹理	脐部	触感	好瓜
1	–	蜷缩	浊响	清晰	凹陷	硬滑	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	–	是
3	乌黑	蜷缩	–	清晰	凹陷	硬滑	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	是
5	–	蜷缩	浊响	清晰	凹陷	硬滑	是
6	青绿	稍蜷	浊响	清晰	–	软粘	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	是
8	乌黑	稍蜷	浊响	–	稍凹	硬滑	是
9	乌黑	–	沉闷	稍糊	稍凹	硬滑	否
10	青绿	硬挺	清脆	–	平坦	软粘	否
11	浅白	硬挺	清脆	模糊	平坦	–	否
12	浅白	蜷缩	–	模糊	平坦	软粘	否
13	–	稍蜷	浊响	稍糊	凹陷	硬滑	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	否
15	乌黑	稍蜷	浊响	清晰	–	软粘	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	否
17	青绿	–	沉闷	稍糊	稍凹	硬滑	否

4.4.2 缺失值处理-实例

- 继续递归划分得到最终决策树：

总结：权值w的使用实现了两个目的

1.在属性选择时，通过加权统计和 ρ 缩放，让缺失样本仍能“间接”参与决策，同时惩罚缺失严重的属性。

2.在样本划分时，通过权值拆分，让缺失样本“软分配”到多个分支，既保留了其存在，又符合数据分布。

大纲

- 基本流程
- 划分选择
- 剪枝处理
- 连续与缺失值
- 多变量决策树

4.5 多变量决策树

- 单变量决策树——轴平行

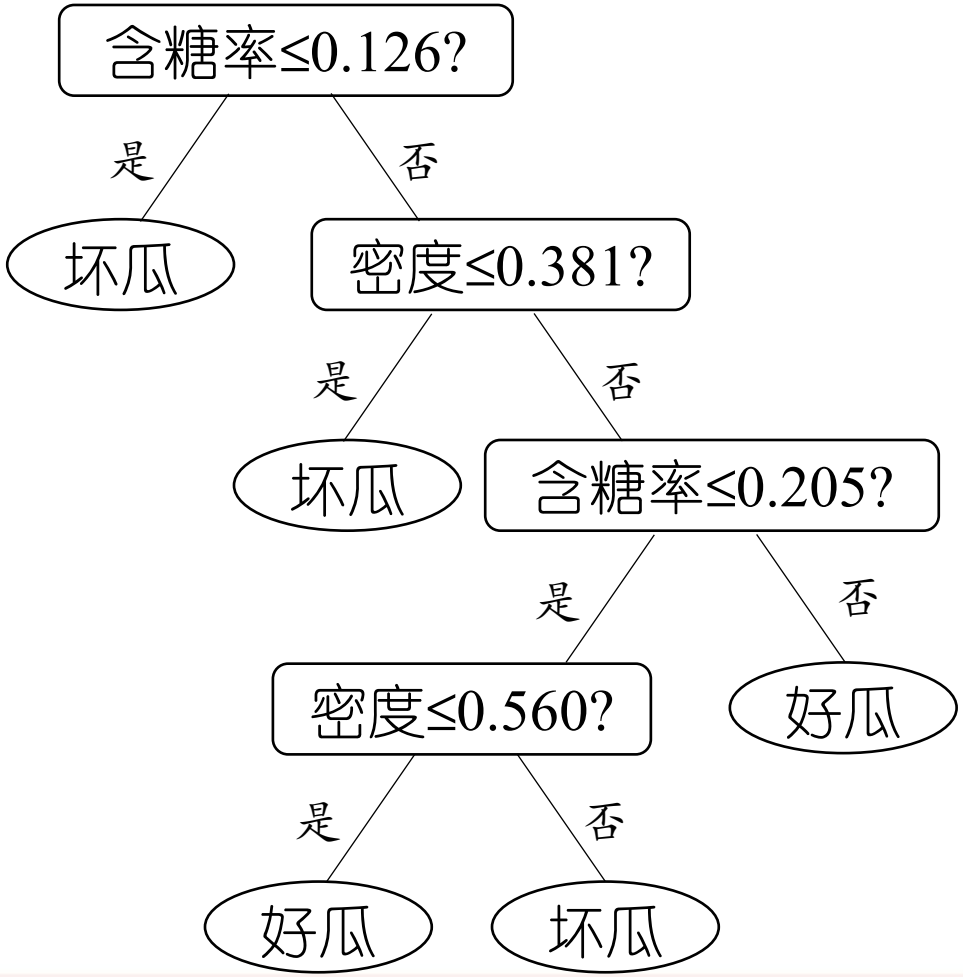

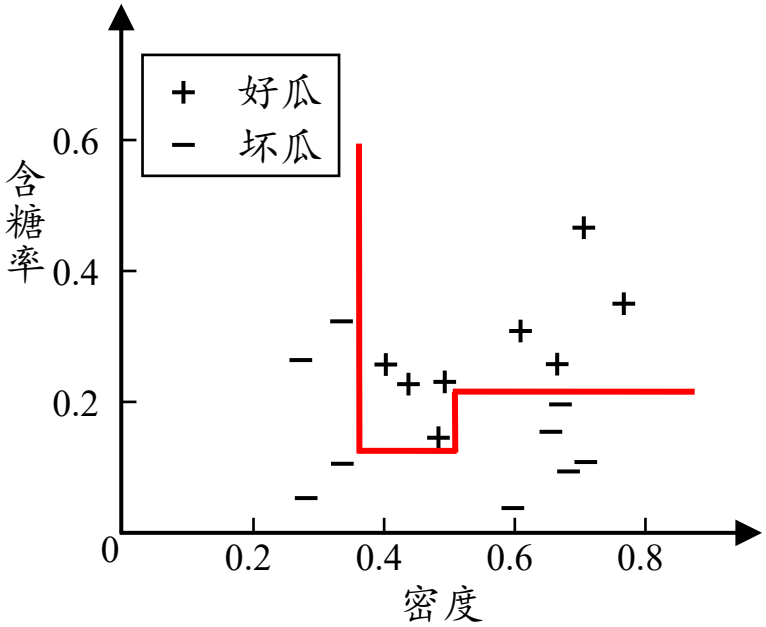

4.5 多变量决策树

- 单变量决策树分类边界:轴平行
- 多变量决策树：灵活

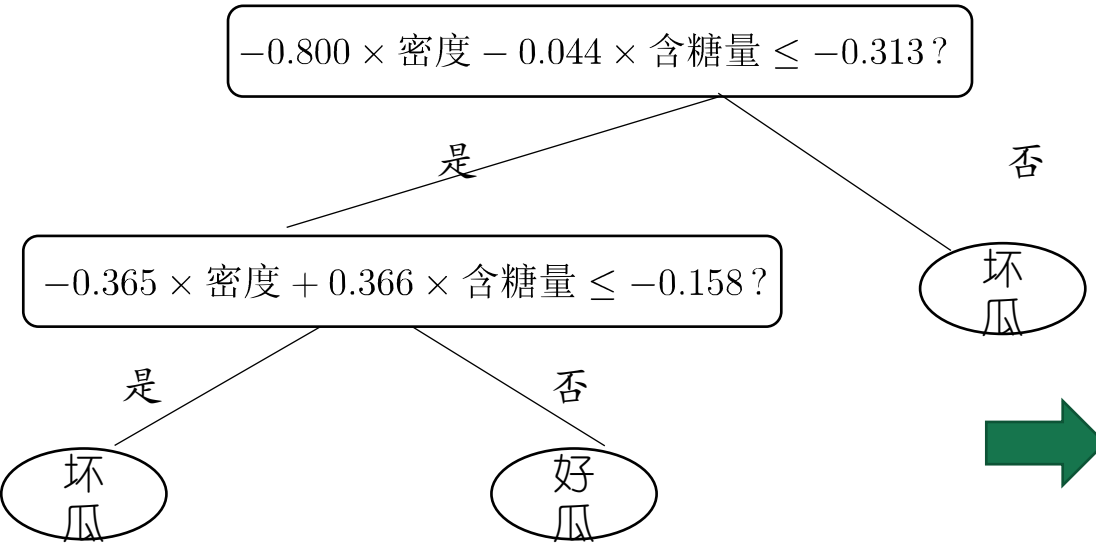

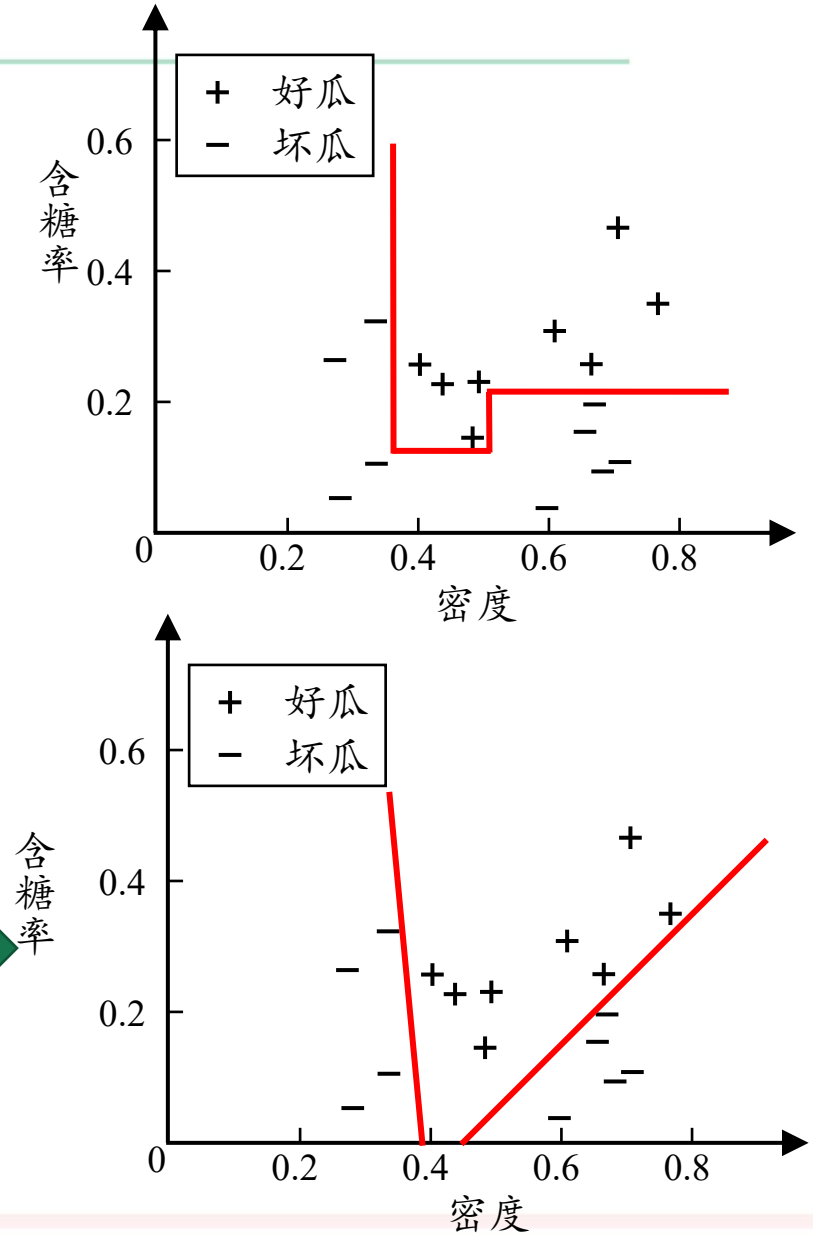

4.5 多变量决策树

- 单变量决策树分类边界:轴平行
- 多变量决策树

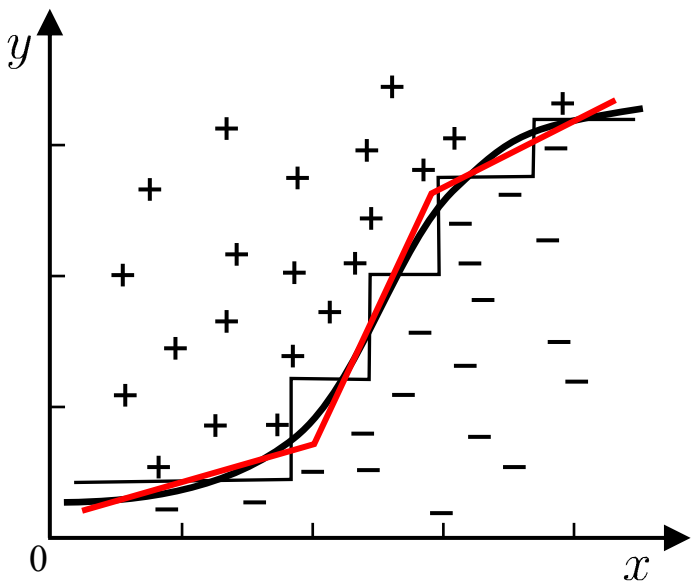

- 非叶节点不再是仅对某个属性，而是对属性的线性组合

- 每个非叶结点是一个形如 $\sum_{i=1}^{d} w_i a_i = t$ 的线性分类器，其中w_i是属性a_i的权值，w_i和 t 可在该结点所含的样本集和属性集上学得

总结

- 属性划分选择
- 剪枝处理（预剪枝，后剪枝）
- 属性连续值和缺失值的处理
- 单变量决策树到多变量决策树

成熟的决策树软件包

- ID3,C4.5,C5.0
  http://www.rulequest.com/Personal/

- J48
  http://www.cs.waikato.ac.nz/ml/weka/