复习-决策树

- 总体思想？
  - 分类问题，选核心特征用来做分界判断；对各子树递归生成，最后得到合适的分类树
  - 核心：泛化能力强
- 核心问题？
  - 每一次划分时，节点如何选择？划分后希望更纯？
  - 每个子树如何生成？何时停止？ 树太大了，怎么办？
- 其他？
  - 连续值？有些属性值缺失？
  - 现有单属性无法划分好？

4.1 基本算法

4.2 划分选择：
信息增益、增益率、基尼指数

4.3 剪枝处理：
预剪枝、后剪枝

4.4 连续与缺失值
4.5 多变量决策树

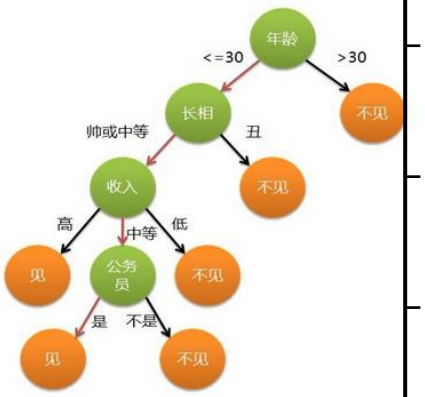

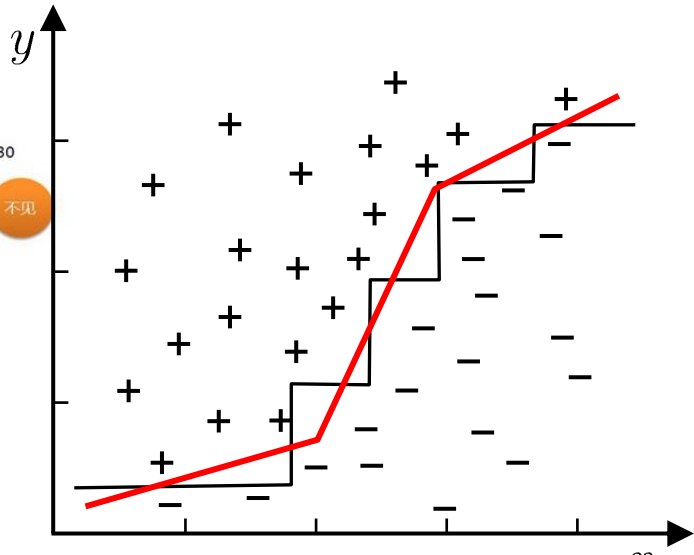

4.1 基本流程

Algorithm 1 决策树学习基本算法

输入:

- 训练集 $D = \{(\mathbf{x}_1, y_1), \ldots, (\mathbf{x}_m, y_m)\}$;
- 属性集 $A = \{a_1, \ldots, a_d\}$.

过程: 函数 TreeGenerate(D, A)

```
生成结点 node;
if D 中样本全属于同一类别 C then
    将 node 标记为 C 类叶结点; return
end if
if A = ∅ OR D 中样本在 A 上取值相同 then
    将 node 标记叶结点，其类别标记为 D 中样本数最多的类; return
end if
从 A 中选择最优划分属性 a*;
for a* 的每一个值 a*^v do
    为 node 生成每一个分枝; 令 D_v 表示 D 中在 a* 上取值为 a*^v 的样本子集;
    if D_v 为空 then
        将分枝结点标记为叶结点, 其类别标记为 D 中样本最多的类; return
    else
        以 TreeGenerate(D_v, A − {a*}) 为分枝结点
    end if
end for
```

输出: 以 node 为根结点的一棵决策树

（1）当前结点包含的样本全部属于同一类别

（2）当前属性集为空，或所有样本在所有属性上取值相同

（3）当前结点包含的样本集合为空

4.2 划分选择

- 决策树学习的关键在于如何选择最优划分属性。一般而言，随着划分过程不断进行，我们希望决策树的分支结点所包含的样本尽可能属于同一类别，即结点的“纯度”(purity)越来越高

- 经典的属性划分方法：
  - 信息增益： ID3
  - 增益率：C4.5
  - 基尼指数：CART

要求：掌握不同属性划分方法的具体实例计算过程。

4.2.1 信息增益

信息熵　　度量样本集合纯度最常用的一种指标

- 离散属性a有V个可能的取值$\{a^1, a^2, ..., a^V\}$，用a来进行划分，则会产生V个分支结点，其中第v个分支结点包含了D中所有在属性a上取值为a^v的样本，记为D^v。则可计算出用属性a对样本集D进行划分所获得的“信息增益”：

$$\mathrm{Gain}(D, a) = \mathrm{Ent}(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} \mathrm{Ent}(D^v)$$

$$\mathrm{Ent}(D) = -\sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$$

为分支结点权重，样本数越多的分支结点的影响越大

- 一般而言，信息增益越大，则意味着使用属性a来进行划分所获得的“纯度提升”越大

□ ID3（Iterative Dichotomiser，迭代二分器）决策树学习算法[Quinlan, 1986]以信息增益为准则来选择划分属性

信息增益对可取值数目较多的属性有所偏好

4.2.2 增益率

- 增益率定义：

$$\mathrm{Gain_ratio}(D,a)=\frac{\mathrm{Gain}(D,a)}{\mathrm{IV}(a)}$$

其中

$$\mathrm{IV}(a)=-\sum_{v=1}^{V}\frac{|D^v|}{|D|}\log_2\frac{|D^v|}{|D|}$$

称为属性a的“固有值” [Quinlan, 1993]，属性a的可能取值数目越多（即V越大），则$\mathrm{IV}(a)$的值通常就越大

4.2.3 基尼指数

定义：分类问题中，假设有K个类，样本点属于第k类的概率为p_k,则概率分布的基尼值定义为：

$$Gini(p) = \sum_{k=1}^{K} p_k(1-p_k) = 1 - \sum_{k=1}^{K} p_k^2$$

Gini(D)越小，数据集D的纯度越高；

反映了随机抽取两个样本，其类别标记不一致的概率

给定数据集D，属性a的基尼指数定义为：

$$Gini_{index}(D,a) = \Sigma_{v=1}^{V} \frac{|D^v|}{|D|} Gini(D^v)$$

在候选属性集合A中，选择那个使得划分后基尼指数最小的属性作为最有划分属性。

4.3 剪枝处理

- 为什么剪枝
  - “剪枝”是决策树学习算法对付“过拟合”的主要手段
  - 可通过“剪枝”来一定程度避免因决策分支过多，以致于把训练集自身的一些特点当做所有数据都具有的一般性质而导致的过拟

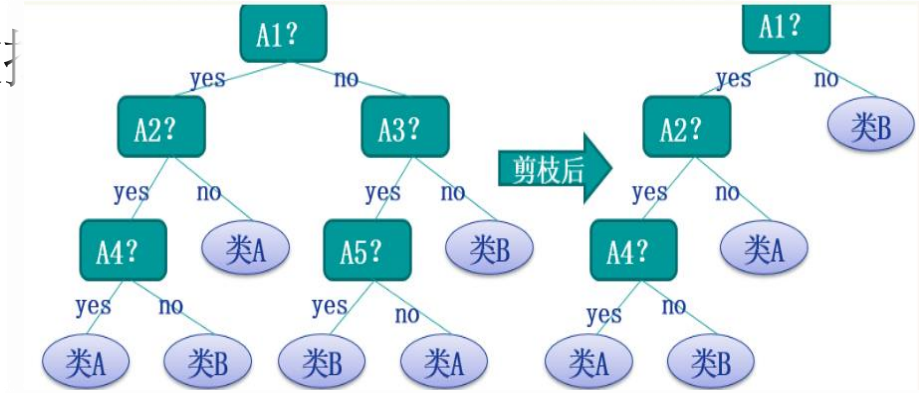

- 剪枝的基本策略
  - 预剪枝
  - 后剪枝

- 判断决策树泛化性能是否提升的方法
  - 留出法：预留一部分数据用作“验证集”以进行性能

4.3.1 预剪枝

预剪枝的优缺点

- 优点
  - 降低过拟合风险
  - 显著减少训练时间和测试时间开销

- 缺点
  - 欠拟合风险：有些分支的当前划分虽然不能提升泛化性能，但在其基础上进行的后续划分却有可能导致性能显著提高。预剪枝基于“贪心”本质禁止这些分支展开，带来了欠拟合风险

4.3.2 后剪枝

后剪枝的优缺点

- 优点
  - 后剪枝比预剪枝保留了更多的分支，欠拟合风险小，泛化性能往往优于预剪枝决策树
- 缺点
  - 训练时间开销大：后剪枝过程是在生成完全决策树之后进行的，需要自底向上对所有非叶结点逐一考察

第六章：支持向量机

引言

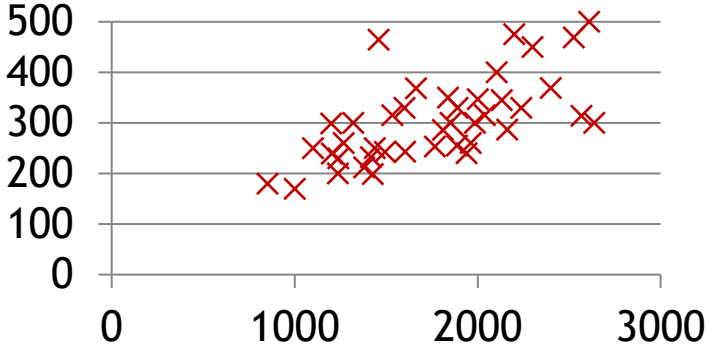
500
400
300
200
100
0
0
1000
2000
3000

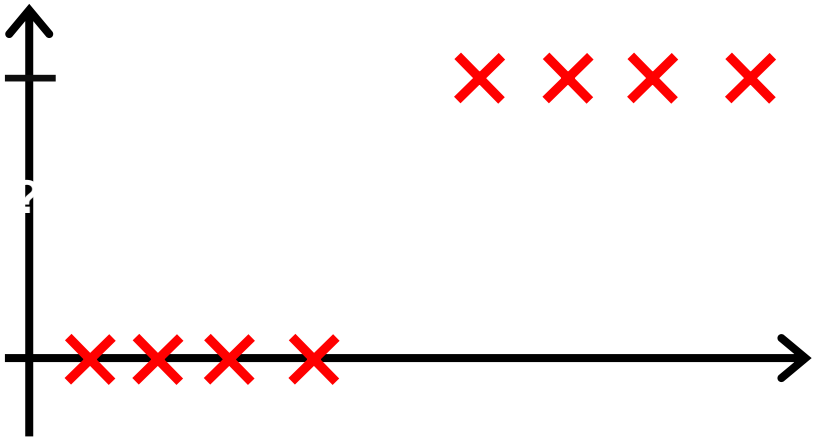

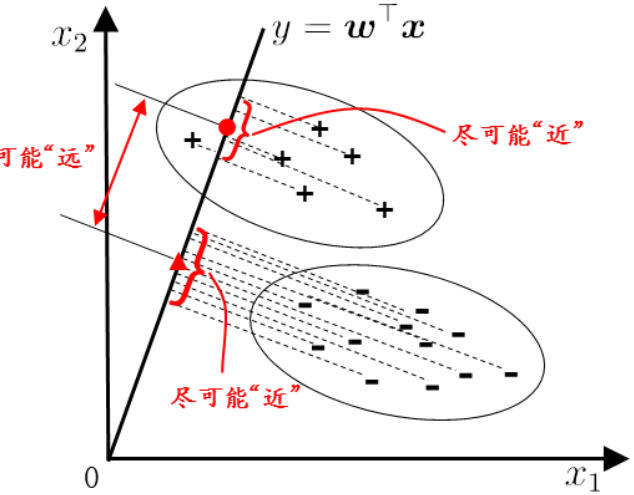
x_2
$y = \boldsymbol{w}^\top \boldsymbol{x}$
可能“远”
尽可能“近”
尽可能“近”
0
x_1

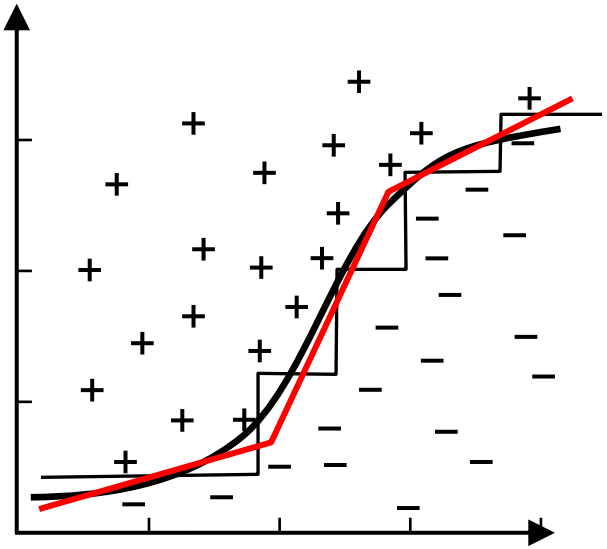

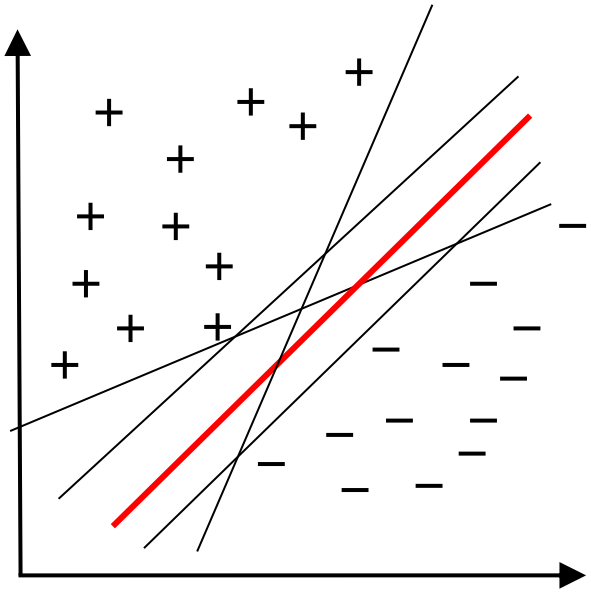

互动

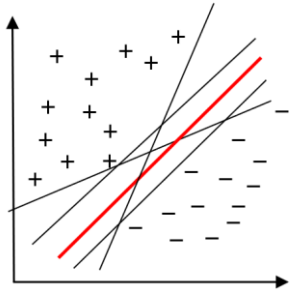

- 总体思想？
  - 用线性超平面来划分不同的类别
  - 核心：泛化能力强
- 核心问题？
  - 将训练样本分开的超平面可能有很多，哪一个好呢? **间隔与支持向量**
  - 怎么得到最优超平面？
  - 模型、损失函数、算法分别如何？ **对偶问题**
- 其他？
  - 线性超平面无法划分，怎么办？ **核函数**
  - 现实中，很难确定合适的核函数使得训练样本在特征空间中线性可分；同时一个线性可分的结果也很难断定是否是有过拟合造成的. **软间隔与正则化**
  - 除了分类问题，能解决回归问题？ **支持向量回归**

SVM

2分钟简介SVM_哔哩哔哩_bilibili

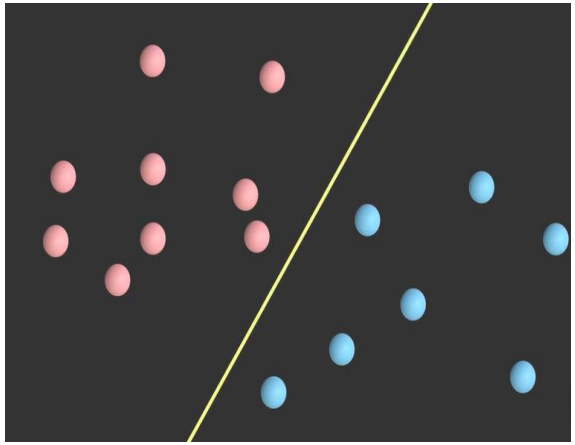

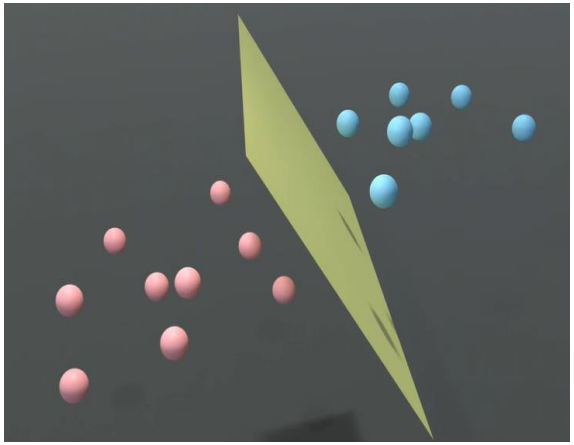

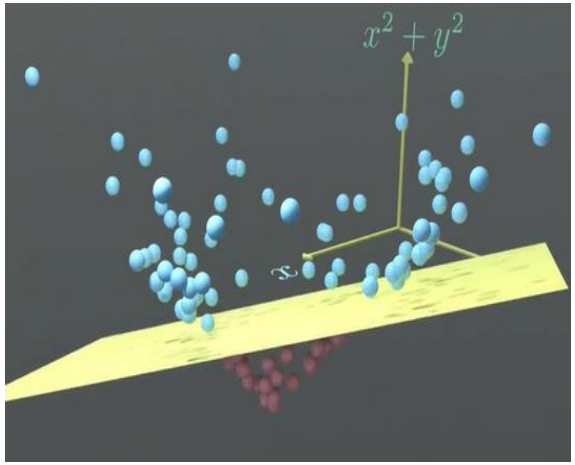

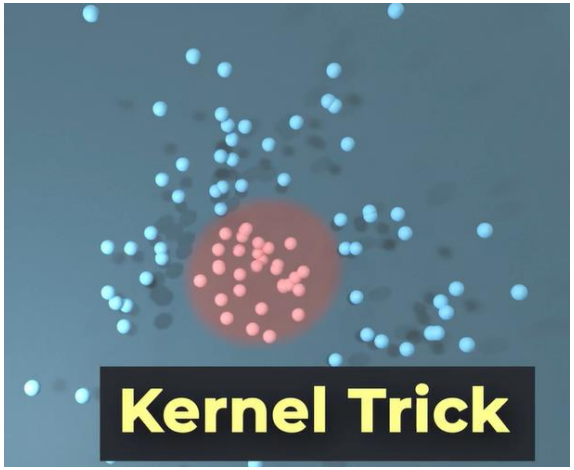

大纲

- 最大间隔与分类
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归

1 最大间隔与分类

线性模型：

在样本空间中寻找一个超平面，将不同类别的样本分开.

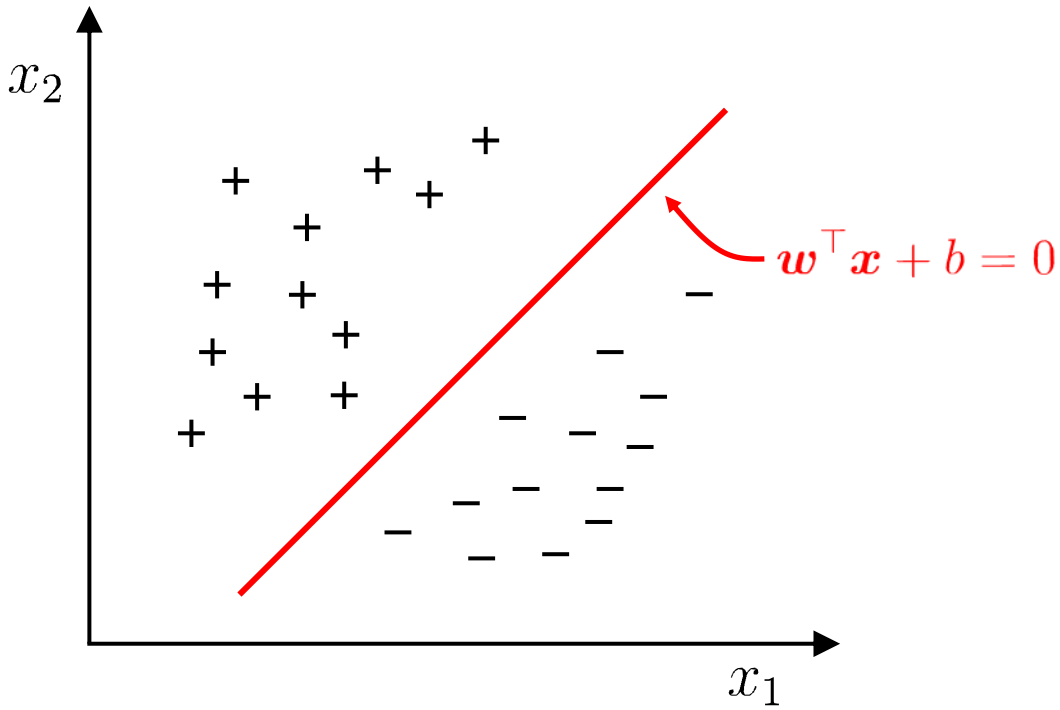

1 最大间隔与分类

空间维度	SVM 形式	图形示例
二维空间	一条直线	
三维空间	一个平面	
多维空间	超平面	

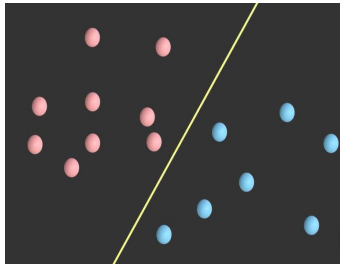

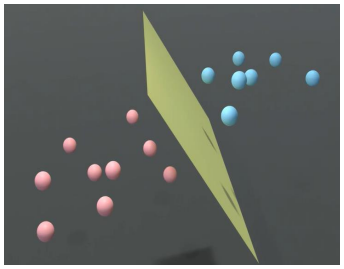

1 最大间隔与分类

问题:将训练样本分开的超平面可能有很多，哪一个好呢?

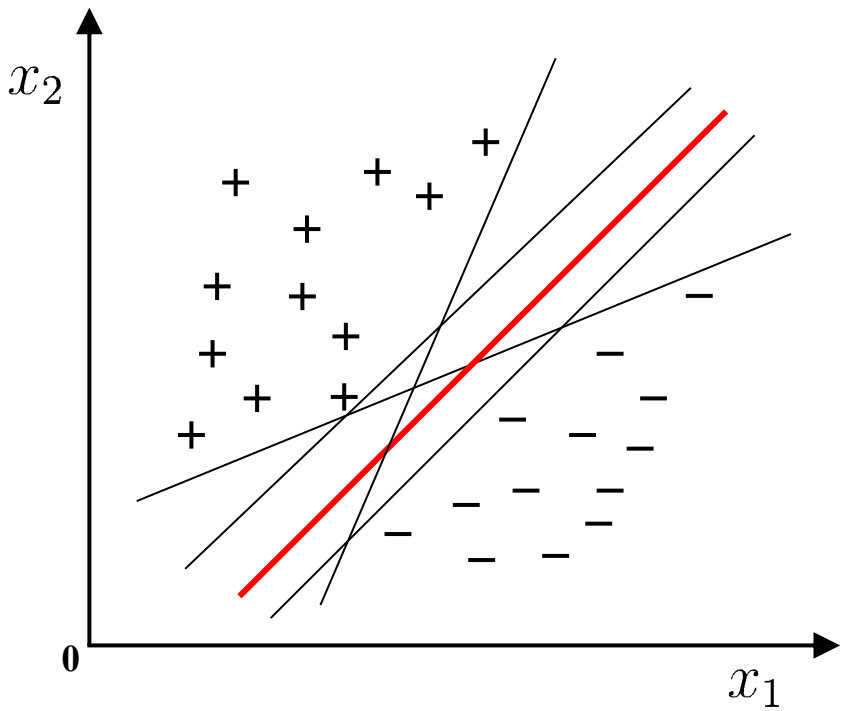

–应选择”正中间”，容忍性好，鲁棒性高，泛化能力最强.

最大化决策边界的边缘

1 最大间隔与分类

超平面方程: $\boldsymbol{w}^\top \boldsymbol{x} + b = 0$

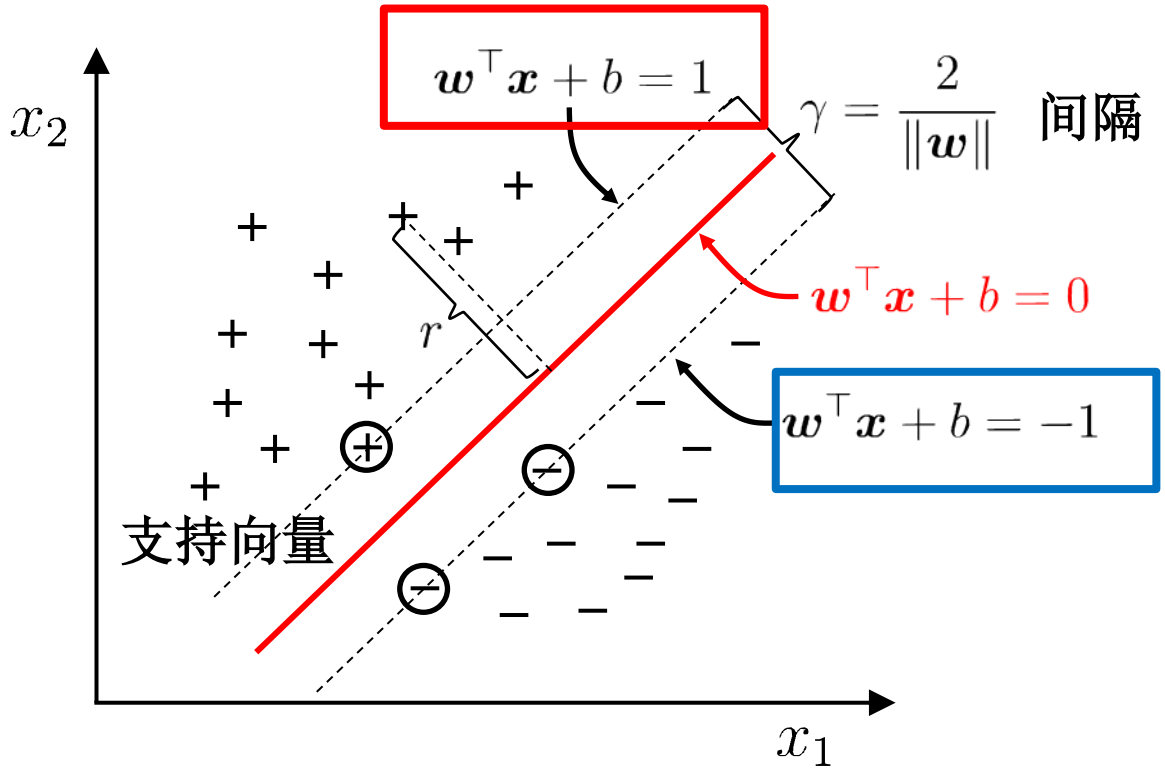

1 最大间隔与分类

训练数据：

$\mathcal{D} = \{x_i, yi\}_{i=1}^{m} \quad \boldsymbol{x} \in \mathbb{R}^n, \quad y \in \{-1, +1\}$

线性可分当且仅当:

$$\exists\, w, b \qquad s.t. \quad w^T x_i + b > 0 \quad \text{if} \quad yi = +1 \qquad \text{且}$$
$$w^T x_i + b < 0 \quad \text{if} \quad y_i = -1$$

1 最大间隔与分类

训练数据：

$\mathcal{D} = \{x_i, yi\}_{i=1}^{m} \quad \boldsymbol{x} \in \mathbb{R}^n, \quad y \in \{-1, +1\}$

线性可分当且仅当:

$$\exists\, w, b \quad s.t. \quad w^T x_i + b > 0 \quad \text{if} \quad yi = +1 \quad \text{且}$$
$$w^T x_i + b < 0 \quad \text{if} \quad y_i = -1$$

$$\Leftrightarrow \exists\, w, b \quad s.t. \quad y_i(w^T x_i + b) > 0$$

$$\Leftrightarrow \exists\, w, b, c \quad s.t. \quad y_i(w^T x_i + b) \geq c \quad and \quad c > 0$$

1 最大间隔与分类

训练数据：

$\mathcal{D} = \{x_i, yi\}_{i=1}^{m} \quad \boldsymbol{x} \in \mathbb{R}^n, \quad y \in \{-1, +1\}$

线性可分当且仅当:

$$\exists\, w, b \quad s.t. \quad w^T x_i + b > 0 \quad \text{if} \quad yi = +1 \quad \text{且}$$
$$w^T x_i + b < 0 \quad \text{if} \quad y_i = -1$$

$$\Leftrightarrow \exists\, w, b \quad s.t. \quad y_i(w^T x_i + b) > 0$$

$$\Leftrightarrow \exists\, w, b, c \quad s.t. \quad y_i(w^T x_i + b) \geq c \quad and \quad c > 0$$

$$\Leftrightarrow \exists\, w, b \quad s.t. \quad \boxed{y_i(w^T x_i + b) \geq 1}$$

1 最大间隔与分类

令 $\boldsymbol{x}_+$和 $\boldsymbol{x}_-$ 位于决策边界上，标签分别为正、负的两个样本，考虑 $\boldsymbol{x}_+$ 到分类线的距离为:

$$d_+ = \frac{\boxed{|\boldsymbol{w}^T\boldsymbol{x}_+ + b|}}{\|\boldsymbol{w}\|}$$

因此，分类间隔为：

$$\text{width} = \frac{2}{\|\boldsymbol{w}\|}$$

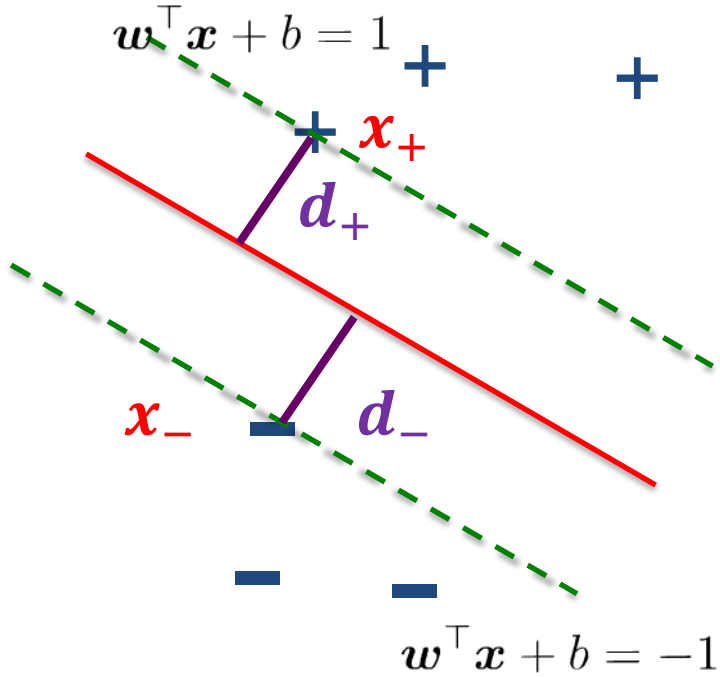

6.1 间隔与支持向量

超平面方程: $w^T x + b = 0$ ，满足：

$$\begin{cases} w^T x_i + b \geq +1, y_i = +1 \\ w^T x_i + b \leq -1, y_i = -1 \end{cases}$$

取两个决策边界上的点：x_1, x_2；

$$w^T x_1 + b = +1$$

$$w^T x_2 + b = -1$$

两式相减：

$$w^T (x_1 - x_2) = 2$$

$$\Rightarrow w^T \overrightarrow{x_1 - x_2} = 2$$

向量内积

$$\Rightarrow ||w|| * \boxed{||x_1 - x_2|| * \cos\theta} = 2$$

$$\Rightarrow ||w|| * \boxed{\gamma} = 2 \Rightarrow \gamma = \frac{2}{||w||}$$

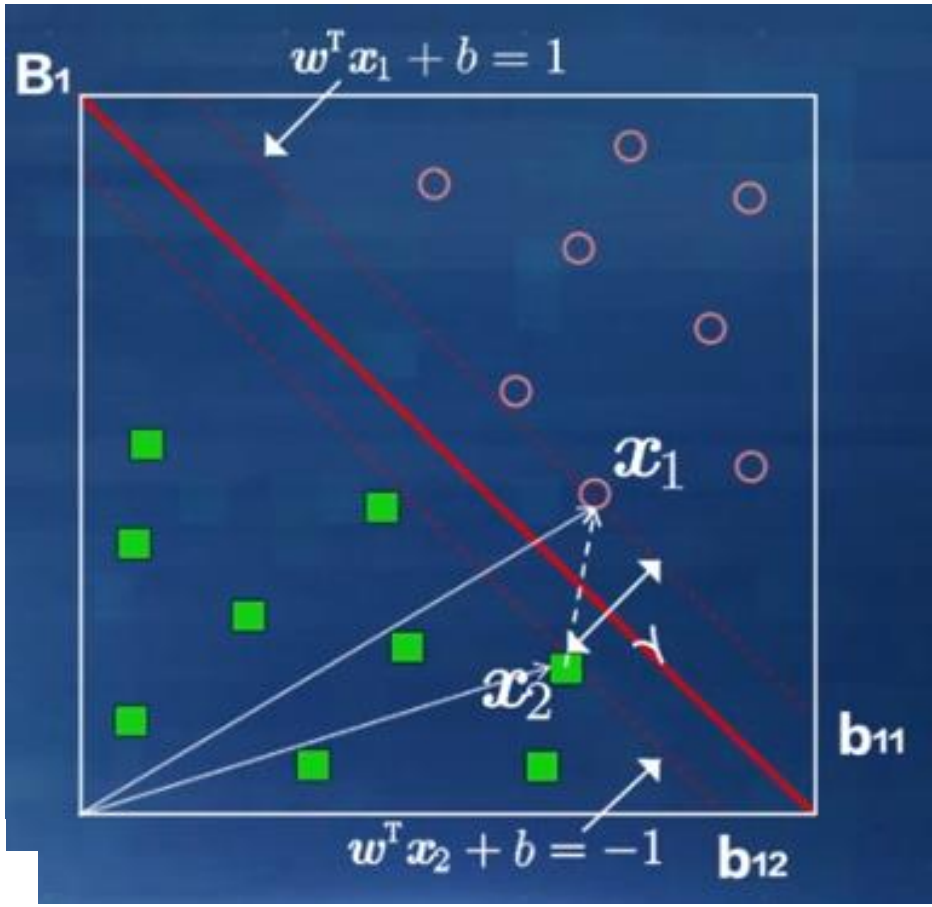

1 最大间隔与分类

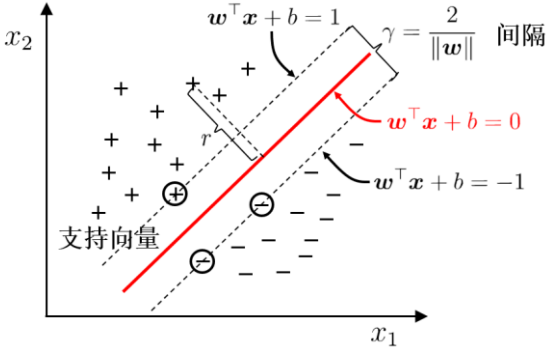

最大化间隔: 寻找参数w和b , 使得下述公式最大

$$\arg\max_{\boldsymbol{w},b} \quad \frac{2}{\|\boldsymbol{w}\|}$$

$$\text{s.t.} \quad y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \ \ i = 1, 2, \ldots, m.$$

$$\Updownarrow$$

$$\arg\min_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2$$

$$\text{s.t.} \quad y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \ \ i = 1, 2, \ldots, m.$$

大纲

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归

2 对偶问题：等式约束

给定一个目标函数 $f: R^n \to R$，希望找到 $x \in R^n$，在满足约束条件 $g(x)=0$ 的前提下，使得 $f(x)$ 有最小值。该约束优化问题记为：

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g(\mathbf{x}) = 0. \end{aligned}$$

可建立拉格朗日函数：

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x})$$

其中 λ 称为拉格朗日乘数。因此，可将原本的约束优化问题转换成等价的无约束优化问题：

$$\min_{\mathbf{x},\lambda} \; L(\mathbf{x}, \lambda)$$

分别对待求解参数求偏导，可得：

$$\nabla_{\mathbf{x}} L = \frac{\partial L}{\partial \mathbf{x}} = \nabla f + \lambda \nabla g = \mathbf{0}$$

$$\nabla_{\lambda} L = \frac{\partial L}{\partial \lambda} = g(\mathbf{x}) = 0$$

一般联立方程组可以得到相应的解。

2 对偶问题：不等式约束的KKT条件

将约束等式 $g(x)=0$ 推广为不等式 $g(x)\leq 0$。这个约束优化问题可改为：

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g(\mathbf{x}) \leq 0. \end{aligned}$$

同理，其拉格朗日函数为：

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x})$$

其约束范围为不等式，因此可等价转化成Karush-Kuhn-Tucker (KKT)条件：

$$\begin{cases} \nabla_{\mathbf{x}} L = \nabla f + \lambda \nabla g = \mathbf{0} \\ g(\mathbf{x}) \leq 0 \\ \lambda \geq 0 \\ \boxed{\lambda g(\mathbf{x}) = 0.} \end{cases}$$

互补松弛性

在此基础上，通过优化方式（如二次规划或SMO）求解其最优解。

2 对偶问题

- 最大间隔问题的拉格朗日乘法

$$\arg\min_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2$$
$$\text{s.t.} \quad y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \ i = 1, 2, \ldots, m.$$
$$y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) - 1 \geq 0$$

$$\min \quad f(\mathbf{x})$$
$$\text{s.t.} \quad g(\mathbf{x}) \leq 0.$$

– 第一步：引入拉格朗日乘子 $\boxed{\alpha_i} \geq 0$得到拉格朗日函数 $L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \boxed{\lambda} g(\mathbf{x})$

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\boldsymbol{w}\|^2 - \sum_{i=1}^{m} \alpha_i \left(y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) - 1\right)$$

2 对偶问题

$$\min_{w,b} \frac{1}{2} w^T w = \min_{w,b} \max_{\alpha} L(w,b,\alpha) = \max_{\alpha} \min_{w,b} L(w,b,\alpha)$$

https://zhuanlan.zhihu.com/p/99008623

- 拉格朗日乘子法:
  - 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$得到拉格朗日函数

$$L(\boldsymbol{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\boldsymbol{w}\|^2 - \sum_{i=1}^{m} \alpha_i \left(y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) - 1\right)$$

$$L(\mathbf{x}, \lambda) = f(\mathbf{x}) + \lambda g(\mathbf{x})$$

  - 第二步：令$L(w,b,\alpha)$ 对w和b的偏导为零：

$$\boldsymbol{w} = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i, \quad \sum_{i=1}^{m} \alpha_i y_i = 0.$$

$$\nabla_{\mathbf{x}} L = \nabla f + \lambda \nabla g = \mathbf{0}$$
$$g(\mathbf{x}) \leq 0$$
$$\lambda \geq 0$$
$$\lambda g(\mathbf{x}) = 0.$$

  - 第三步：回代到第一步：

$$\min_{\boldsymbol{\alpha}} \quad \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \boxed{\alpha_i \alpha_j} y_i y_j \boldsymbol{x}_i^\top \boldsymbol{x}_j - \sum_{i=1}^{m} \boxed{\alpha_i}$$

$$\text{s.t.} \quad \sum_{i=1}^{m} \alpha_i y_i = 0, \ \alpha_i \geq 0, \ i = 1, 2, \ldots, m.$$

2 对偶问题

$$\min_{w,b} \frac{1}{2} w^T w = \min_{w,b} \max_{\alpha} L(w,b,\alpha) = \max_{\alpha} \min_{w,b} L(w,b,\alpha)$$

https://zhuanlan.zhihu.com/p/99008623

- 支持向量机基本型：

$$\arg\min_{\boldsymbol{w},b} \quad \frac{1}{2}\|\boldsymbol{w}\|^2$$

$$\text{s.t.} \quad y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1, \ i = 1, 2, \ldots, m.$$

$$\boldsymbol{w} = \sum_{i=1}^{m} \alpha_i y_i \boldsymbol{x}_i, \quad \sum_{i=1}^{m} \alpha_i y_i = 0.$$

$$\min_{\boldsymbol{\alpha}} \quad \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^\top \boldsymbol{x}_j - \sum_{i=1}^{m} \alpha_i$$

$$\text{s.t.} \quad \sum_{i=1}^{m} \alpha_i y_i = 0, \ \alpha_i \geq 0, \ i = 1, 2, \ldots, m.$$

等价形式：

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j x_i^T x_j \quad s.t. \sum_{i=1}^{m} \alpha_i y_i = 0$$

2 对偶问题--KKT

- 最终模型:$f(\boldsymbol{x}) = \boldsymbol{w}^\top \boldsymbol{x} + b = \sum_{i=1}^{m} \boxed{\alpha_i y_i \boldsymbol{x}_i^\top \boldsymbol{x} + b}$ 未知数为α_i

- 根据Karush-Kuhn-Tucker（KKT）条件，函数的最优解满足下面条件：

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\boldsymbol{x}_i) \geq 1, \\ \alpha_i (y_i f(\boldsymbol{x}_i) - 1) = 0. \end{cases}$$

对于不在最大边缘边界上的点：$y_i f(\boldsymbol{x}_i) > 1$ ⇨ $\alpha_i = 0$

支持向量机解的稀疏性: 训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.

2 对偶问题--KKT

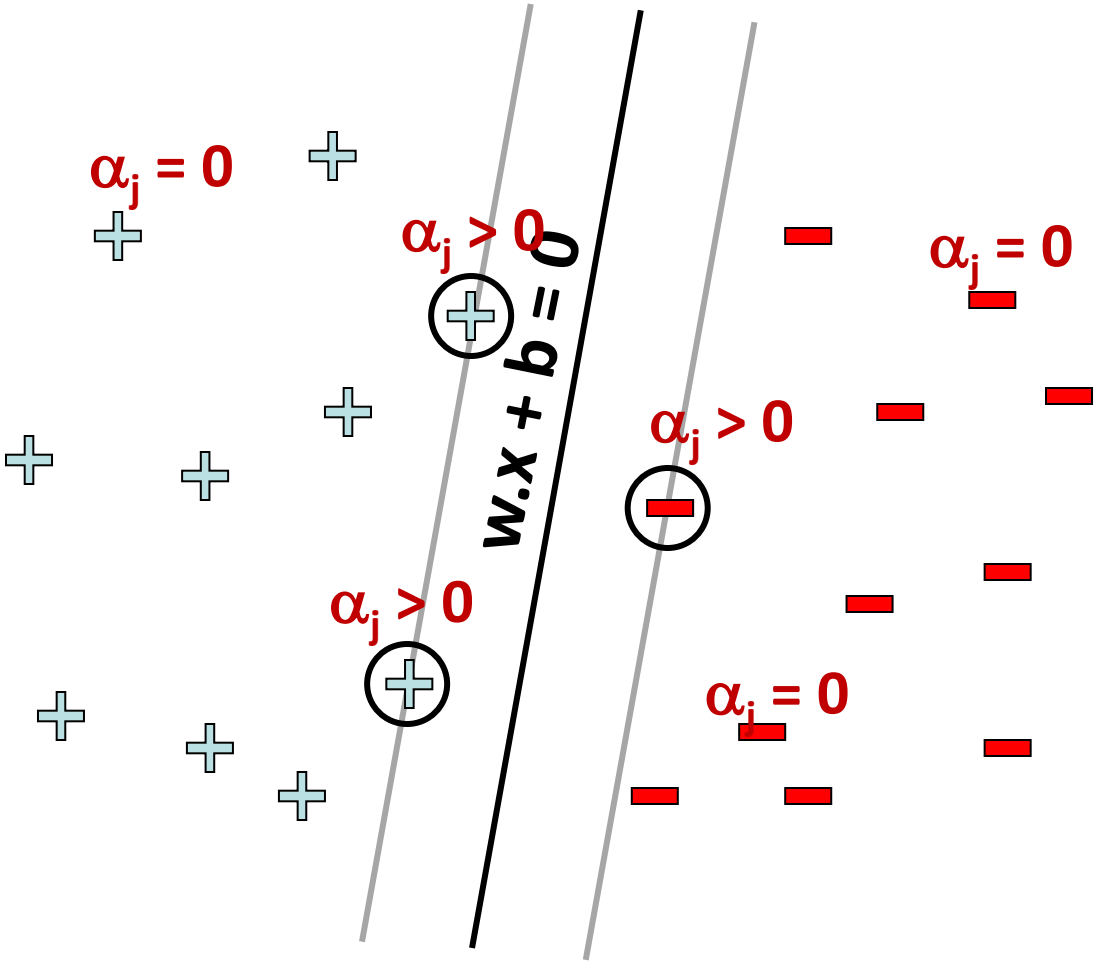

2 对偶问题：求解

超平面方程: $\boldsymbol{w}^\top \boldsymbol{x} + b = 0$

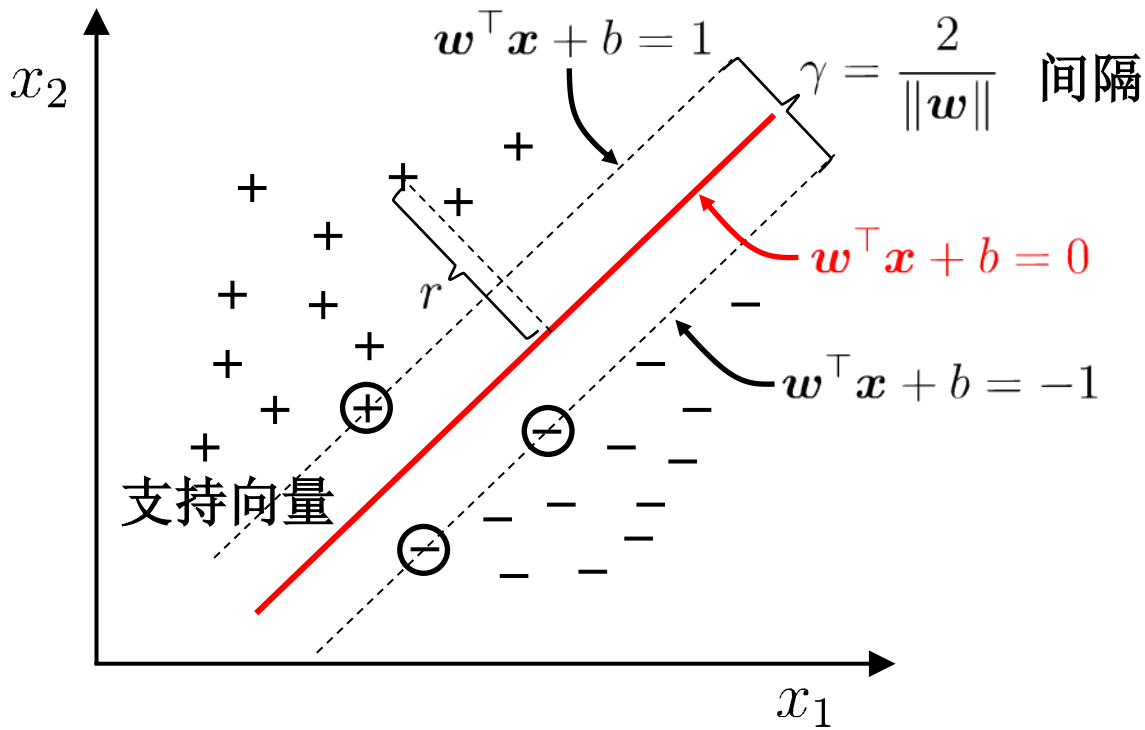

对于大样本数据集的计算量太大

2 对偶问题：求解 -- SMO

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j x_i^T x_j \quad \text{s.t.} \boxed{\sum_{i=1}^{m} \alpha_i y_i = 0}$$

- 基本思路：不断执行如下两个步骤直至收敛.
  - 第一步：选取一对需更新的变量α_i和 α_j.
  - 第二步：固定α_i和 α_j以外的参数, 求解对偶问题更新α_i和 α_j.

- 仅考虑α_i和 α_j时, 对偶问题的约束变为

$$\boxed{\alpha_i y_i + \alpha_j y_j = -\sum_{k \neq i,j} \alpha_k y_k,} \quad \alpha_i \geq 0, \quad \alpha_j \geq 0.$$

- 偏移项b：通过支持向量来确定.

Sequential Minimal Optimization

2 对偶问题：求解 -- SMO

算法流程：每次选取两个α进行更新

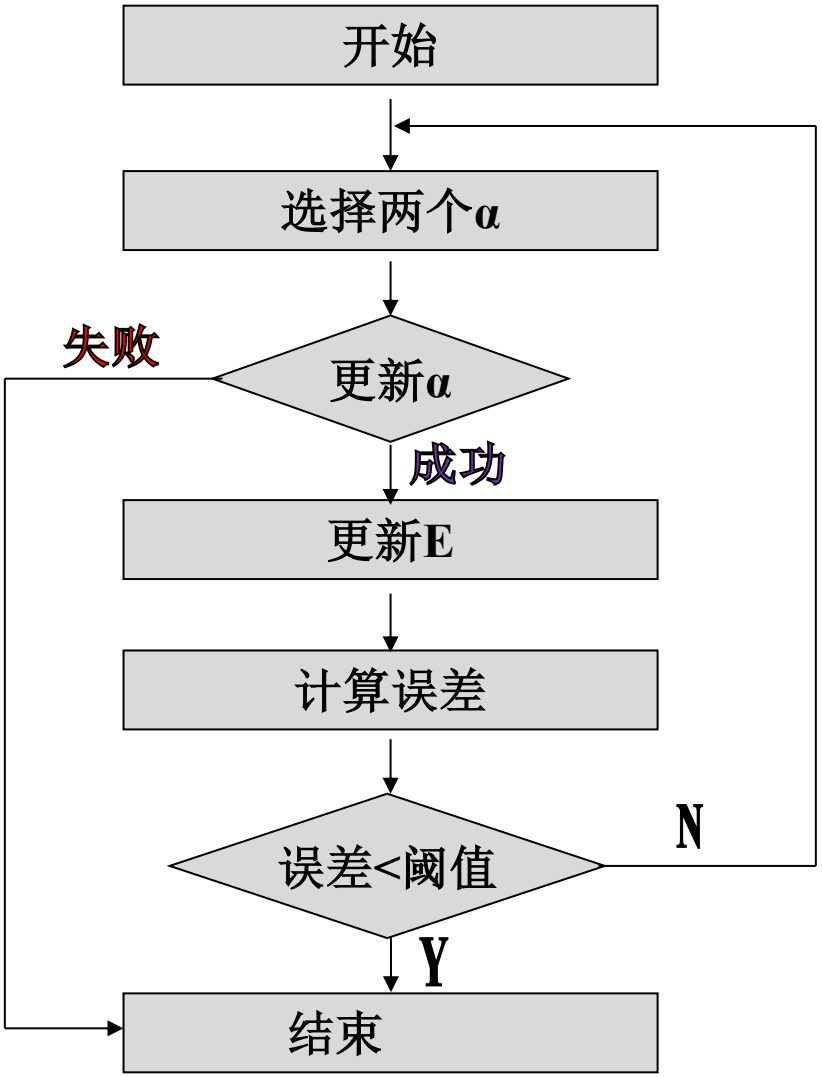

$$\alpha_2^{new} = \alpha_2^{old} - (E_1 - E_2) y_2 / \eta$$

$$\alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new})$$

$$\eta = -x_1^T x_1 + 2 x_1^T x_2 - x_2^T x_2$$

为什么要选取两个？

如果选取一个，则该变量可以通过其它变量和约束条件联合求得

$$\sum_{i=1}^{m} \alpha_i y_i = 0$$

Sequential Minimal Optimization

2 对偶问题：求解 -- SMO

假设最优解为：$\alpha^* = (\alpha_1^*, .., \alpha_n^*)$

可得：

$$w^* = \Sigma_{i=1}^{m} \alpha_i^* y_i x_i$$

$$b^* = y_j - \Sigma_{i=1}^{m} \alpha_i^* y_i x_i x_j$$

得到分类平面：$f(x) = w^* x + b^*$

大纲

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归

3 核函数：线性不可分–高维可分

-Q: 若不存在一个能正确划分两类样本的超平面, 怎么办?

-A: 将样本从原始空间映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分.

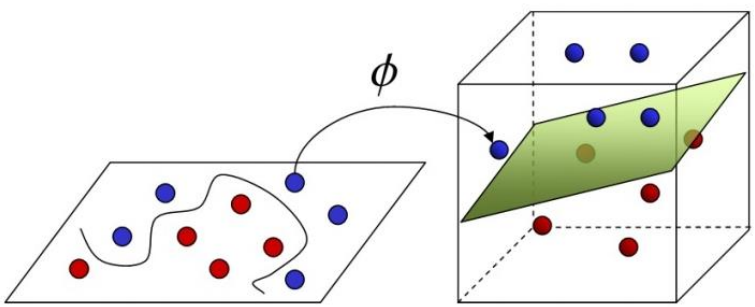

$$\boldsymbol{x} \mapsto \phi(\boldsymbol{x})$$

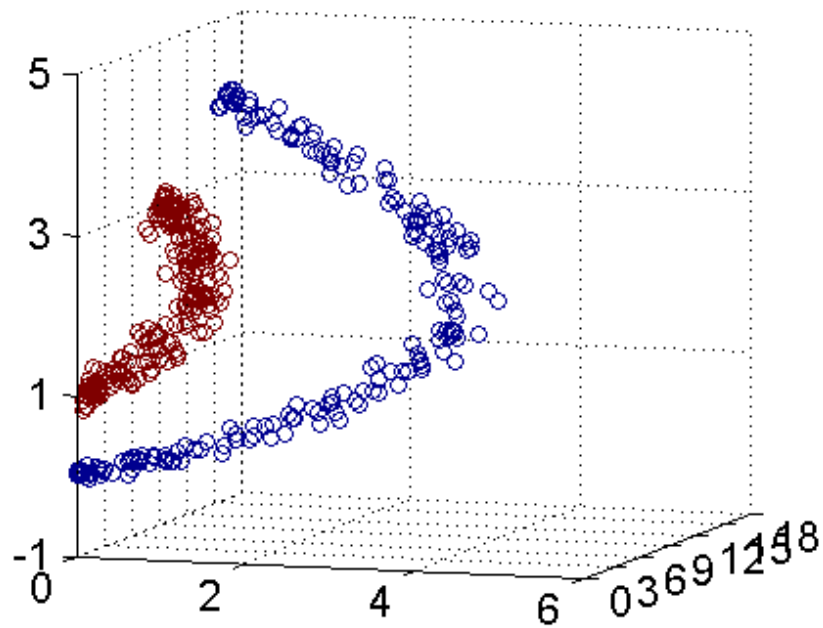

3 核函数

SVM核方法--这是我见过最好的一个视频。。核技巧核函数_哔哩哔哩_bilibili

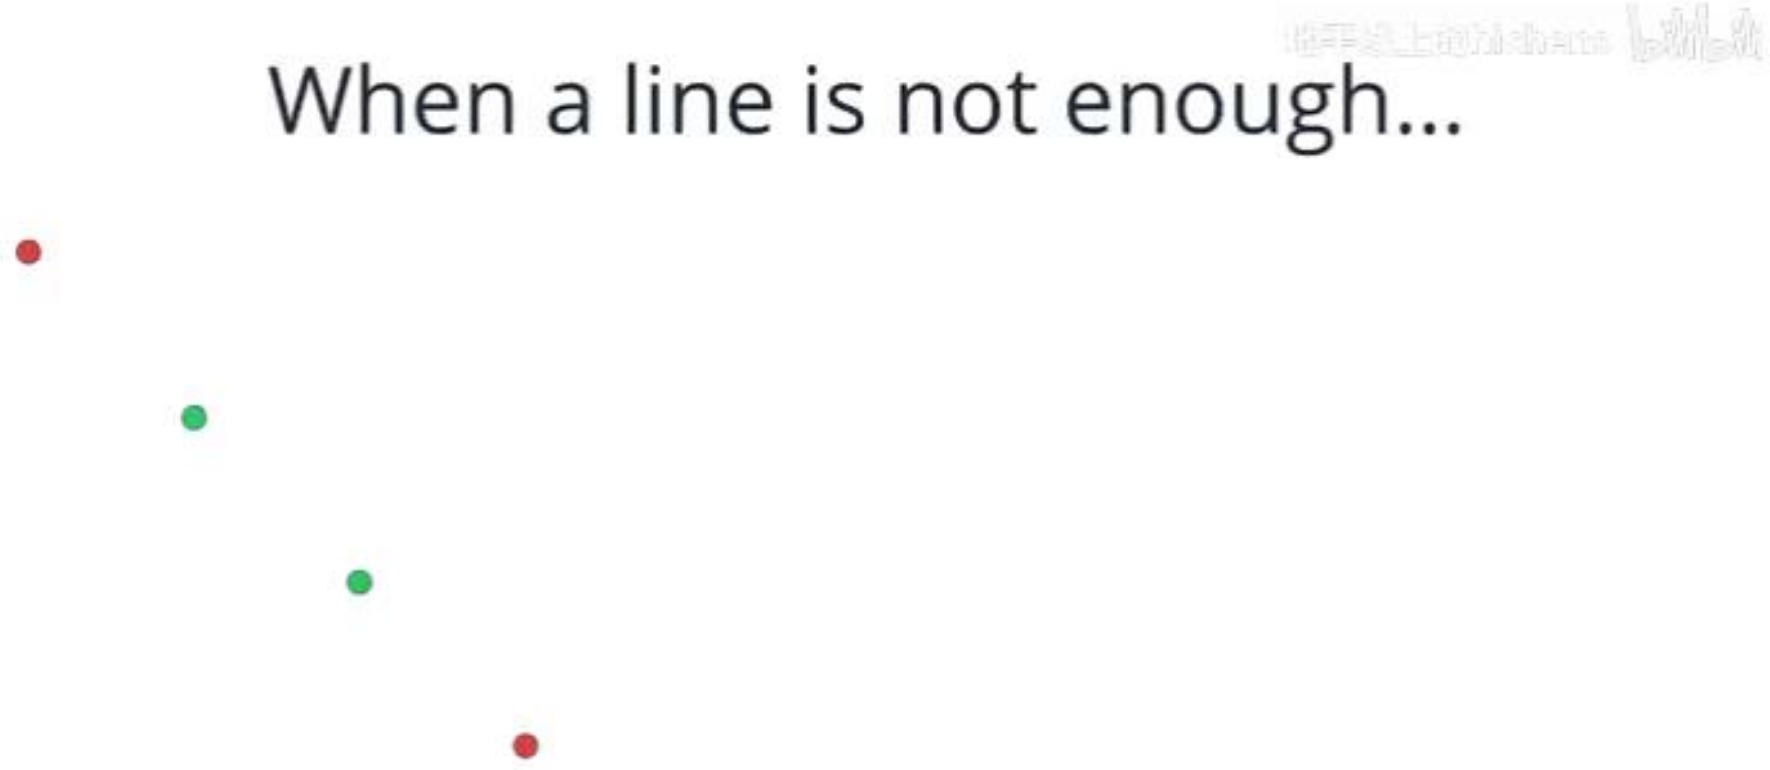

3 核函数：线性不可分–高维可分

变换：$\mathrm{x} \to \phi(x)$

例如：　$ax_1^2 + bx_2^2 + cx_1x_2 = 1$

映射：$\Rightarrow w_1z_1 + w_2z_2 + w_3z_3 + b = 0$

ϕ：$\mathrm{R}^2 \to \mathrm{R}^3$，$(x_1, x_2) \leftrightarrow (z_1, z_2, z_3) \coloneqq \left(x_1^2, \sqrt{2}x_1x_2, x_2^2\right)$

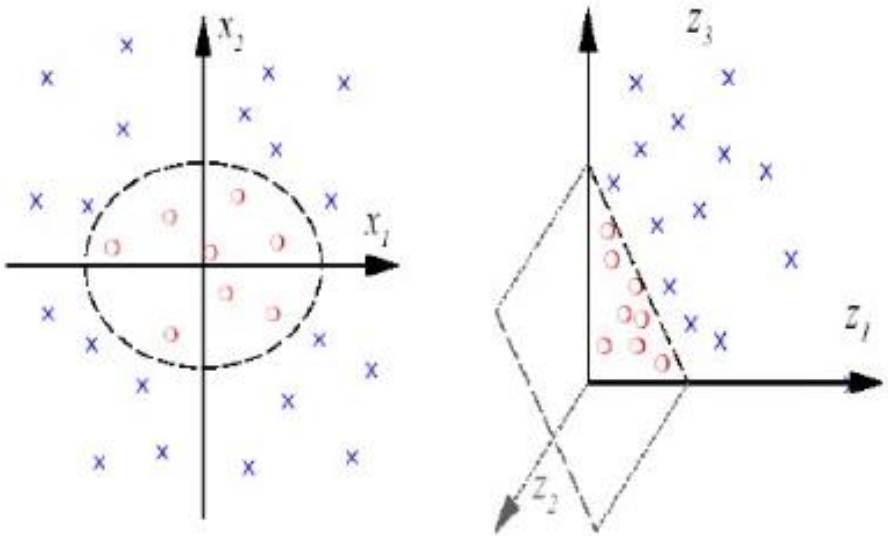

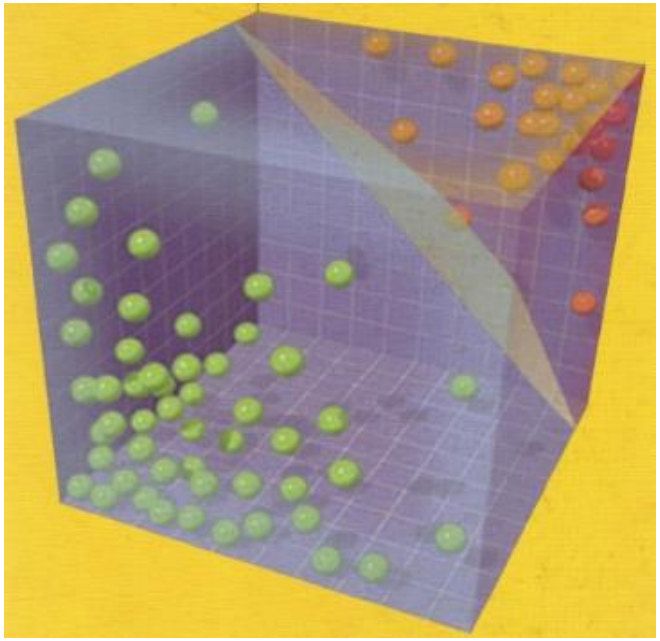

3 核函数：核支持向量机

- 设样本x映射后的向量为$\phi(x)$, 划分超平面为$f(x)=w^T\phi(x)+b$

线性可分的对偶问题

$$\min_{\boldsymbol{\alpha}} \ \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \boxed{\boldsymbol{x}_i^\top \boldsymbol{x}_j} - \sum_{i=1}^{m}\alpha_i$$

$$\text{s.t.} \ \sum_{i=1}^{m}\alpha_i y_i = 0, \ \alpha_i \geq 0, \ i = 1, 2, \ldots, m.$$

映射后的对偶问题

$$\min_{\boldsymbol{\alpha}} \ \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \boxed{\phi(\boldsymbol{x}_i)^\top \phi(\boldsymbol{x}_j)} - \sum_{i=1}^{m}\alpha_i$$

$$\text{s.t.} \ \sum_{i=1}^{m}\alpha_i y_i = 0, \ \alpha_i \geq 0,$$

只以内积的形式出现

预测

$$f(\boldsymbol{x}) = \boldsymbol{w}^\top \phi(\boldsymbol{x}) + b = \sum_{i=1}^{m}\alpha_i y_i \boxed{\phi(\boldsymbol{x}_i)^\top \phi(\boldsymbol{x})} + b$$

$\phi(x)$怎么找？

引入核函数： $\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \phi(\boldsymbol{x}_i)^\top \phi(\boldsymbol{x}_j)$

3 核函数

引入核函数： $\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \phi(\boldsymbol{x}_i)^\top \phi(\boldsymbol{x}_j)$

$$\min_{\boldsymbol{\alpha}} \quad \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \boxed{\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j)} - \sum_{i=1}^{m}\alpha_i$$

$$\text{s.t.} \quad \sum_{i=1}^{m}\alpha_i y_i = 0, \ \ \alpha_i \geq 0, \ \ i = 1, 2, \ldots, m.$$

$$f(\boldsymbol{x}) = \boldsymbol{w}^\top \phi(\boldsymbol{x}) + b = \sum_{i=1}^{m}\alpha_i y_i \boxed{\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j)} + b$$

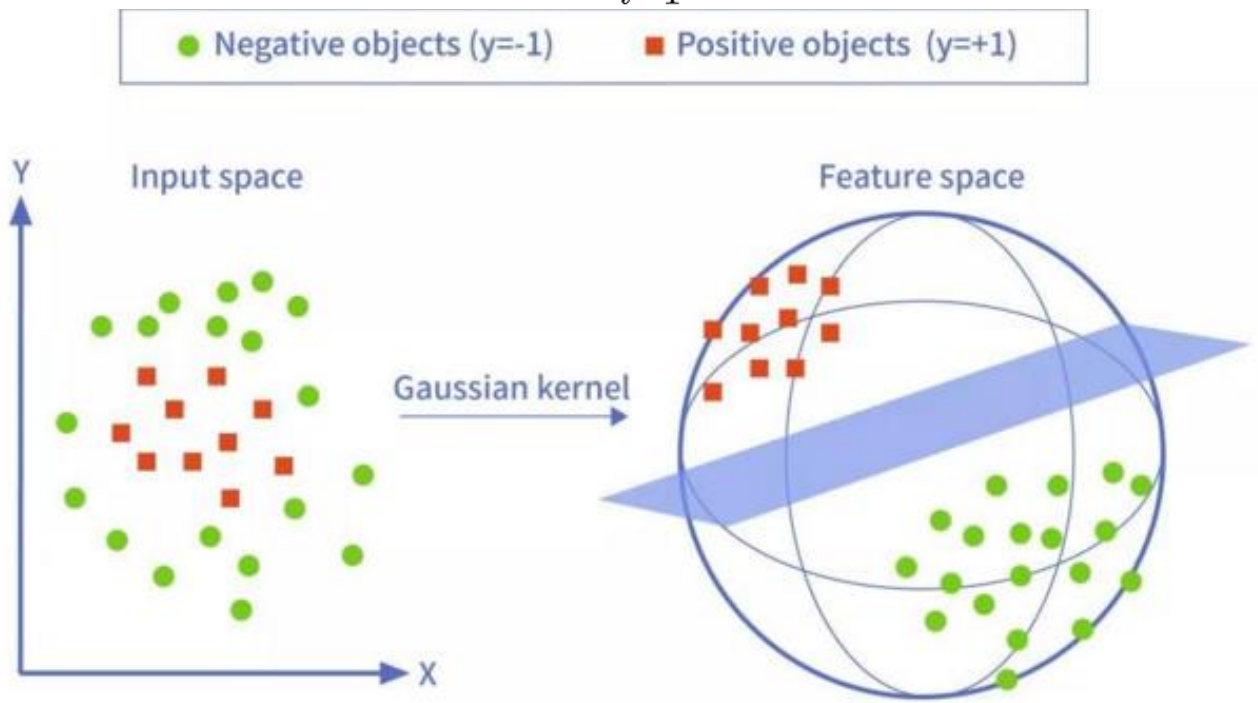

3 核函数

- 基本想法：不显式地构造核映射, 而是设计核函数.

$$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \phi(\boldsymbol{x}_i)^\top \phi(\boldsymbol{x}_j)$$

- Mercer定理(充分非必要)：只要对称函数值所对应的核矩阵半正定, 则该函数可作为核函数.

——距离函数
任何一个核函数，都隐式对应了一个空间

$$D = \begin{bmatrix} (x_1,x_1) & (x_1,x_2) & \dots & (x_1,x_m) \\ (x_2,x_1) & (x_2,x_2) & \dots & (x_2,x_m) \\ \dots & \dots & \dots & \dots \\ (x_m,x_1) & (x_m,x_2) & \dots & (x_m,x_m) \end{bmatrix}$$

$$D = \begin{bmatrix} \kappa(x_1,x_1) & \kappa(x_1,x_2) & \dots & \kappa(x_1,x_m) \\ \kappa(x_2,x_1) & \kappa(x_2,x_2) & \dots & \kappa(x_2,x_m) \\ \dots & \dots & \dots & \dots \\ \kappa(x_m,x_1) & \kappa(x_m,x_2) & \dots & \kappa(x_m,x_m) \end{bmatrix}$$

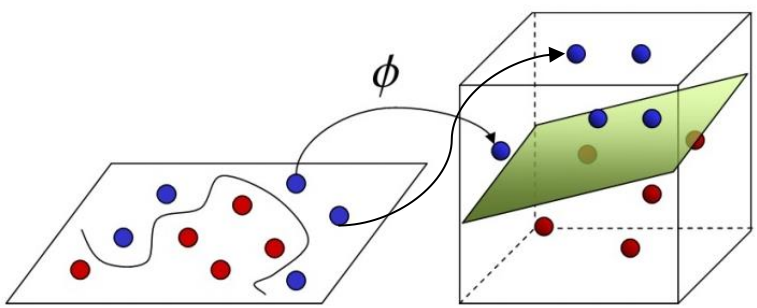

仍然可用SMO算法求解！

3 核函数

- 常用核函数：

名称	表达式	参数
线性核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \boldsymbol{x}_i^\top \boldsymbol{x}_j$	
多项式核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = (\boldsymbol{x}_i^\top \boldsymbol{x}_j)^d$	$d \geq 1$为多项式的次数
高斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\lVert \boldsymbol{x}_i - \boldsymbol{x}_j \rVert^2}{2\delta^2}\right)$	$\delta > 0$为高斯核的带宽(width)
拉普拉斯核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp\left(-\frac{\lVert \boldsymbol{x}_i - \boldsymbol{x}_j \rVert}{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) = \tanh(\beta \boldsymbol{x}_i^\top \boldsymbol{x}_j + \theta)$	tanh为双曲正切函数, $\beta > 0$, $\theta < 0$

核函数的选择——SVM性能决定性的因素！

大纲

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归

4 软间隔与正则化

-Q:实际应用中，很难选择合适的核函数，使样本在特征空间中线性可分；此外，线性可分的结果也很难断定是否是由过拟合造成的.

-A:引入“软间隔”的概念，允许SVM在一些样本上不满足约束.

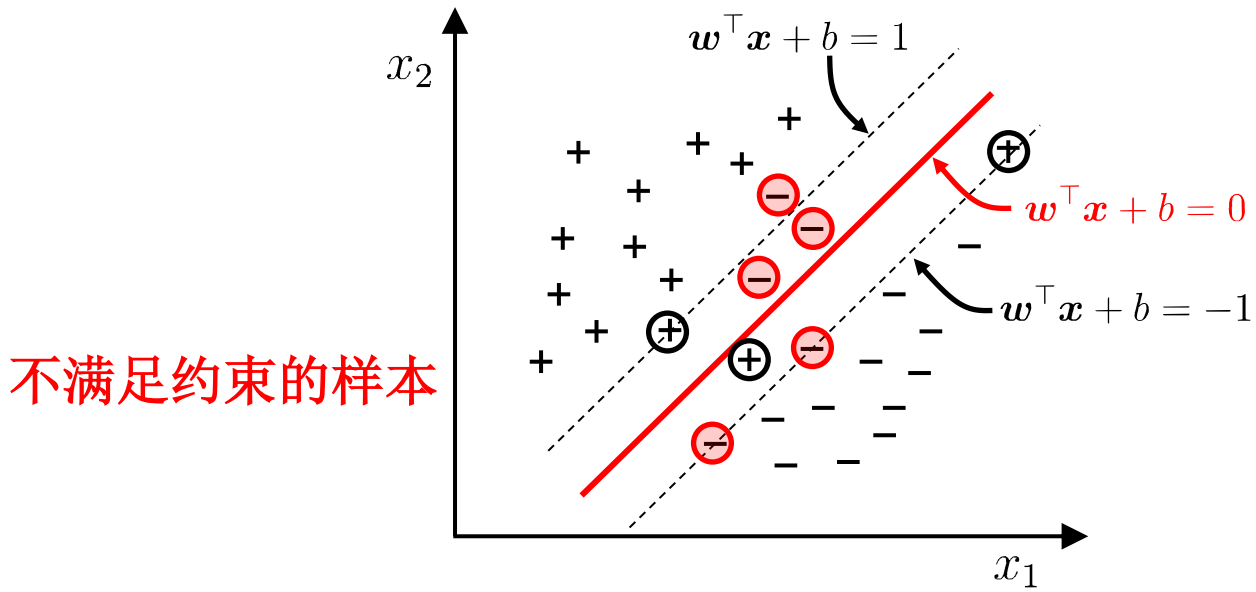

部分样本允许： $y_i(\mathrm{w}^T x + b) \geq 1 \Rightarrow y_i(\mathrm{w}^\mathrm{T}\mathrm{x} + \mathrm{b}) \geq 1 - \epsilon$ ϵ称为松弛变量

4 软间隔与正则化：损失函数

- 基本思路：最大化间隔的同时, 让不满足约束的样本应尽可能少.

$$\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m} l_{0/1}\left(y_i\left(\boldsymbol{w}^\top \boldsymbol{x}_i + b\right) - 1\right)$$

其中C>0为惩罚参数；$l_{0/1}$是”0/1损失函数”

$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

不满足约束条件的样本

- 存在问题：0/1损失函数非凸、非连续, 不易优化！

替代损失

4 软间隔与正则化：Hinge Loss

原始问题

$$\min_{\boldsymbol{w},b} \ \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}\max\left(0, 1 - y_i(\boldsymbol{w}^\top\phi(\boldsymbol{x}_i) + b)\right)$$

对偶问题

$$\min_{\boldsymbol{\alpha}} \ \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}\alpha_i\alpha_j y_i y_j \phi(\boldsymbol{x}_i)^\top\phi(\boldsymbol{x}_j) - \sum_{i=1}^{m}\alpha_i$$

$$\text{s.t.} \ \sum_{i=1}^{m}\alpha_i y_i = 0, \ 0 \le \alpha_i \le \boxed{C,} \ i = 1, 2, \ldots, m.$$

根据KKT条件可推得最终模型仅与支持向量有关, 也即hinge损失函数依然保持了支持向量机解的稀疏性.

4 软间隔与正则化

- 支持向量机学习模型的更一般形式

$$\min_{f} \ \Omega(f) + C\sum_{i=1}^{m} l(f(\boldsymbol{x}_i), y_i)$$

结构风险，描述模型的某些性质

经验风险，描述模型与训练数据的契合程度

- 通过替换上面两个部分, 可以得到许多其他学习模型
  - 对数几率回归(Logistic Regression)
  - 最小绝对收缩选择算子(LASSO)
  - ……

大纲

- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归

5 支持向量回归

特点: 允许模型输出和实际输出间存在2ε的偏差.

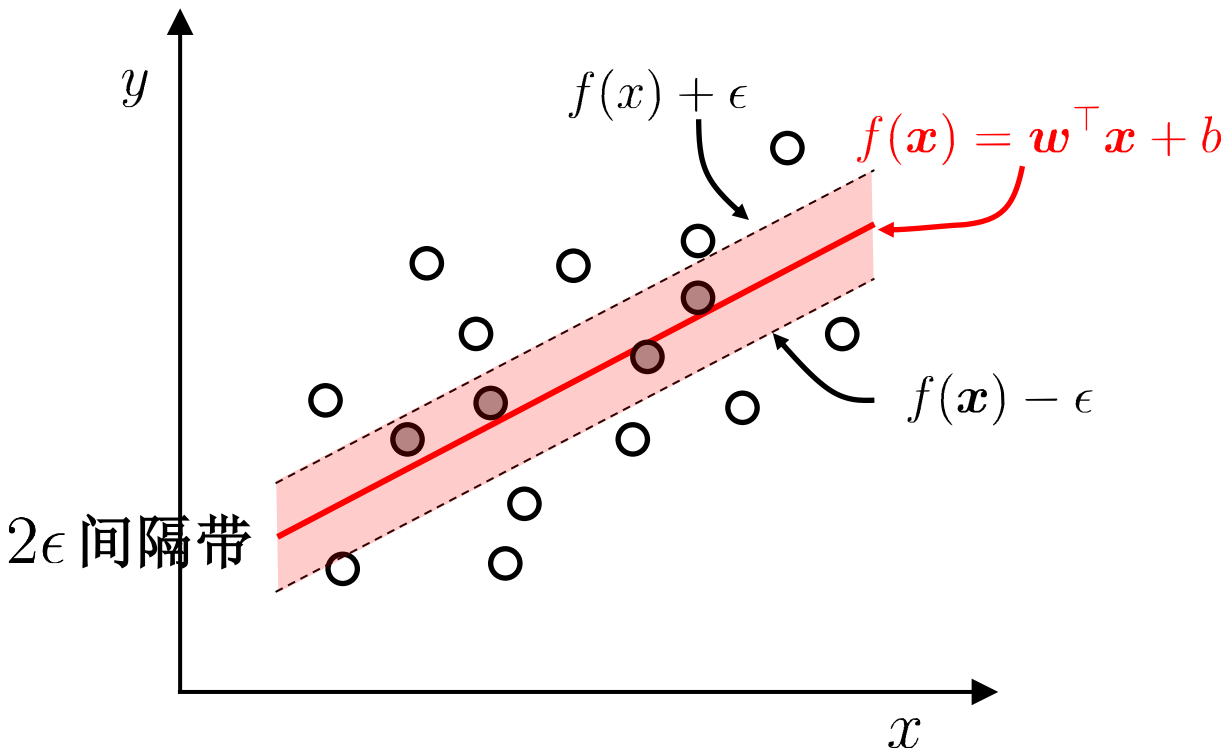

5 支持向量回归:损失函数

落入中间2ε间隔带的样本不计算损失, 从而使得模型获得稀疏性.

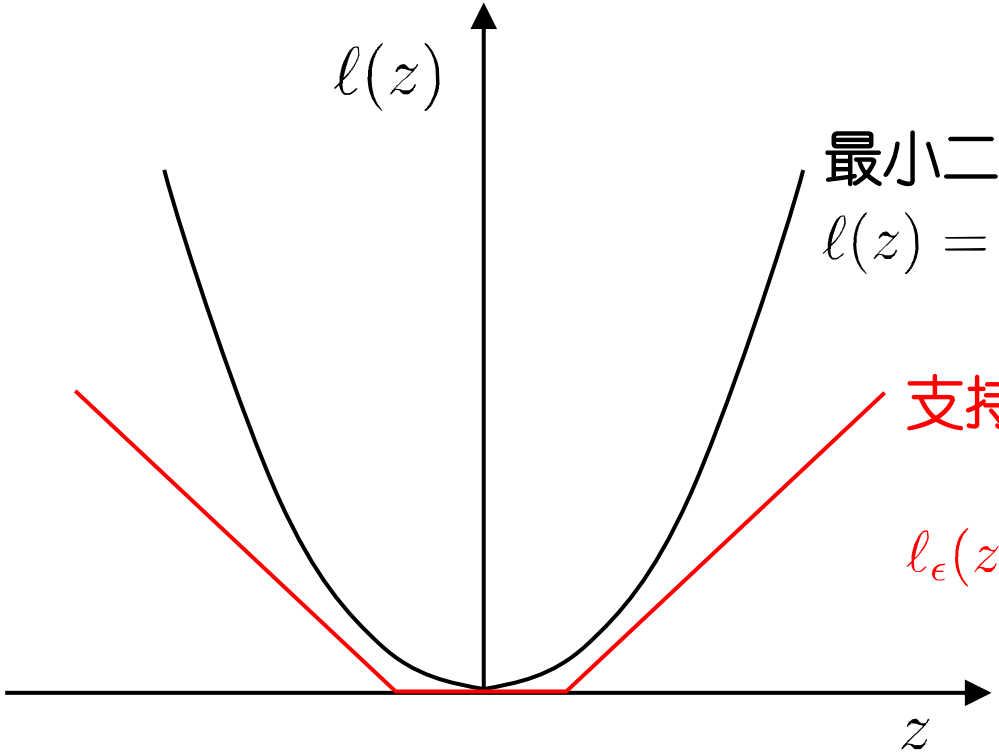

最小二乘损失函数

$$\ell(z) = z^2$$

支持向量回归损失函数

$$\ell_\epsilon(z) = \begin{cases} 0 & \text{if } |z| \le \epsilon \\ |z| - \epsilon & \text{otherwise} \end{cases}$$

5 支持向量回归:形式化

原始问题

$$\begin{aligned}\min_{\boldsymbol{w},b,\xi_i,\hat{\xi}_i} \quad & \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_{i=1}^{m}(\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & y_i - \boldsymbol{w}^\top\phi(\boldsymbol{x}_i) - b \le \epsilon + \xi_i, \\ & y_i - \boldsymbol{w}^\top\phi(\boldsymbol{x}_i) - b \ge -\epsilon - \hat{\xi}_i, \\ & \xi_i \ge 0,\ \hat{\xi}_i \ge 0,\ i = 1, 2, \ldots, m.\end{aligned}$$

对偶问题

$$\begin{aligned}\min_{\boldsymbol{\alpha},\hat{\boldsymbol{\alpha}}} \quad & \frac{1}{2}\sum_{i=1}^{m}\sum_{j=1}^{m}(\alpha_i - \hat{\alpha}_i)(\alpha_j - \hat{\alpha}_j)\kappa(\boldsymbol{x}_i, \boldsymbol{x}_j) + \sum_{i=1}^{m}(\alpha_i(\epsilon - y_i) + \hat{\alpha}_i(\epsilon + y_i)) \\ \text{s.t.} \quad & \sum_{i=1}^{m}(\alpha_i - \hat{\alpha}_i) = 0, \\ & 0 \le \alpha_i \le C,\ 0 \le \hat{\alpha}_i \le C.\end{aligned}$$

预测

$$f(\boldsymbol{x}) = \boldsymbol{w}^\top\phi(\boldsymbol{x}) + b = \sum_{i=1}^{m}(\hat{\alpha}_i - \alpha_i)y_i\kappa(\boldsymbol{x}_i, \boldsymbol{x}) + b$$

训练策略

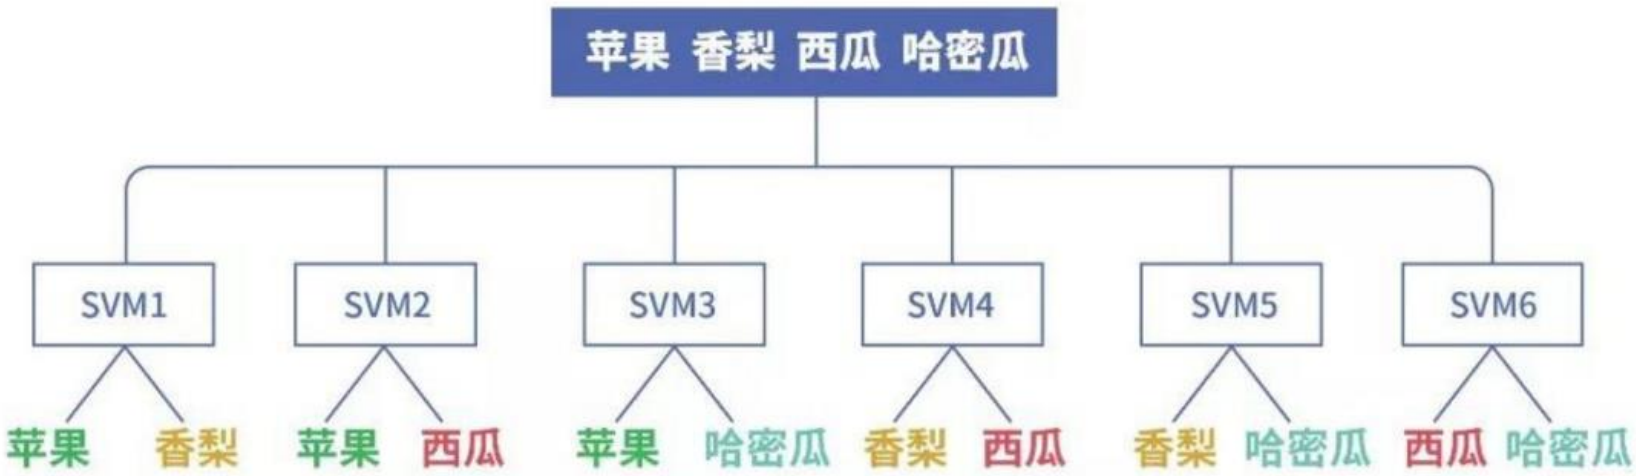
苹果 香梨 西瓜 哈密瓜
SVM1
SVM2
SVM3
SVM4
SVM5
SVM6
苹果 香梨
苹果 西瓜
苹果 哈密瓜
香梨 西瓜
香梨 哈密瓜
西瓜 哈密瓜

训练策略

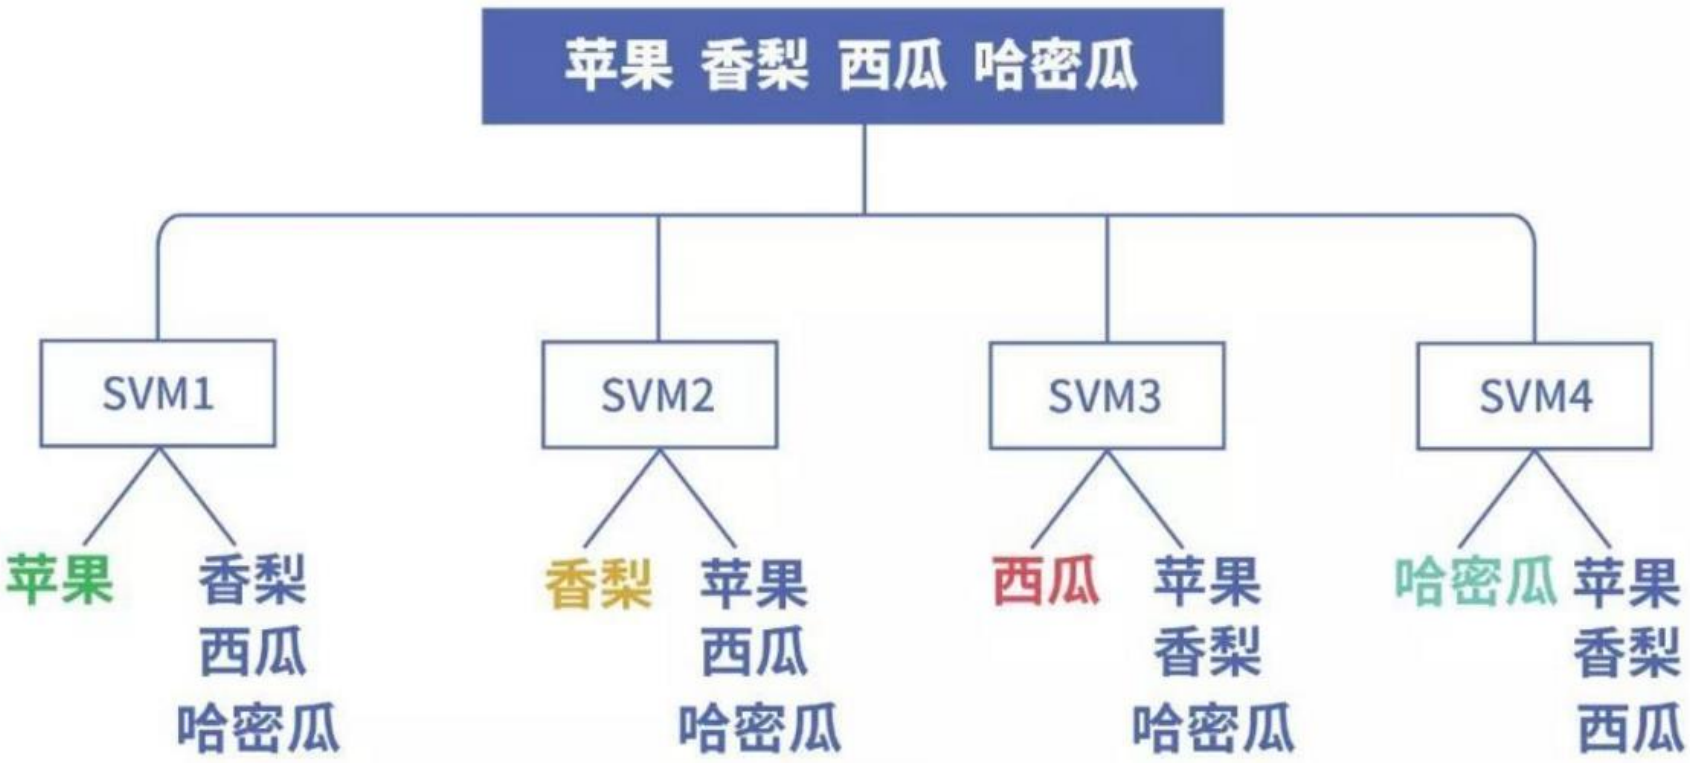
苹果 香梨 西瓜 哈密瓜
SVM1
SVM2
SVM3
SVM4
苹果
香梨
西瓜
哈密瓜
香梨
苹果
西瓜
哈密瓜
西瓜
苹果
香梨
哈密瓜
哈密瓜
苹果
香梨
西瓜
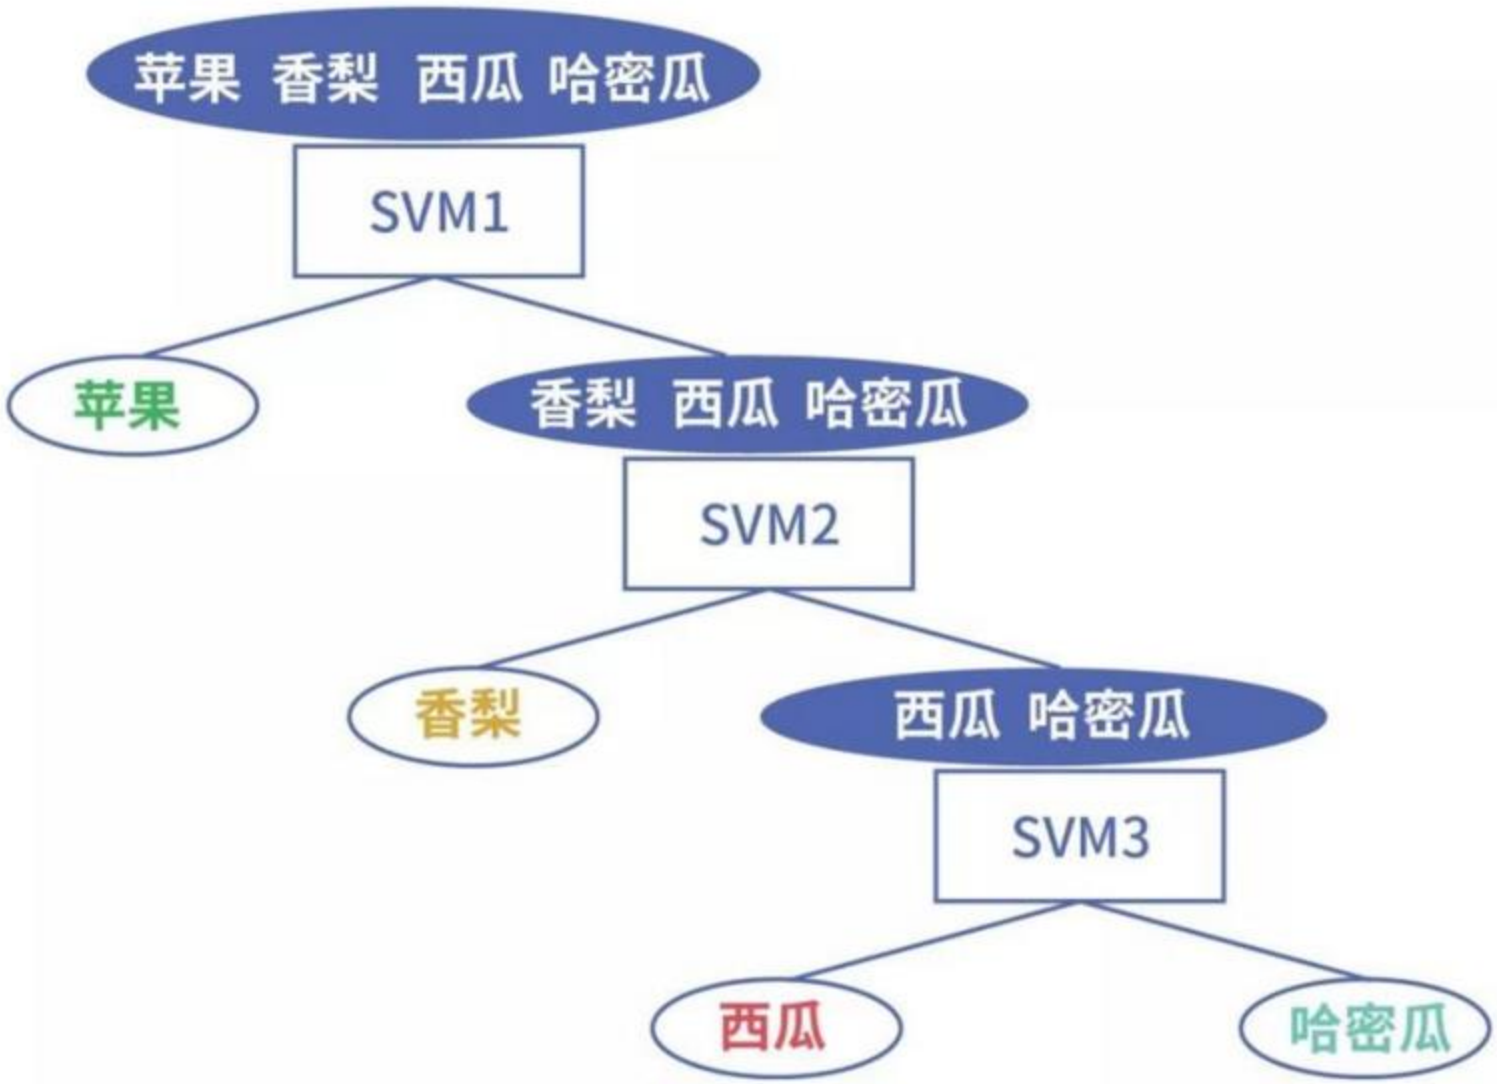
训练策略