第三章：线性模型

复习

- 机器学习的定义和流程
  - P.E.T.
  - LAMBDA：模型/损失函数/算法
- 机器学习方法分类
  - 监督学习（回归、分类）、无监督学习、半监督学习
  - 判别式/产生式
  - 五大主义+
- 基本概念
  - 假设空间；训练集/测试集/验证集；
  - 泛化，欠拟合/过拟合；偏差与方差；泛化误差的分解
- 评价方法和性能指标
  - 留出法，交叉验证，自助法
  - 混淆矩阵， PR曲线，F1度量，ROC曲线，AUC

Machine Learning Methods

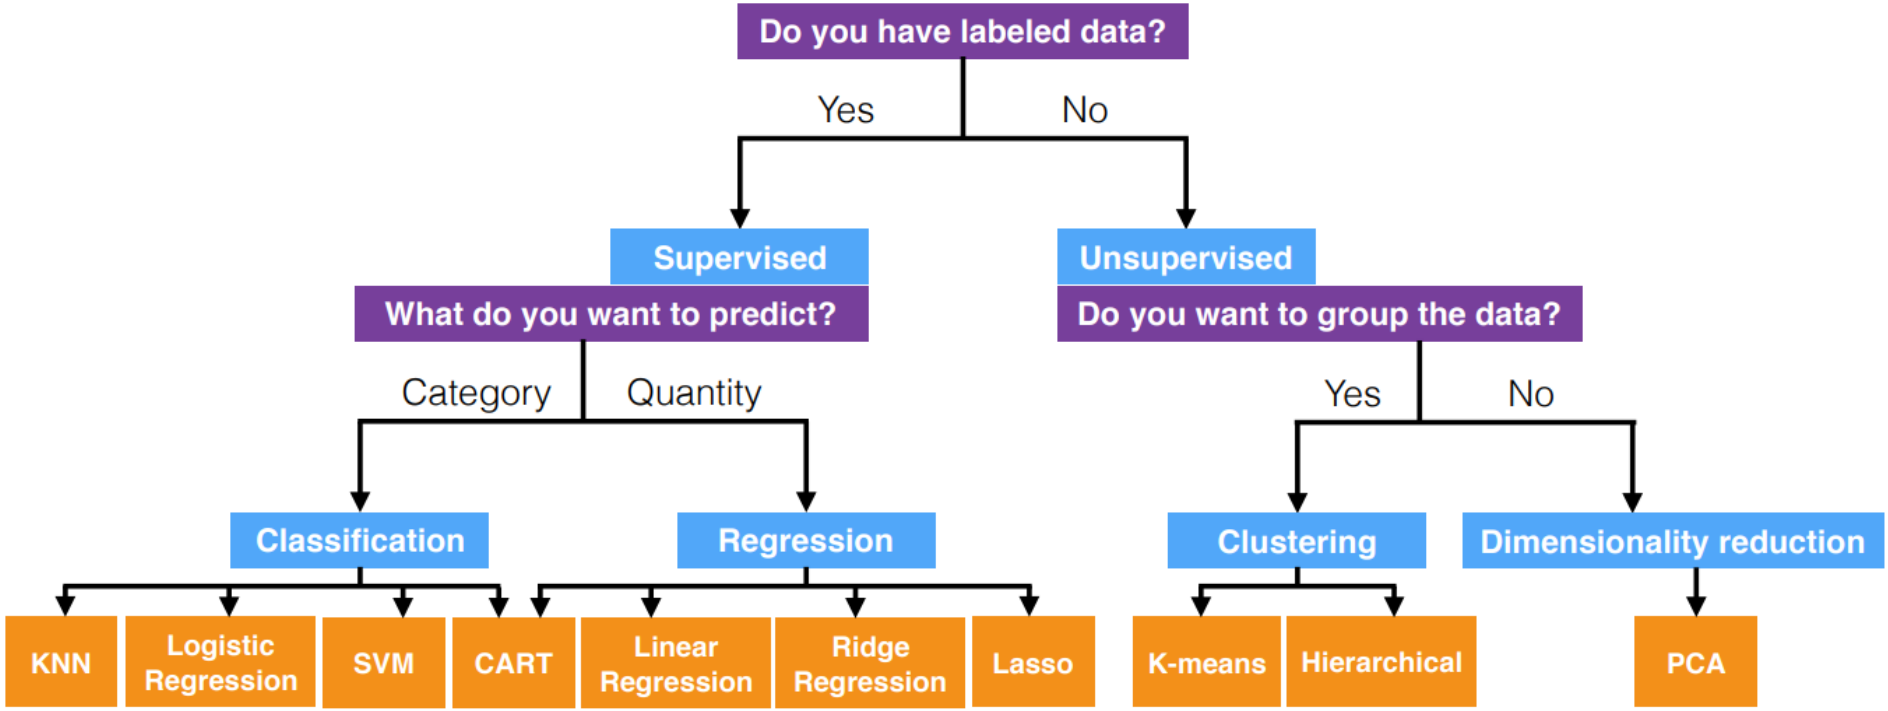

cme250_lecture7 (stanford.edu)

五大主义

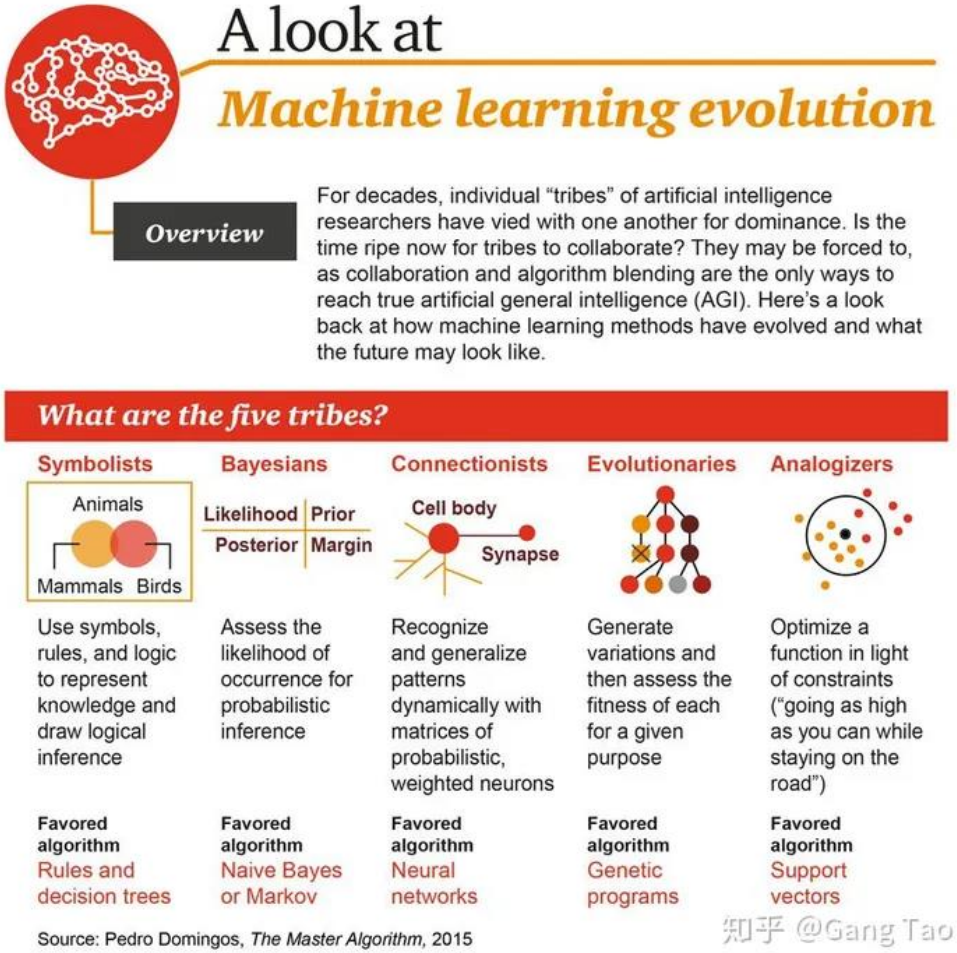
A look at
Machine learning evolution
Overview
For decades, individual "tribes" of artificial intelligence researchers have vied with one another for dominance. Is the time ripe now for tribes to collaborate? They may be forced to, as collaboration and algorithm blending are the only ways to reach true artificial general intelligence (AGI). Here's a look back at how machine learning methods have evolved and what the future may look like.
What are the five tribes?
Symbolists
Animals
Mammals Birds
Use symbols, rules, and logic to represent knowledge and draw logical inference
Favored algorithm
Rules and decision trees
Bayesians
Likelihood Prior
Posterior Margin
Assess the likelihood of occurrence for probabilistic inference
Favored algorithm
Naive Bayes or Markov
Connectionists
Cell body
Synapse
Recognize and generalize patterns dynamically with matrices of probabilistic, weighted neurons
Favored algorithm
Neural networks
Evolutionaries
Generate variations and then assess the fitness of each for a given purpose
Favored algorithm
Genetic programs
Analogizers
Optimize a function in light of constraints ("going as high as you can while staying on the road")
Favored algorithm
Support vectors
Source: Pedro Domingos, The Master Algorithm, 2015
知乎 @Gang Tao

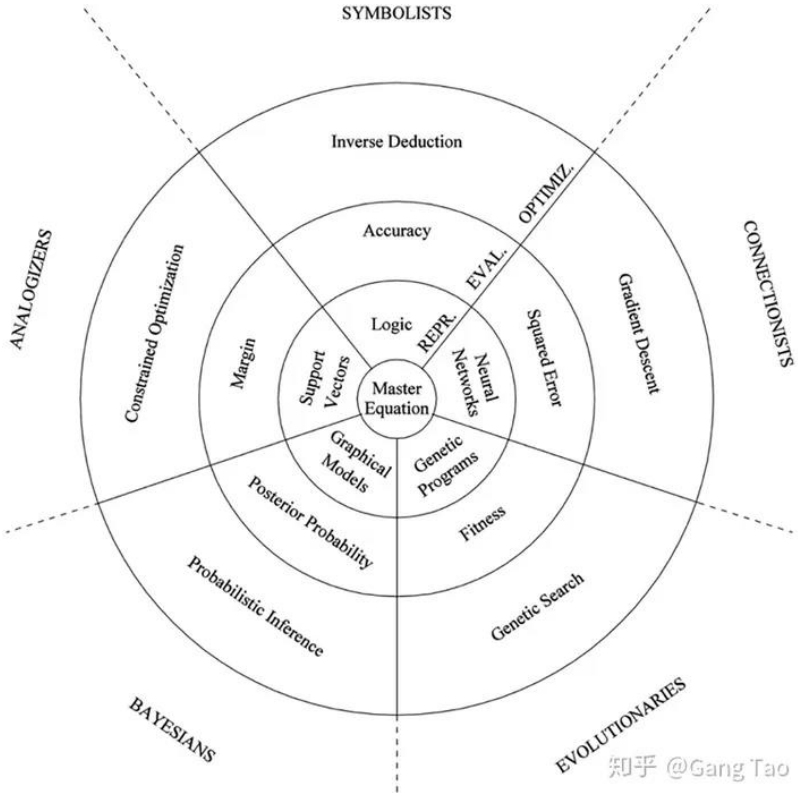
SYMBOLISTS
CONNECTIONISTS
EVOLUTIONARIES
BAYESIANS
ANALOGIZERS
Inverse Deduction
OPTIMIZ.
EVAL.
REPR.
Accuracy
Logic
Master Equation
Support Vectors
Margin
Neural Networks
Squared Error
Gradient Descent
Constrained Optimization
Graphical Models
Genetic Programs
Posterior Probability
Fitness
Probabilistic Inference
Genetic Search
知乎 @Gang Tao

假设空间

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	沉闷	是
3	青绿	硬挺	清脆	否
4	乌黑	稍蜷	沉闷	否

假设空间：(色泽=?)∧(根蒂=?)∧(敲声=?)↔好瓜

色泽（3种）：青绿+乌黑+什么值都合适的情况；

根蒂（4种）：蜷缩+硬挺+稍蜷+什么值都合适的情况；

敲声（4种）：浊响+清脆+沉闷+什么值都合适的情况；

还有一种假设组成——可能"好瓜"这个概念就不成立，用∅表示这种假设。

假设空间大小：3*4*4+1=49

基本术语-偏差与方差

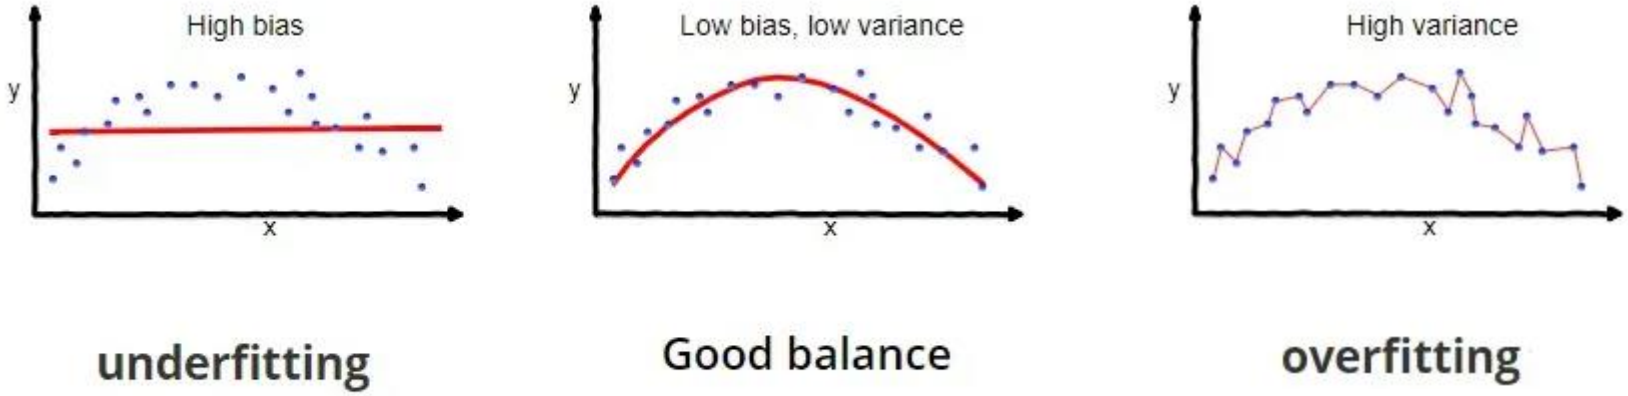

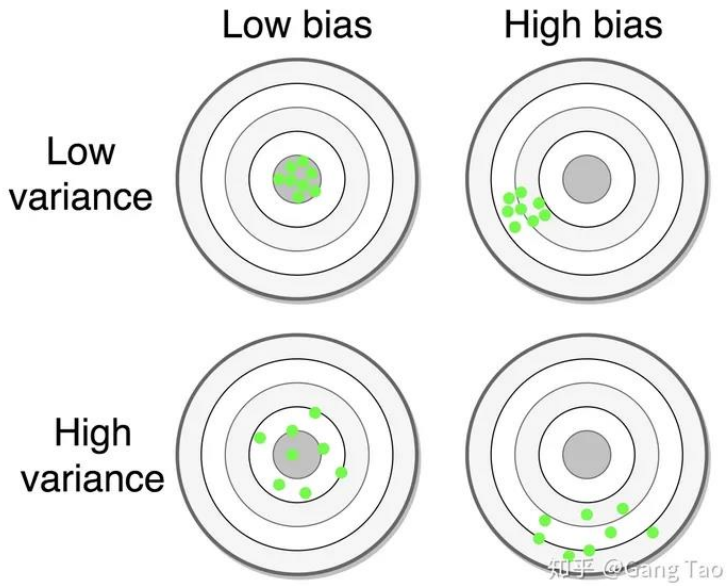

偏差（bias）：描述模型输出结果的期望与样本真实结果的差距。
方差（var）：描述模型对于给定值的输出稳定性。

泛化误差的偏差与方差分解

通过实验可以估计学习算法的泛化性能，而“偏差-方差分解”可以用来帮助解释泛化性能。偏差-方差分解试图对学习算法期望的泛化错误率进行**拆解**。

泛化误差可分解为偏差、方差与噪声之和。

$$\boxed{E(f;D) = bias^2(\boldsymbol{x}) + var(\boldsymbol{x}) + \varepsilon^2}$$

- 偏差，对象是单个模型，度量期望输出与真实结果的偏离程度；即模型对数据的**拟合能力**；
- 方差，对象是多个模型，度量了换同样规模的训练集所导致的学习性能的变化；即刻画了**数据扰动**所造成的影响；
- 噪声表达了在当前任务上任何学习算法所能达到的期望泛化误差的下界；即刻画了学习问题**本身的难度**。

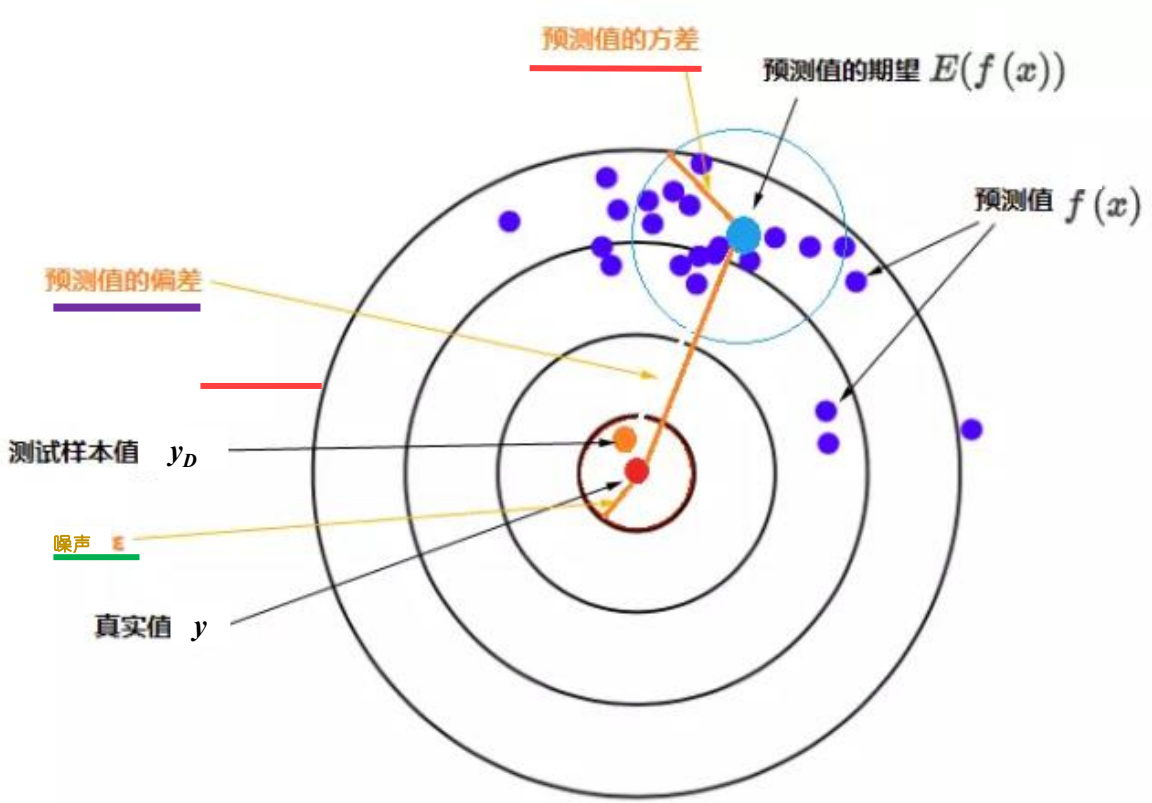

偏差-方差窘境

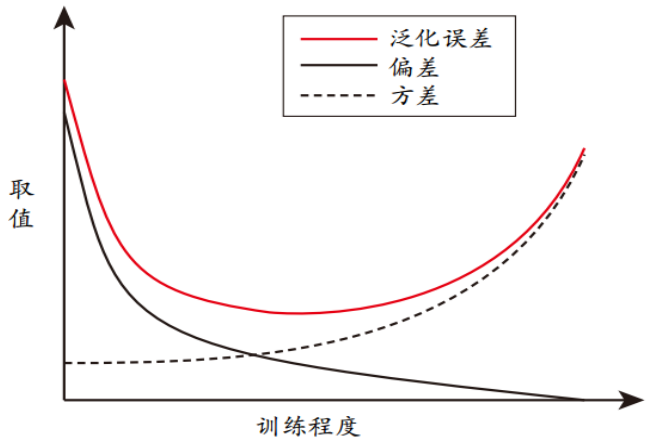

泛化误差与偏差、方差的关系示意图

改进策略	使用场景
采集更多的样本	高方差
降低特征维度	高方差
采集更多的特征	高偏差
进行高次多项式回归(增加模型复杂度)	高偏差
降低正则化项系数 λ	高方差
增大正则化项系数 λ	高偏差

性能度量- P-R曲线、ROC曲线、AUC

1. 混淆矩阵，P-R曲线

分类结果混淆矩阵

真实情况	预测结果	
	正例	反例
正例	TP (真正例)	FN (假反例)
反例	FP (假正例)	TN (真反例)

查准率（精确率）

$$P = \frac{TP}{TP + FP}$$

查全率（召回率）

$$R = \frac{TP}{TP + FN}$$

2.ROC曲线：计算TPR和FPR，得到（TPR1，FPR1）

- 真正例率(True Postive Rate)TPR: TP/(TP+FN),代表分类器预测的正类中实际正实例占所有正实例的比例。
- 假正例率(False Postive Rate)FPR: FP/(FP+TN). 代表分类器预测的正类中实际负实例占所有负实例的比例。

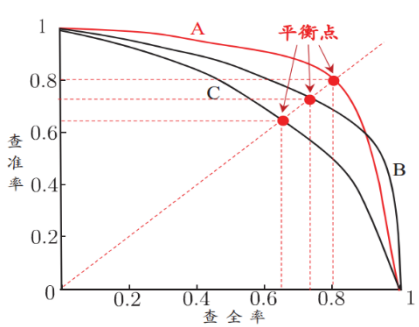

P-R曲线与平衡点示意图

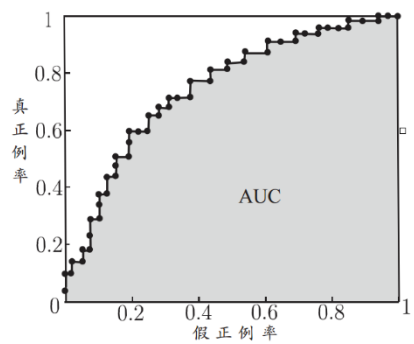

基于有限样例绘制的 ROC 曲线与 AUC

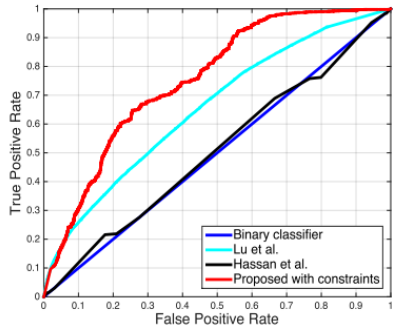

目录

- 线性回归
  - 最小二乘法
- 二分类任务
  - 对数几率回归
  - 线性判别分析
- 多分类任务
  - 一对一
  - 一对其余
  - 多对多
- 类别不平衡问题

3.1基本形式

- 线性模型一般形式

$$f(\boldsymbol{x}) = w_1x_1 + w_2x_2 + \ldots + w_dx_d + b$$

$\boldsymbol{x} = (x_1; x_2; \ldots; x_d)$是由属性描述的示例，其中$x_i$是$\boldsymbol{x}$在第$i$个属性上的取值

- 向量形式

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

其中 $\boldsymbol{w} = (w_1; w_2; \ldots; w_d)$

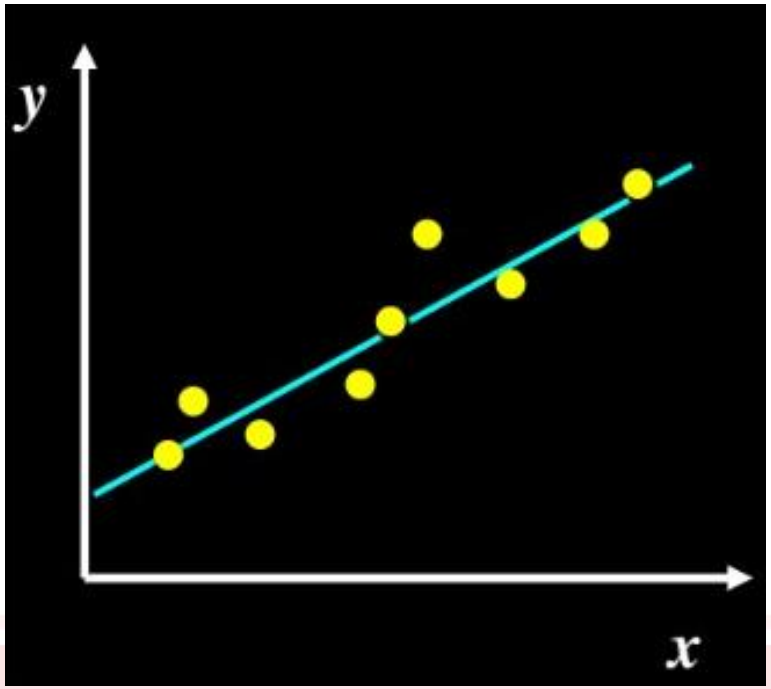

线性模型优点

- 例子
  - 综合考虑色泽、根蒂和敲声来判断西瓜好不好
  - 其中根蒂的系数最大，表明根蒂最要紧；而敲声的系数比色泽大，说明敲声比色泽更重要

$$f_{\text{好瓜}}(\boldsymbol{x}) = \underset{w_1}{\underset{\uparrow}{0.2}} \cdot x_{\text{色泽}} + \underset{w_2}{\underset{\uparrow}{0.5}} \cdot x_{\text{根蒂}} + \underset{w_3}{\underset{\uparrow}{0.3}} \cdot x_{\text{敲声}} + \underset{b}{\underset{\uparrow}{1}}$$

3.2线性回归

- 给定数据集 $D=\{(\boldsymbol{x}_1,y_1),(\boldsymbol{x}_2,y_2),\ldots,(\boldsymbol{x}_m,y_m)\}$

其中 $\boldsymbol{x}_i=(x_{i1};x_{i2};\ldots;x_{id})$, $y_i\in\mathbb{R}$

- 线性回归（linear regression）目的
  - 学得一个线性模型以尽可能准确地预测实值输出标记

$$f(x)=wx_i+b \quad \text{使得} \quad f(x_i)\simeq y_i$$

3.2线性回归

- 离散属性处理
  - 身高：{高，矮}，性别：{男，女}，瓜类：{西瓜，南瓜，黄瓜}
  - 有“序”关系：转化为连续值：
    - 例如：身高->{1.0,0.0}
  - 无“序”关系：有k个属性值，则转换为k维向量：
    - 例如：瓜类->{(0,0,1),(0,1,0),(1,0,0)}

3.2线性回归

线性回归目标

$$f(x) = wx_i + b \quad \text{使得} \quad f(x_i) \simeq y_i$$

参数/模型估计：最小二乘法（least square method）

设任意一个回归值$f(x_i)$实际观察y_i之间存在的误差e_i：则有：

$$(w^*, b^*) = \arg\min \Sigma e_i^2$$

$$(w^*, b^*) = \arg\min_{(w,b)} \sum_{i=1}^{m} (f(x_i) - y_i)^2$$

$$= \arg\min_{(w,b)} \sum_{i=1}^{m} (y_i - wx_i - b)^2$$

3.2线性回归 – 最小二乘法

- 最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^{m} (y_i - wx_i - b)^2$$

- 分别对 w 和 b 求导，可得

$$\frac{\partial E_{(w,b)}}{\partial w} = 2\left(w\sum_{i=1}^{m} x_i^2 - \sum_{i=1}^{m}(y_i - b)\,x_i\right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2\left(mb - \sum_{i=1}^{m}(y_i - wx_i)\right)$$

3.2线性回归 – 最小二乘法

- 得到闭式（closed-form）解

$$w = \frac{\sum_{i=1}^{m} y_i \left(x_i - \bar{x}\right)}{\sum_{i=1}^{m} x_i^2 - \frac{1}{m}\left(\sum_{i=1}^{m} x_i\right)^2}$$

$$b = \frac{1}{m}\sum_{i=1}^{m}\left(y_i - w x_i\right)$$

其中

$$\bar{x} = \frac{1}{m}\sum_{i=1}^{m} x_i$$

3.2.2 多元线性回归

- 给定数据集

$$D=\{(\boldsymbol{x}_1,y_1),(\boldsymbol{x}_2,y_2),\ldots,(\boldsymbol{x}_m,y_m)\}$$

$$\boldsymbol{x}_i=(x_{i1};x_{i2};\ldots;x_{id})\quad y_i\in\mathbb{R}$$

- 多元线性回归目标

$$f(\boldsymbol{x}_i)=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i+b \text{ 使得} f(\boldsymbol{x}_i)\simeq y_i$$

$$\Downarrow$$

$$f(\hat{\boldsymbol{x}})=\hat{\boldsymbol{w}}^{\mathrm{T}}\hat{\boldsymbol{x}}$$

3.2.2 多元线性回归

- 把$\boldsymbol{w}$和 b 吸收入向量形式 $\hat{\boldsymbol{w}} = (\boldsymbol{w}; b)$，数据集表示为

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1^{\mathrm{T}} & 1 \\ \boldsymbol{x}_2^{\mathrm{T}} & 1 \\ \vdots & \vdots \\ \boldsymbol{x}_m^{\mathrm{T}} & 1 \end{pmatrix}$$

$$\boldsymbol{y} = (y_1; y_2; \ldots; y_m)$$

3.2.2 多元线性回归 – 最小二乘法

- 最小二乘法（least square method）

$$\hat{\boldsymbol{w}}^* = \arg\min_{\hat{w}} \left(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}^{\mathrm{T}}\right)\left(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}\right)$$

令 $E_{\hat{\boldsymbol{w}}} = \left(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}\right)^{\mathrm{T}}\left(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}\right)$ ，对$\hat{\boldsymbol{w}}$求导得到

$$\frac{\partial E_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 2\mathbf{X}^{\mathrm{T}}\left(\mathbf{X}\hat{\boldsymbol{w}} - \boldsymbol{y}\right)$$

令上式为零可得$\hat{\boldsymbol{w}}$最优解的闭式解

3.2.3 对数线性回归

- 线性回归模型：$f(x) = wx + b$，取合适的w，b值，使得预测值逼近真实标记y

怎么令模型的预测值非线性呢？

- 广义线性回归模型：

$$y = f(x) = wx + b$$

转为：

$$y = g\big(f(x)\big) = g(wx + b)$$

g称为联系函数，单调可微函数

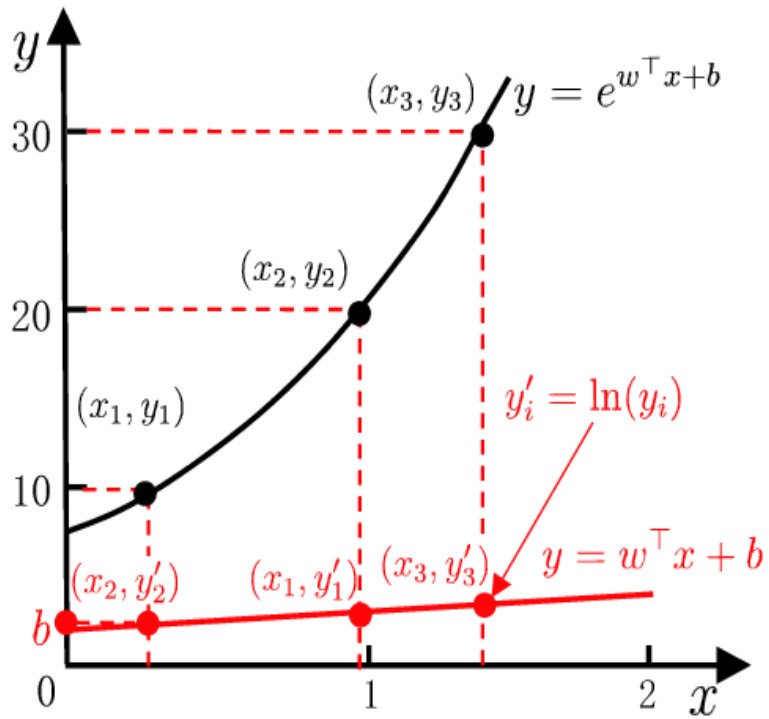

3.2.3 对数线性回归

- g取y的对数，即lny，就可以得到对数线性回归模型：

$$lny = wx + b$$

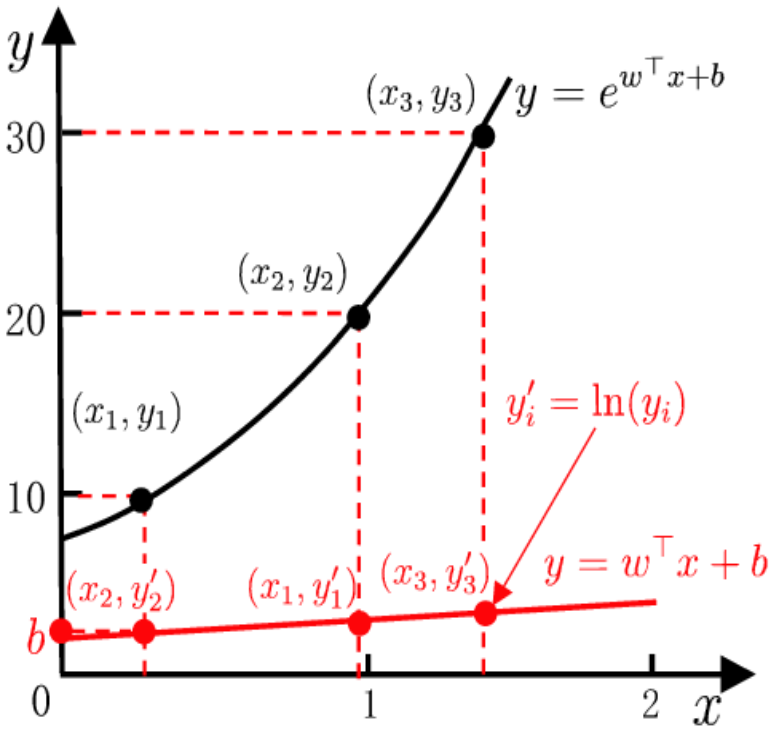

$$y = e^{w^T x+b}$$

$$\Updownarrow$$

$$\ln y = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

$$\Updownarrow$$

$$y = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

3.3对数几率回归-二分类任务

预测值与输出标记

$$z = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b \qquad y \in \{0, 1\} \neq z \in (-\infty, +\infty)$$

寻找函数将分类标记与线性回归模型输出联系起来

单位阶跃函数：

$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$

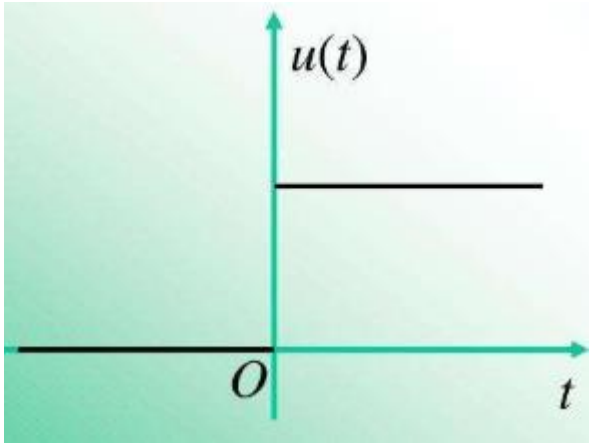

3.3对数几率回归-二分类任务

- 单位阶跃函数缺点
  - 不连续

Sigmoid函数，激活函数

- 替代函数——对数几率函数（logistic function）
  - 单调可微、任意阶可导

$$y = \frac{1}{1+e^{-z}}$$

$$ln\frac{y}{1-y} = w^T x + b$$

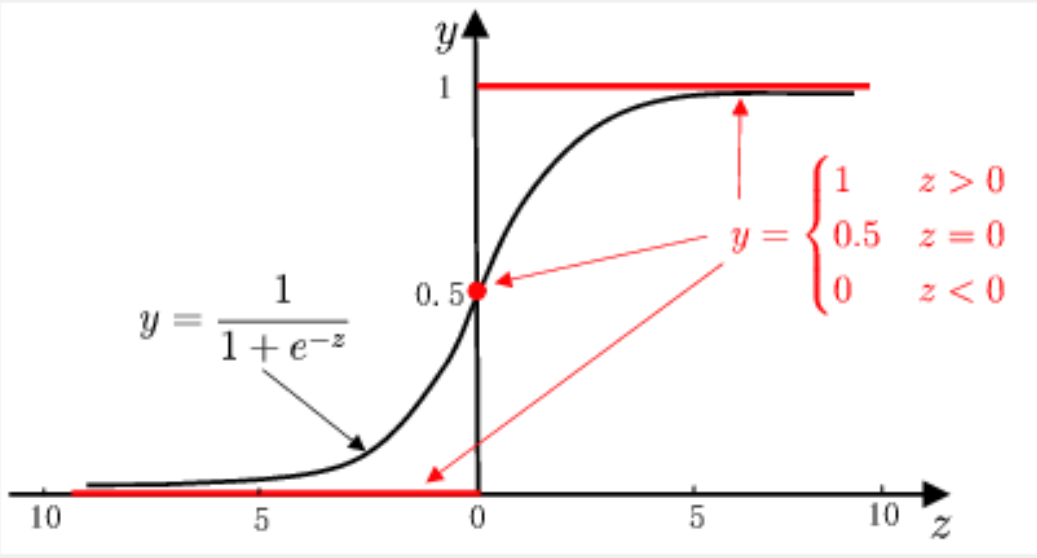

单位阶跃函数与对数几率函数的比较

3.3对数几率回归

- 运用对数几率函数

$$y=\frac{1}{1+e^{-z}} \quad \text{变为} \quad y=\frac{1}{1+e^{-(\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b)}}$$

- 对数几率（log odds）
  - 样本作为正例的相对可能性的对数

$$ln\frac{y}{1-y}$$

- 对数几率回归优点
- 无需事先假设数据分布
- 可得到“类别”的近似概率预测
- 可直接应用现有数值优化算法求取最优解

3.4 二分类任务 – 线性判别分析

- 线性判别分析（Linear Discriminant Analysis）[Fisher, 1936]

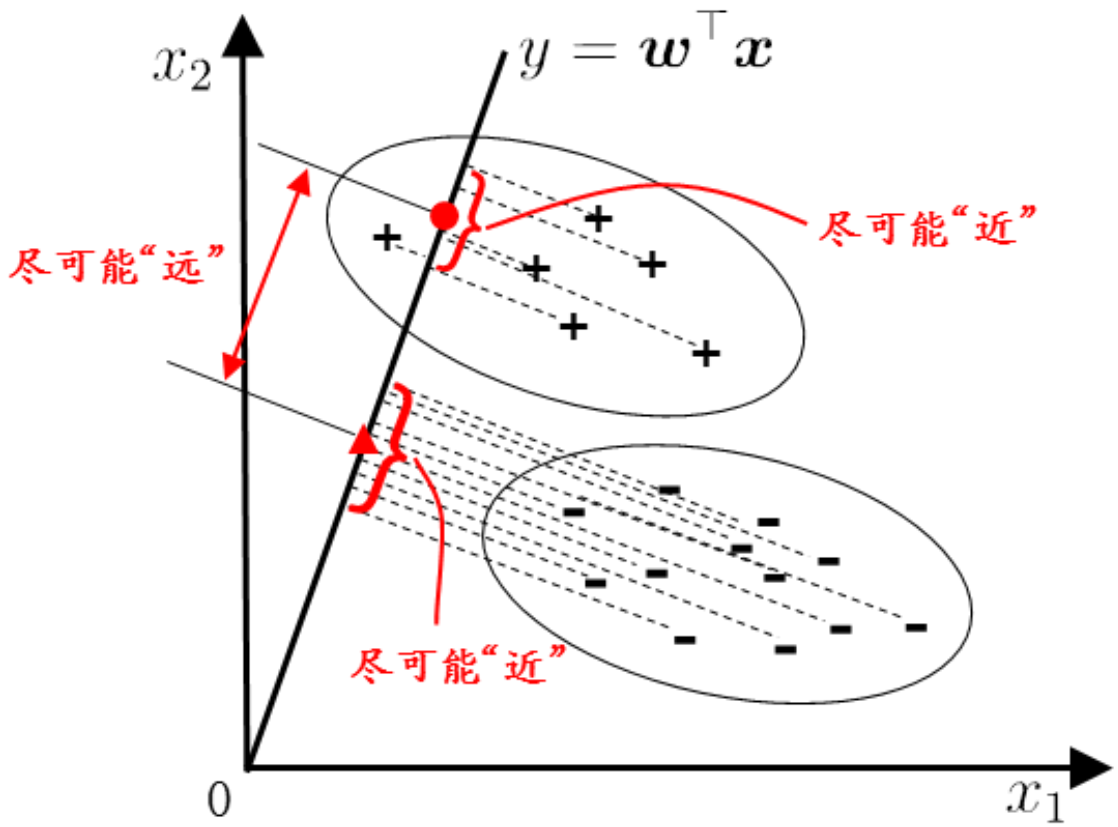

LDA也可被视为一种监督降维技术

3.4 二分类任务 – 线性判别分析

LDA的思想

- 同类样例投影点尽可能接近=>同类样例投影点的协方差尽可能小；
- 异类样例的投影点尽可能远=>类中心之间的距离尽可能大；

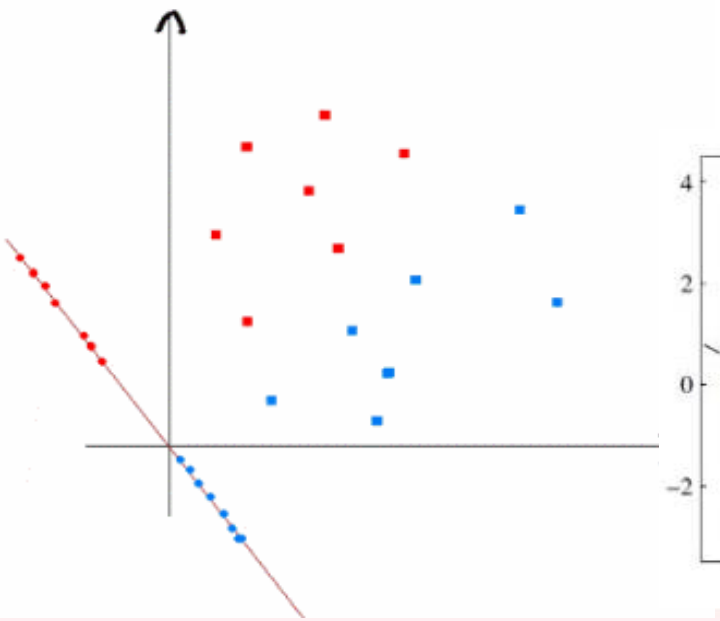

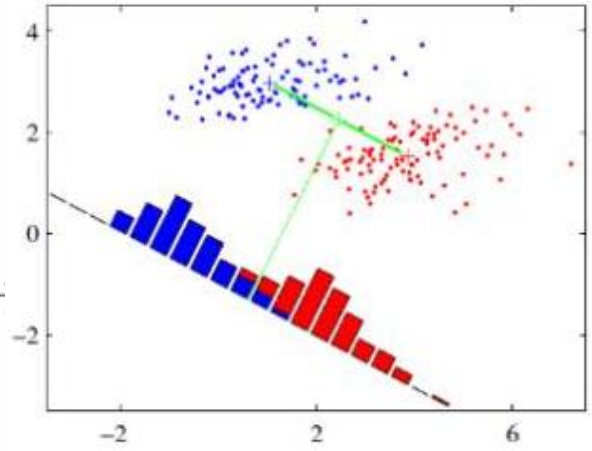

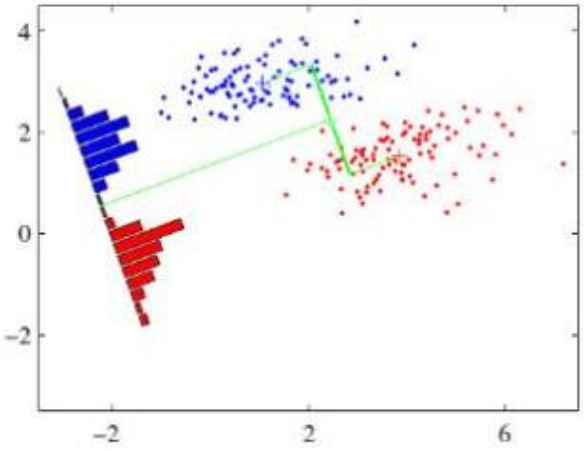

二分类任务 – 线性判别分析

- 定义变量：
  - 第i类示例的集合 X_i
  - 第i类示例的均值向量 $\boldsymbol{\mu}_i$
  - 第i类示例的协方差矩阵 $\boldsymbol{\Sigma}_i$
  - 两类样本的中心在直线上的投影： $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}_0$和 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}_1$
  - 两类样本的协方差： $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}_0\boldsymbol{w}$和 $\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}_1\boldsymbol{w}$

注：协方差矩阵用于描述**同一类**内样本之间的离散程度以及不同特征之间的相关性。

二分类任务 – 线性判别分析

- 最大化目标

$$J = \frac{\left\|\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}_0 - \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\mu}_1\right\|_2^2}{\boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}_0\boldsymbol{w} + \boldsymbol{w}^{\mathrm{T}}\boldsymbol{\Sigma}_1\boldsymbol{w}}$$

类别中心距离

同类样本间距离

$$= \frac{\boldsymbol{w}^{\mathrm{T}}\left(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1\right)\left(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1\right)^{\mathrm{T}}\boldsymbol{w}}{\boldsymbol{w}^{\mathrm{T}}\left(\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1\right)\boldsymbol{w}}$$

- 类内散度矩阵

$$\mathbf{S}_w = \boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1$$

$$= \sum_{\boldsymbol{x}\in X_0}\left(\boldsymbol{x} - \boldsymbol{\mu}_0\right)\left(\boldsymbol{x} - \boldsymbol{\mu}_0\right)^{\mathrm{T}} + \sum_{\boldsymbol{x}\in X_1}\left(\boldsymbol{x} - \boldsymbol{\mu}_1\right)\left(\boldsymbol{x} - \boldsymbol{\mu}_1\right)^{\mathrm{T}}$$

- 类间散度矩阵 $\mathbf{S}_b = \left(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1\right)\left(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1\right)^{\mathrm{T}}$

- 最大化目标写成： $J = \dfrac{w^T S_b w}{w^T S_w w}$ 广义瑞利商

二分类任务 – 线性判别分析

- 最大化广义瑞利商：

$$J = \frac{w^T S_b w}{w^T S_w w} \Longleftrightarrow \mathbf{S}_b \mathbf{w} = \lambda \mathbf{S}_w \mathbf{w}$$

J(w)最大值为矩阵$S_w^{-\frac{1}{2}} S_b S_w^{-\frac{1}{2}}$的最大特征值；

对应的w′为$S_w^{-\frac{1}{2}} S_b S_w^{-\frac{1}{2}}$的最大特征值对应的特征向量；

又$S_w^{-\frac{1}{2}} S_b S_w^{-\frac{1}{2}}$ 和$\mathrm{S_w^{-1} S_b}$具有相同的最大特征值，如下：

$$(S_w^{-1} S_b) w = \lambda w$$

$\mathrm{S_b w}$平行于$\mu_0 - \mu_1$，令：

$$\mathrm{S_b w} = \lambda(\mu_0 - \mu_1)$$

代入得：$w = S_w^{-1}(\mu_0 - \mu_1)$　　原始样本的均值和方差即可以求w

3.5多分类学习

- 多分类学习方法
  - 二分类学习方法推广到多类
  - 利用二分类学习器解决多分类问题（常用）
    - 对问题进行拆分，为拆出的每个二分类任务训练一个分类器
    - 对于每个分类器的预测结果进行集成以获得最终的多分类结果

- 拆分策略
  - 一对一（One vs. One, OvO）
  - 一对其余（One vs. Rest, OvR）
  - 多对多（Many vs. Many, MvM）

3.5多分类学习 – 一对一

- 拆分阶段
  - N个类别两两配对
    - N(N-1)/2 个二类任务
  - 各个二类任务学习分类器
    - N(N-1)/2 个二类分类器

- 测试阶段
  - 新样本提交给所有分类器预测
    - N(N-1)/2 个分类结果
  - 投票产生最终分类结果
    - 被预测最多的类别为最终类别

3.5多分类学习 – 一对其余

- 任务拆分
  - 某一类作为正例，其他反例
    - N 个二类任务
  - 各个二类任务学习分类器
    - N 个二类分类器

- 测试阶段
  - 新样本提交给所有分类器预测
    - N 个分类结果
  - 比较各分类器预测置信度
    - 置信度最大类别作为最终类别

3.5多分类学习 – 两种策略比较

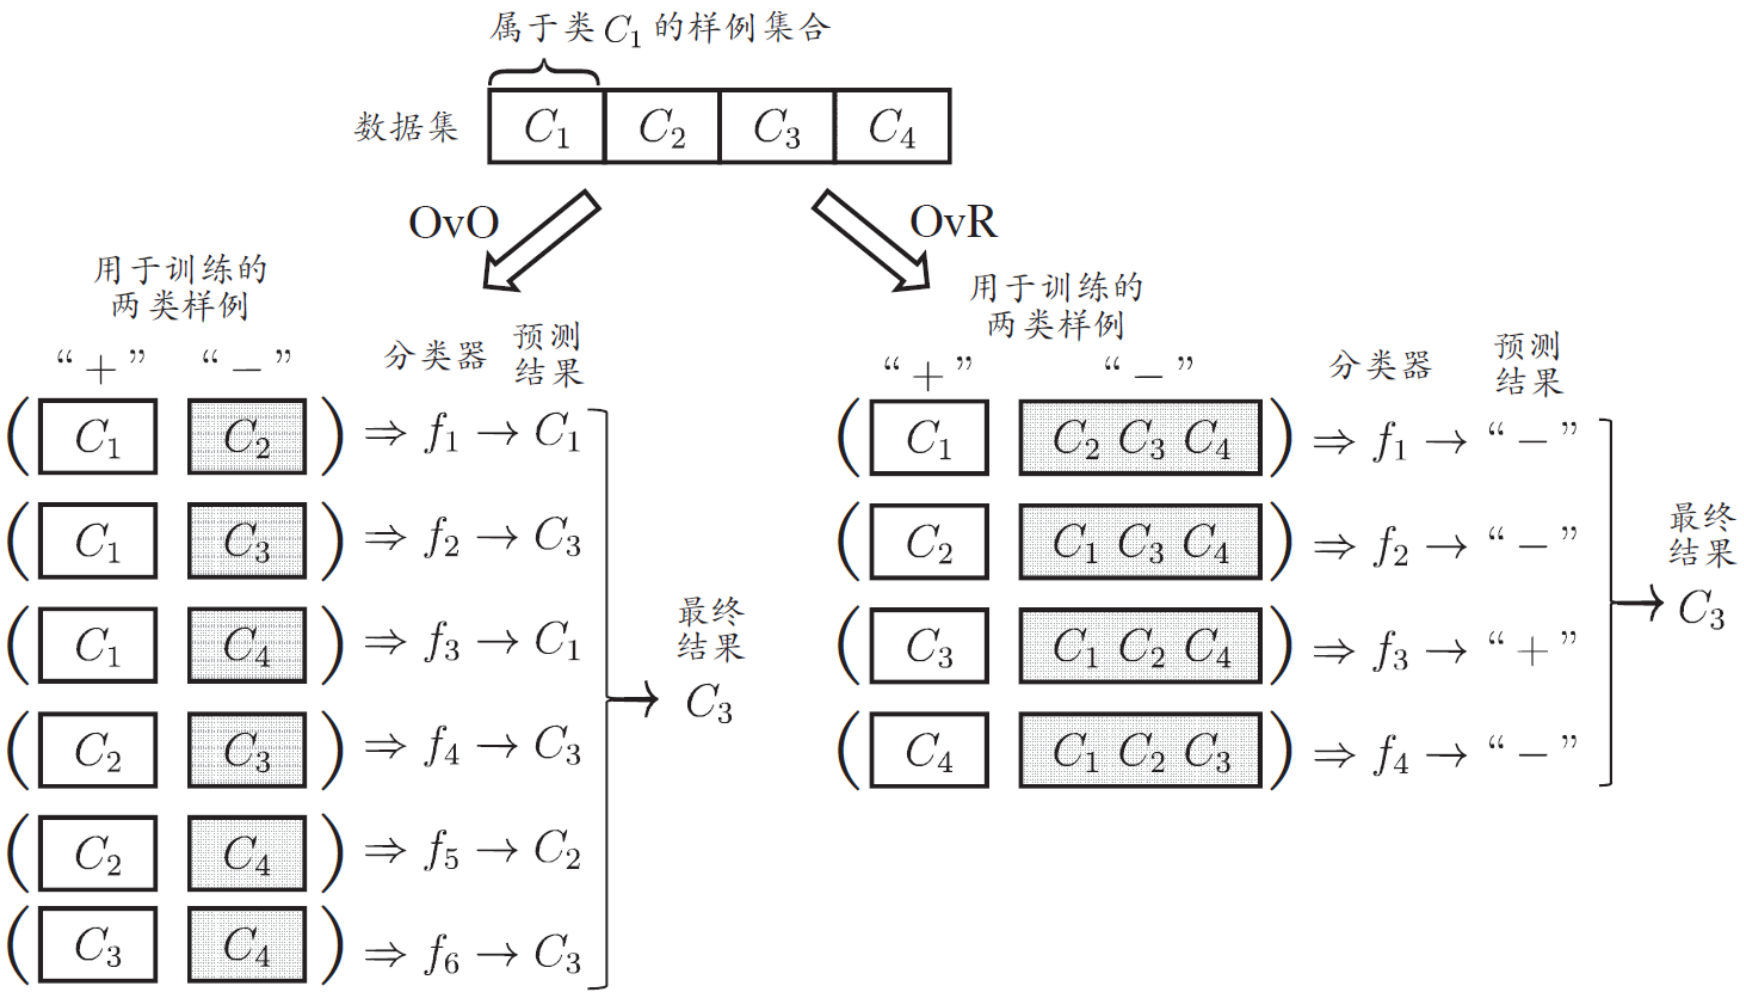

一对一　　一对其余

3.5 多分类学习 – 两种策略比较

一对一

- 训练N(N-1)/2个分类器，存储开销和测试时间大
- 训练只用两个类的样例，训练时间短

一对其余

- 训练N个分类器，存储开销和测试时间小
- 训练用到全部训练样例，训练时间长

预测性能取决于具体数据分布，多数情况下两者差不多

3.5多分类学习 – 多对多

- 多对多（Many vs Many, MvM）
  - 若干类作为正类，若干类作为反类

- 纠错输出码（Error Correcting Output Code, ECOC）

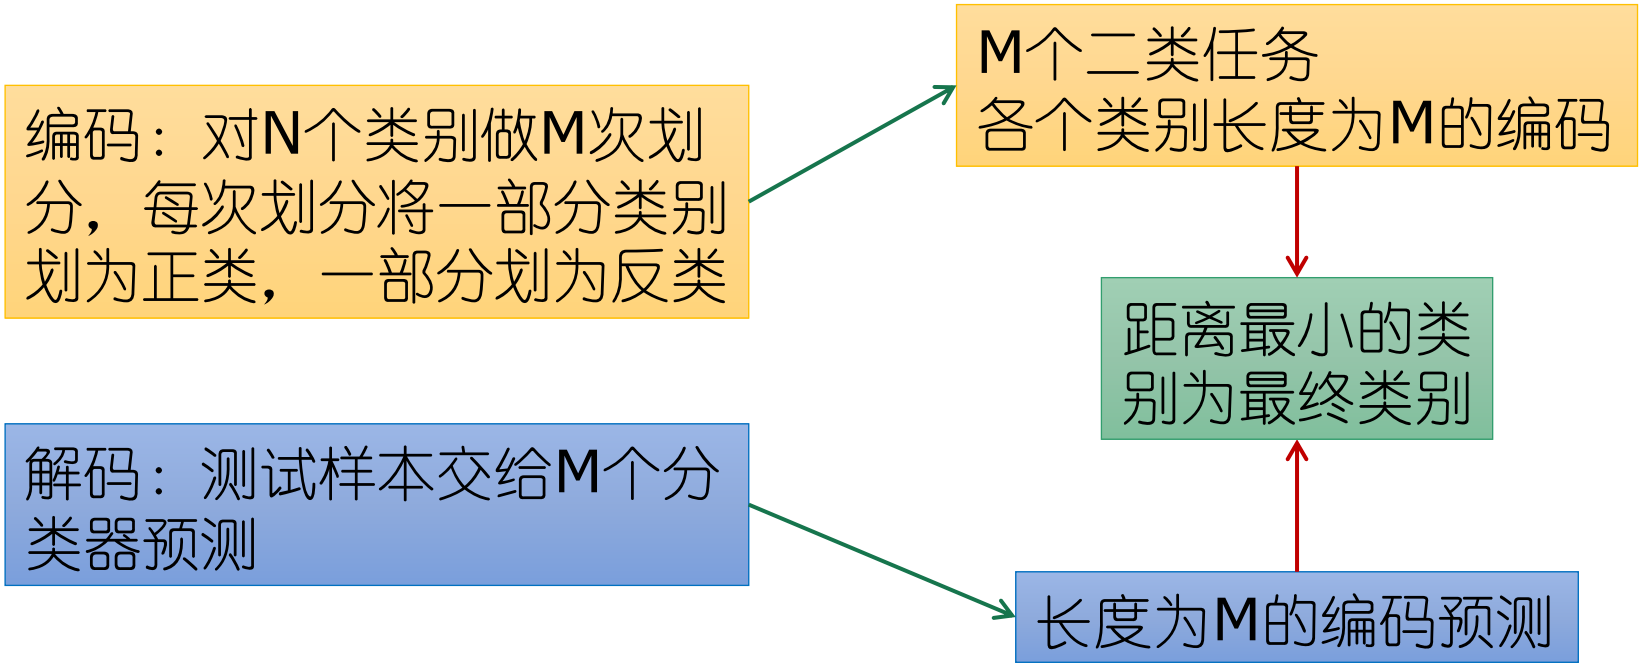

3.5多分类学习 - 多对多

- 编码阶段：
  - 二元码：把类别指定为正类和反类；
  - 三元码：把类别指定为正类、反类和停用类；
- 下图（a）f2把C1和C3作为正类；
- 下图（b）f2把C2停用；

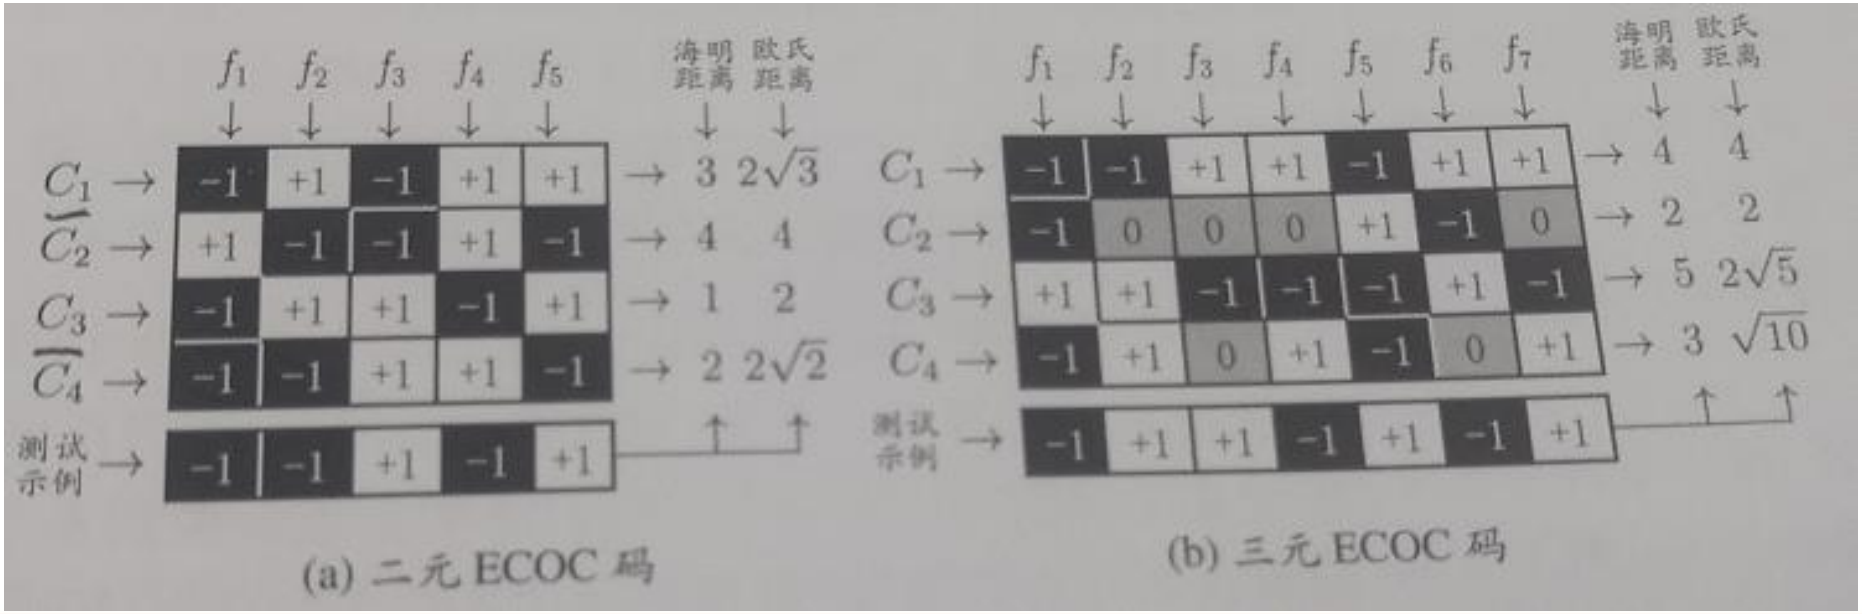

	f_1	f_2	f_3	f_4	f_5	海明距离	欧氏距离
C_1	-1	+1	-1	+1	+1	3	$2\sqrt{3}$
$\overline{C_2}$	+1	-1	-1	+1	-1	4	4
C_3	-1	+1	+1	-1	+1	1	2
$\overline{C_4}$	-1	-1	+1	+1	-1	2	$2\sqrt{2}$
测试示例	-1	-1	+1	-1	+1		

(a) 二元 ECOC 码

	f_1	f_2	f_3	f_4	f_5	f_6	f_7	海明距离	欧氏距离
C_1	-1	-1	+1	+1	-1	+1	+1	4	4
C_2	-1	0	0	0	+1	-1	0	2	2
C_3	+1	+1	-1	-1	-1	+1	-1	5	$2\sqrt{5}$
C_4	-1	+1	0	+1	-1	0	+1	3	$\sqrt{10}$
测试示例	-1	+1	+1	-1	+1	-1	+1		

(b) 三元 ECOC 码

3.5多分类学习 - 多对多

解码阶段：各个分类器的预测结果联合起来形成了测试示例的编码。

海明距离：两个合法代码对应位上编码不同的位数称为码距，又称海明距离。举例如下：10101和00110从第一位开始依次有第一位、第四、第五位不同，则海明距离为3。

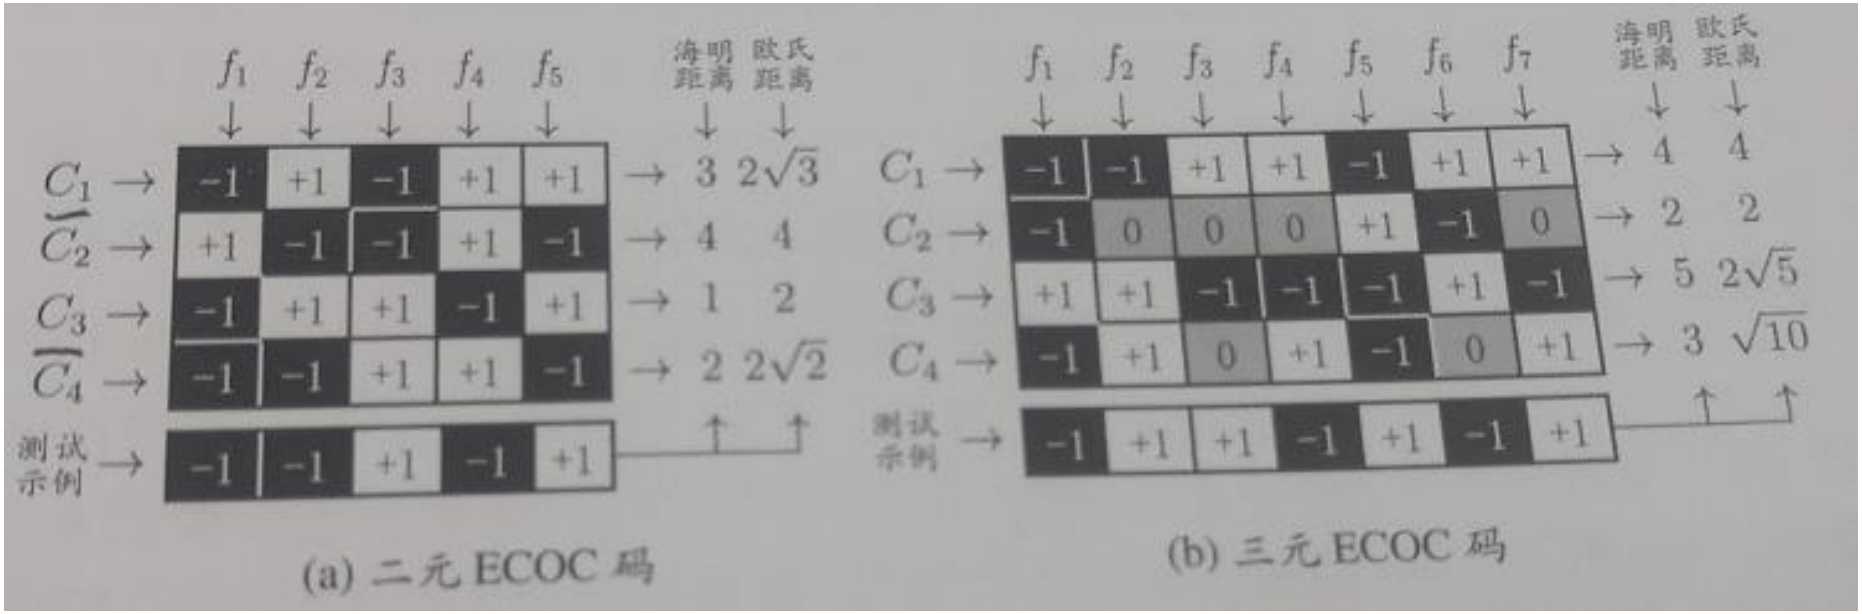

3.6类别不平衡问题

- 类别不平衡（class imbalance）
  - 不同类别训练样例数相差很大情况（正类为小类）

类别平衡正例预测 $\frac{y}{1-y} > 1$ ⇒ $\frac{y}{1-y} > \frac{m^+}{m^-}$ 正负类比例

- 再缩放
  - 欠采样（undersampling）
    - 去除一些反例使正反例数目接近（EasyEnsemble [Liu et al.,2009]）
  - 过采样（oversampling）
    - 增加一些正例使正反例数目接近（SMOTE [Chawla et al.2002]）
  - 阈值移动（threshold-moving）

总结：优化提要

- 各任务下（回归、分类）各个模型优化的目标
  - 最小二乘法：最小化均方误差
  - 对数几率回归：最大化样本分布似然
  - 线性判别分析：投影空间内最小（大）化类内（间）散度

- 参数的优化方法
  - 最小二乘法：线性代数
  - 对数几率回归：凸优化梯度下降、牛顿法
  - 线性判别分析：矩阵论、广义瑞利商

总结

- 线性回归
  - 最小二乘法（最小化均方误差）
- 二分类任务
  - 对数几率回归
    - 单位阶跃函数、对数几率函数、极大似然法
  - 线性判别分析
    - 最大化广义瑞利商
- 多分类学习
  - 一对一
  - 一对其余
  - 多对多
    - 纠错输出码
- 类别不平衡问题
  - 基本策略：再缩放